Calcolo delle Probabilità

Fabio Bonsignore

16 Agosto 2025

1 Spazi di Probabilità

1.1 Assiomi della Probabilità

Definizione 1.1.1. *Un esperimento aleatorio è un fenomeno di cui è possibile prevedere con certezza l'esito.*

Esempio 1.1.1. *Il risultato di un lancio di un dado a 6 facce.*

Definizione 1.1.2. *Lo spazio campionario è l'insieme* Ω *che contiene tutti i possibili esiti di un esperimento aleatorio.*

Esempio 1.1.2. *Nel caso del lancio un dado a 6 facce è* $\Omega = \{1, 2, 3, 4, 5, 6\}$

Definizione 1.1.3. *Un evento è un sottoinsieme dello spazio campionario, cioè l'insieme di tutti e soli gli esiti che rendono vera l'affermazione.*

Esempio 1.1.3. *L'evento "esce un numero pari" del lancio di un dado a* 6 *facce è* $A = \{2, 4, 6\}$
L'evento "esce un numero dispari è $B = \{1, 3, 5\}$
L'evento "esce un numero pari e multiplo di 3*" è* $C = A \cap B = \{6\}$
L'evento "esce un numero pari o multiplo di 3*" è* $D = A \cup B = \{2, 3, 4, 6\}$
L'evento "non esce un numero pari" è $E = A^c = \{1, 3, 5\}$
L'evento "esce 8" è $F = \varnothing$

Se Ω è un insieme finito o infinito numerabile, allora consideriamo come eventi $\mathscr{A} = \mathscr{P}(\Omega)$. Se Ω è infinito non numerabile, allora consideriamo come elementi classe degli eventi $\mathscr{A}$ quelli che rispettano:
(a) $\varnothing \in \mathscr{A}$ (b) $A \in \mathscr{A} \implies A^c \in \mathscr{A}$

(c) $\{A_n\}_{n=1}^{\infty} \subset \mathscr{A} \Longrightarrow \bigcup_{n=1}^{\infty} A_n \in \mathscr{A}$
In altre parole, la classe degli eventi $\mathscr{A}$ è una σ-algebra di sottoinsiemi di Ω.

Definizione 1.1.4. *La probabilità è una funzione $p : \mathscr{A} \to [0,1]$ tale che:*
(i) $p(\Omega) = 1$
(ii) Se $\{A_i\}_{i \in I}$ sono eventi a due a due disgiunti, allora $p(\bigcup_{i \in I} A_i) = \sum_{i \in I} p(A_i)$

Questa definizione è coerente con le interpretazioni più comuni della probabilità:
- Interpretazione frequentista: se possiamo ripetere l'esperimento aleatorio un numero elevato di volte, la probabilità è il rapporto $p(A) \cong \frac{\mathscr{C}_N(A)}{N}$, dove $\mathscr{C}_N(A)$ è il numero di volte in cui l'evento A si è verificato e N è il numero di iterazioni.
- Interpretazione soggettivista: la probabilità è il 'prezzo equo' che si è disposto a pagare di una scommessa che paga 1 se l'evento si verifica e 0 se non si verifica.

Definizione 1.1.5. *La terna $(\Omega, \mathscr{A}, p)$, dove Ω è lo spazio campionario, $\mathscr{A}$ è la classe degli eventi e p è la probabilità, si chiama spazio di probabilità.*

Teorema 1.1.1. *La probabilità è una misura, ovvero soddisfa anche:*
(i) $p(\varnothing) = 0$
(ii) Se $\{A_i\}_{i=1}^{n}$ sono eventi a due a due disgiunti, allora $p(\bigcup_{i=1}^{n} A_i) = \sum_{i=1}^{n} p(A_i)$

Proof. (i) Sia $x = p(\varnothing)$ e consideriamo la sequenza $\{\varnothing\}_{n \in \mathbb{N}}$, allora $x = p(\varnothing) = p(\bigcup_{n \in \mathbb{N}} A_n) = \sum_{n \in \mathbb{N}} p(\varnothing) = \sum_{n \in \mathbb{N}} x$, verificata se e solo se $x = 0$

(ii) Considero la sequenza $\{A_j\}_{j \in J}$, con $A_j = \varnothing$ per $j > n$. Allora, $p(\bigcup_{j=1}^{n} A_j) = p(\bigcup_{j \in J} A_j) = \sum_{j \in J} p(A_j) = \sum_{j=1}^{n} p(A_j) + \sum_{j=n+1}^{\infty} p(\varnothing) = \sum_{j=1}^{n} p(A_j)$ □

Definizione 1.1.6. *Sia μ una misura su $(\Omega, \mathscr{A})$.*
La massa di μ è il numero $\mu(\Omega) \in [0, +\infty]$
Il supporto di μ è un insieme $A \in \mathscr{A}$ tale che $\mu(A^c) = 0$

Corollario 1.1.1.1. *Una probabilità p su $(\Omega, \mathscr{A})$ è una misura su $(\Omega, \mathscr{A})$ di massa 1.*

Esempio 1.1.4. *Sia μ una misura su $(\Omega, \mathscr{A})$ con $0 < \mu(\Omega) < \infty$, allora possiamo definire una probabilità come $p(A) = \frac{\mu(A)}{\mu(\Omega)}$ ed è l'unica probabilità della forma $p(A) = c \cdot \mu(A)$*

Esempio 1.1.5. *Se Ω è finito e non vuoto, allora la probabilità uniforme discreta è $p(A) = \frac{\#A}{\#\Omega}$ ed è l'unica probabilità tale che $p(\{\omega\}) = \frac{1}{\#\Omega}$ $\forall \omega \in \Omega$*
Lo spazio di probabilità risultante è detto uniforme discreto ed è il modello naturale per descrivere esperimenti aleatori con esiti equiprobabili.

1.2 Proprietà delle Probabilità

Teorema 1.2.1. *Sia $(\Omega, \mathscr{A}, p)$ uno spazio di probabilità, allora:*
(i) $p(B\backslash A) = p(B) - p(A)$, con $A \subseteq B \in \mathscr{A}$
(ii) $p(A \cup B) = p(A) + p(B) - p(A \cap B)$, con $A, B \in \mathscr{A}$

Proof. (i) Sappiamo che $B = A \cup (B\backslash A)$, usando l'additività finita si ha $p(B) = p(A) + p(B\backslash A)$, da cui $p(B\backslash A) = p(B) - p(A)$
(ii) Sappiamo che $B = (A \cap B) \cup B\backslash A$, ovvero $B\backslash A = B\backslash(A \cap B)$ e da (i) ricaviamo che $p(B\backslash A) = p(B) - p(A \cap B)$. Dato che $A \cup B = A \cup B\backslash A$, otteniamo $p(A \cup B) = p(A) + p(B\backslash A) = p(A) + p(B) - p(A \cap B)$ □

Esempio 1.2.1. *Vogliamo calcolare la probabilità dell'evento $A =$ "esce almeno un 6 lanciando 8 dadi regolari a 6 facce". Consideriamo il complementare $A^c =$ "non esce alcun 6" $= \{\omega = (\omega_1, ..., \omega_8) \in \Omega \mid \omega_i \in \{1, 2, 3, 4, 5\}, i = 1, ..., 8\} = \{1, 2, 3, 4, 5\}^8$, da cui $\#A^c = 5^8$. Concludiamo che $p(A) = 1 - p(A^c) = 1 - \frac{\#A^c}{\#\Omega} = 1 - \frac{5^8}{6^8} = 1 - (\frac{5}{6})^8$*

Teorema 1.2.2 (Principio di Inclusione-Esclusione)**.** *Sia $(\Omega, \mathscr{A}, p)$ uno spazio di probabilità e siano $A_1, ..., A_n \in \mathscr{A}$. Allora, $p(A_1 \cup ... \cup A_n) = p(A_1) + ...p(A_n) - \sum_{1 \leqslant i < j \leqslant n} p(A_i \cap A_j) + \sum_{1 \leqslant i < j < l \leqslant n} p(A_i \cap A_j \cap A_k) - ... + (-1)^{n+1} p(A_1 \cap ... \cap A_n)$. In altre parole, $p(A_1 \cup ... \cup A_n) = \sum_{k=1}^{n} (-1)^{k+1} \sum_{A \subseteq \{1,...,n\}, |A|=k} p(\bigcap_{j \in A} A_j)$*

Teorema 1.2.3. *Sia $(\Omega, \mathscr{A})$ uno spazio misurabile e sia $p : \mathscr{A} \to [0, 1]$ una funzione che soddisfa:*
(i) $p(\Omega) = 1$
(ii) p è finitamente additiva.
Allora, sono equivalenti:
(a) p è una probabilità (dunque è σ-additiva)

(b) p è continua dal basso.
(c) p è continua dall'alto.

Corollario 1.2.3.1. *Sia $(\Omega, \mathscr{A}, p)$ uno spazio di probabilità e siano $\{A_n\}_{n\in\mathbb{N}} \subset \mathscr{A}$. Allora,*
(i) $p(\bigcup_{i\in\mathbb{N}} A_i) = \lim_{n\to\infty} p(\bigcup_{i=1}^{n} A_i)$
(ii) $p(\bigcap_{i\in\mathbb{N}} A_i) = \lim_{n\to\infty} p(\bigcap_{i=1}^{n} A_i)$

Proof. (i) Siano $B_n = \bigcup_{i=1}^{n} A_i$ e $C_n = \bigcap_{i=1}^{n} A_i$, allora $\{B_n\}_{n\in\mathbb{N}}$ sono eventi crescenti e $\bigcup_{n\in\mathbb{N}} B_n = \bigcup_{n\in\mathbb{N}} A_n$. Infatti,
- Se $\omega \in \bigcup_{n\in\mathbb{N}} A_n$, allora $\exists n \in \mathbb{N}$ tale che $\omega \in A_n$, dunque $\omega \in B_n = A_1 \cup ...A_n$ e quindi $\omega \in \bigcup_{n\in\mathbb{N}} B_n$
- Se $\omega \in \bigcup_{n\in\mathbb{N}} B_n$, allora esiste $n \in \mathbb{N}$ tale che $\omega \in B_n = A_1 \cup ...A_n$, dunque esiste $i \in \{1, ..., n\}$ per cui $\omega \in A_i$; quindi, $\omega \in \bigcup_{n\in\mathbb{N}} A_n$

Per continuità dal basso, si ha $p(\bigcup_{n\in\mathbb{N}} A_n) = p(\bigcup_{n\in\mathbb{N}} B_n) = \lim_{n\to\infty} p(B_n) = \lim_{n\to\infty} p(\bigcup_{i=1}^{n} A_i)$
(ii) Similmente, ma usando la continuità dall'alto su C_n. □

Corollario 1.2.3.2. *Siano $(\Omega, \mathscr{A}, p)$ uno spazio di probabilità e $\{A_n\}_{n\in\mathbb{N}} \subset \mathscr{A}$, allora:*
(i) $p(\bigcup_{n=1}^{N} A_n) \leqslant \sum_{n=1}^{N} p(A_n)$
(ii) $p(\bigcup_{n\in\mathbb{N}} A_n) \leqslant \sum_{n\in\mathbb{N}} p(A_n)$

Proof. (i) Procediamo per induzione su N.
$P(2)$: $p(A \cup B) = p(A) + p(B) - p(A \cap B) \leqslant p(A) + p(B)$
$P(N+1)$: $p(\bigcup_{n=1}^{n+1} A_n) = p((\bigcup_{n=1}^{N} A_n) \cup A_{N+1}) \leqslant p(\bigcup_{n=1}^{N} A_n) + p(A_{N+1}) \leqslant \sum_{n=1}^{N} p(A_n) + p(A_{N+1}) = \sum_{n=1}^{N+1} p(A_n)$

(ii) Per il corollario precedente e per (i), $p(\bigcup_{n\in\mathbb{N}} A_n) = \lim_{N\to\infty} p(\bigcup_{n=1}^{N} A_n) \leqslant \lim_{N\to\infty} \sum_{n=1}^{N} p(A_n) = \sum_{n\in\mathbb{N}} p(A_n)$ □

1.2.1 Probabilità Discrete

Definizione 1.2.1. *Sia $(\Omega, \mathscr{A}, p)$ uno spazio di probabilità. La probabilità p si dice discreta se ammette un supporto finito o numerabile, cioè esiste $\tilde{\Omega} \in \mathscr{A}$ finito o numerabile tale che $p(\tilde{\Omega}^c) = 0$*
Ogni probabilità su uno spazio campionario finito o numerabile è discreta.

Definizione 1.2.2. *Siano Ω un insieme non vuoto e $\{a(\omega)\}_{\omega\in\Omega}$ una famiglia di numeri non negativi indicizzati da Ω, ovvero $a : \Omega \to [0, \infty)$. Definiamo* $\sum_{\omega\in\Omega} a(\omega) = \sup\{\sum_{\omega\in A} a(\omega) \mid A \subseteq \Omega \text{ e } \#A < \infty\}$

Teorema 1.2.4. *Siano $\{a(\omega)\}_{\omega\in\Omega}$ e $\{b(\omega)\}_{\omega\in\Omega}$ famiglie di numeri non negativi. Allora,*
(Linearità) Se $\alpha, \beta \geqslant 0$, allora $\sum_{\omega\in\Omega} (\alpha a(\omega) + \beta b(\omega)) = \alpha \sum_{\omega\in\Omega} a(\omega) + \beta \sum_{\omega\in\Omega} b(\omega)$
(Monotonia) Se $a(\omega) \leqslant b(\omega)$ $\forall \omega \in \Omega$, allora $\sum_{\omega\in\Omega} a(\omega) \leqslant \sum_{\omega\in\Omega} b(\omega)$
(Associatività) Sia $\{I_j\}_{j\in J}$ partizione di Ω, allora $\sum_{\omega\in\Omega} a(\omega) = \sum_{j\in J} (\sum_{\omega\in I_j} a(\omega))$

Teorema 1.2.5 (Lemma)**.** *Sia $\{a(\omega)\}_{\omega\in\Omega}$ una famiglia di numeri non negativa. Se $\sum_{\omega\in\Omega} a(\omega) < \infty$, allora i termini non nulli della somma sono in quantità finita oppure numerabile (ovvero il supporto è finito o numerabile). Inoltre, se il supporto è numerabile, allora per ogni ordinamento si ha*

$$\sum_{\omega\in\Omega} a(\omega) = \sum_{\omega\in\tilde{\Omega}} a(\omega) = \sum_{n=1}^{\infty} a(\omega_n) = \lim_{N\to\infty} \sum_{n=1}^{N} a(\omega_n)$$

Proof. Per $\varepsilon > 0$, definiamo $\tilde{\Omega}_\varepsilon = \{\omega \in \Omega \mid a(\omega) > \varepsilon\}$. Allora, $\tilde{\Omega} = \bigcup_{\varepsilon>0} \tilde{\Omega}_\varepsilon = \bigcup_{k\in\mathbb{N}_0} \tilde{\Omega}_{\frac{1}{k}}$, dunque dobbiamo mostrare che $\tilde{\Omega}_{\frac{1}{k}}$ è finito per ogni $k \in \mathbb{N}_0$. Sappiamo che $S = \sum_{\omega\in\Omega} a(\omega) < \infty$ e consideriamo $\omega_1, ..., \omega_N$ punti distinti per $N \in \mathbb{N}_0$, allora $S \geqslant a(\omega_1) + ... + a(\omega_N) \geqslant \frac{N}{k}$. Dunque, $\#\tilde{\Omega}_{\frac{1}{k}} = \max\{N \in \mathbb{N}_0 \mid \exists \omega_1, ..., \omega_N \in \tilde{\Omega}_{\frac{1}{k}}\} \leqslant kS < \infty$ □

Teorema 1.2.6. *Sia $(\Omega, \mathscr{A})$ uno spazio misurabile, con $\{\omega\} \in \mathscr{A}$ per ogni $\omega \in \Omega$, e sia p una probabilità. Allora, sono equivalenti:*
(i) p è discreta
(ii) $p(A) = \sum_{\omega\in A} p(\{\omega\})$*, per ogni $A \in \mathscr{A}$*
(iii) $\sum_{\omega\in\Omega} p(\{\omega\}) = 1$

Proof. (i) $\implies$ (ii) Siano $\tilde{\Omega}$ supporto di p e $A \in \mathscr{A}$, allora $A = (A \cap \tilde{\Omega}) \cup (A \cap \tilde{\Omega}^c)$ è unione disgiunta e dunque $p(A) = p(A \cap \tilde{\Omega}) + p(A \cap \tilde{\Omega}^c) = p(A \cap \tilde{\Omega}) = p(\bigcup_{\omega \in A \cap \tilde{\Omega}}) = \sum_{\omega \in A \cap \tilde{\Omega}} p(\{\omega\}) = \sum_{\omega \in A} p(\{\omega\})$
(ii) $\implies$ (iii) Scelgo $A = \Omega$, allora $1 = p(\Omega) = \sum_{\omega \in \Omega} p(\{w\})$
(iii) $\implies$ (i) Sappiamo che $\sum_{\omega \in \Omega} p(\{\omega\}) = 1$, dunque per il lemma si ha che l'insieme dei valori per cui la probabilità è non nulla I è al più numerabile, dunque $p(I) = p(\bigcup_{\omega \in I} \{\omega\}) = \sum_{\omega \in I} p(\{\omega\}) = 1$, dunque I è un supporto di p e dunque p è discreta. □

Definizione 1.2.3. *Sia Ω un insieme non vuoto. Si dice densità discreta (o funzione di massa) su Ω ogni funzione $p : \Omega \to \mathbb{R}$ tale che:*
(i) $p(\omega) \geqslant 0$ per ogni $\omega \in \Omega$
(ii) $\sum_{\omega \in \Omega} p(\omega) = 1$

Teorema 1.2.7. *Sia p una densità discreta su un insieme Ω. Allora, la probabilità su $(\Omega, \mathscr{P}(\Omega))$ ottenuta ponendo $p(A) = \sum_{\omega \in A} p(\omega)$ per ogni $A \in \mathscr{P}(\Omega)$ è discreta.*

Esempio 1.2.2. *Per il lancio di un dado a 6 facce non necessariamente regolare, è sufficiente assegnare ad ogni numero da 1 a 6 un valore non-negativo la cui somma faccia 1.*

Esempio 1.2.3. *Sia $\lambda \in (0, \infty)$ e consideriamo su $\Omega = \mathbb{N}$ la densità discreta $p(k) = e^{-\lambda} \frac{\lambda^k}{k!}$ $\forall k \in \mathbb{N}$. Notiamo che $\sum_{k \in \mathbb{N}_0} p(k) = \sum_{k=1}^{\infty} e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1$. Dunque, p determina una probabilità discreta su Ω detta Poisson di parametro λ e si indica con $p = Pois(\lambda)$*

1.2.2 Probabilità Assolutamente Continue

Consideriamo come σ-algebra quella di Borel e per misura quella di Lebesgue.

Definizione 1.2.4. *Una funzione misurabile $f : \mathbb{R}^d \to \mathbb{R}$ si dice densità se $f(x) \geqslant 0$ $\forall x \in \mathbb{R}^d$ e $\int_{\mathbb{R}^d} f(x)dx = 1$*

Definizione 1.2.5. *Una probabilità p su $(\mathbb{R}^d, \mathscr{B}(\mathbb{R}^d))$ si dice assolutamente continua se esiste una densità f su $\mathbb{R}^d$ tale che $p(A) = \int_A f(x)dx$ $\forall A \in \mathscr{B}(\mathbb{R}^d)$*

L'utilità di queste probabilità è di ottenere un modello matematico che descrive esperimenti aleatori su quantità infinite non numerabili. Infatti, su eventi finiti o numerabili si ha $p(A) = \int_A f(x)dx = \int_{\mathbb{R}^d} f(x)\chi_A(x)m(dx) = 0$, in quanto $m(A) = 0$.

Esempio 1.2.4. *Siano $a < b \in \mathbb{R}$ e definiamo $f(x) = \frac{1}{b-a}\chi_{(a,b)}$. Allora, f è una densità su $\mathbb{R}$ e determina una probabilità assolutamente continua, detta uniforme continua su (a, b) e indicata con $p = U((a, b))$, definita da $p(A) = \int_A f(x)dx = \frac{1}{b-a}\int_{\mathbb{R}} \chi_{(a,b)}(x)\chi_A(x)dm(x) = \frac{1}{b-a}\int_{\mathbb{R}} \chi_{(a,b)\cap A}dm(x) = \frac{m(A\cap(a,b))}{m((a,b))}$*

Esempio 1.2.5. *Sia $\lambda > 0$ e definiamo $f(x) = \lambda e^{-\lambda x}\chi_{(0,\infty)}(x)$. Allora, f è una densità su $\mathbb{R}$ e determina una probabilità assolutamente continua, detta esponenziale di parametro λ, definita da $p(A) = \int_0^\infty \lambda e^{-\lambda x}\chi_A(x)dx$*

1.3 Calcolo Combinatorio

Definizione 1.3.1. *Due insiemi hanno la stessa cardinalità se e solo se esiste una biezione tra i due. Diremo che un insieme ha cardinalità $n \in \mathbb{N}$ se è in corrispondenza biunivoca con $\{1, ..., n\}$*

Osserviamo che se un insieme è unione di due insiemi disgiunti, allora la sua cardinalità è la somma delle due. Similmente, se un insieme è il prodotto cartesiano di due insiemi, allora la sua cardinalità è il prodotto delle cardinalità dei due.

1.3.1 Disposizioni con ripetizione

Definizione 1.3.2. *Dati $k \in \mathbb{N}_0$ e A un insieme finito, si dicono disposizioni con ripetizione di k elementi estratti da A le funzioni $f : \{1, ..., k\} \to A$ o, equivalentemente, i vettori $x = (x_1, ..., x_k) \in A^k$*

Teorema 1.3.1. *Esistono n^k disposizioni con ripetizioni di k elementi estratti da A con $|A| = n$.*

Esempio 1.3.1. *I possibili compleanni di 4 persone sono disposizioni con ripetizione con $k = 4$ e $|A| = 365$, dunque sono 365^4.*

Teorema 1.3.2. *Se $|\Omega| = n$, allora $|\mathscr{P}(\Omega)| = 2^n$*

Proof. Basta usare la biezione $f : \mathscr{P}(\Omega) \to \{0, 1\}^\Omega$ tale che $A \mapsto \chi_A$ □

1.3.2 Disposizioni semplici

Definizione 1.3.3. *Si dicono disposizioni semplici di k elementi estratti da un insieme A le funzioni iniettive $f : \{1, ..., k\} \to A$ o, equivalentemente, i vettori $x = (x_1, ..., x_k) \in A^k$, con $x_i \neq x_j$ per $i \neq j$.*

Se $|A| < k$, allora non esistono disposizioni semplici di k elementi estratti da A.

Teorema 1.3.3. *Esistono $\prod_{i=0}^{k-1}(n-i)$ disposizioni semplici di k elementi estratti da A con $|A| = n$.*

Definizione 1.3.4. *Per $n \in \mathbb{N}$, si definisce il fattoriale come* $n! = \begin{cases} 1, & n = 0 \\ \prod_{i=1}^{n} i, & n > 0 \end{cases}$

Il numero di disposizioni semplici può essere riscritto come $\frac{n!}{(n-k)!}$

Definizione 1.3.5. *Le funzioni biunivoche $f : A \to A$ si dicono permutazioni di A e il loro numero è $n! = |A|!$*

Nel caso in cui $A = B = \{1, ..., n\}$, l'insieme $S_n = \{f : \{1, ..., n\} \to \{1, ..., n\}$ biunivoche$\}$ si chiama gruppo simmetrico.

Esempio 1.3.2. *Mischiando un mazzo di carte, la sequenza delle carte è una permutazione del mazzo.*

Teorema 1.3.4 (Approssimazione di Stirling)**.** $n! \sim n^n e^{-n}\sqrt{2\pi n}$

Esempio 1.3.3 (Paradosso dei compleanni)**.** *Consideriamo un gruppo di n persone scelte casualmente nate in un anno non bisestile, qual è la probabilità p_n che almeno due di esse abbiano lo stesso compleanno?*
Consideriamo $\Omega = \{f : \{1, ..., n\} \to A\} \cong A^n$ e la probabilità uniforme $p(C) = \frac{|C|}{|\Omega|}$. La probabilità coincide con il numero di disposizioni non semplici e sappiamo che il numero di disposizioni con ripetizione è 365^n e di quelle semplici è $\frac{365!}{(365-n)!}$, dunque $p_n = 1 - \prod_{i=0}^{n-1} \frac{365-i}{365} = 1 - \prod_{i=0}^{n-1}(1 - \frac{i}{365})$. Provando con dei valori di n, notiamo che già solo con 23 persone la probabilità è del 50% e con 50 è del 97%. Usando la maggiorazione $1 - x \leqslant e^{-x}$, otteniamo che $p_n \geqslant 1 - \prod_{i=0}^{n-1} e^{-\frac{i}{365}} = 1 - e^{-\frac{1}{365}\sum_{i=0}^{n-1} i} = 1 - e^{-\frac{1}{365}\frac{n(n-1)}{2}}$

1.3.3 Combinazioni

Definizione 1.3.6. *Si dicono combinazioni di k elementi estratti da un insieme A i sottoinsiemi $E \subseteq A$ tali che $|E| = k$.*

Se una disposizione descrive una collezione di oggetti ordinati, una combinazione descrive una collezione di oggetti distinti.

Teorema 1.3.5. *Le combinazioni di k elementi estratti da un insieme A sono in numero $\binom{n}{k} = \frac{n!}{k!(n-k)!}$, con $|A| = n \geqslant k$.*

Teorema 1.3.6 (Binomio di Newton)**.** *Siano $a, b \in \mathbb{R}$, allora $(a+b)^n = \sum_{k=0}^{n} \binom{n}{k} a^k b^{n-k}$*

1.3.4 Principio Fondamentale

Teorema 1.3.7. *Sia E un insieme i cui elementi si possono determinare mediante k scelte successive e supponiamo che la i-esima scelta abbia n_i esiti possibili. Allora, $|E| = n_1 ... n_k$ se le sequenze distinte di esiti delle scelte determinano elementi distinti di E.*

Esempio 1.3.4. *Vogliamo calcolare la probabilità di ottenere un "full" nel gioco del Poker a 5 carte, ovvero un sottoinsieme di 5 carte del mazzo composto da un tris (3 carte dello stesso tipo) e da una coppia (2 carte dello stesso tipo).*
La prima scelta è per il tipo del tris, quindi posso scegliere tra 13 carte, la seconda scelta è per il tipo della coppia, quindi tra 12. Per quanto riguarda i semi, devo sceglierne 3 su 4 per il tris e 2 su 4 per la coppia. Dunque, $|\{FULL\}| = 13 \cdot 12 \cdot \binom{4}{3} \cdot \binom{4}{2} = 3744$
Le mani da 5 carte sono $\binom{52}{5}$, dunque usando la probabilità uniforme discreta si ha $p(FULL) \cong 0.14\%$

Esempio 1.3.5. *Vogliamo calcolare la probabilità di ottenere una "doppia coppia" nel gioco precedente, ovvero 2 coppie di tipo distinto e una quinta carta di un altro tipo ancora.*
Non conta l'ordine del tipo, dunque come prima scelta si prendono i 2 tipi su 13 per le coppie. A questo punto, rimangono 11 tipi per la quinta carta. Abbiamo ora come terza scelta i 2 semi della prima coppia su 4 e similmente per la seconda. Infine, scelgo il seme per la quinta carta. Abbiamo dunque che $|D| = \binom{13}{2} \cdot 11 \cdot \binom{4}{2} \cdot \binom{4}{2} \cdot \binom{4}{1}$, usando la stessa probabilità di prima si ha $p(D) \cong 4.8\%$

1.4 Probabilità Condizionata

Definizione 1.4.1. *Siano $A, B \in \mathscr{A}$ eventi in uno spazio di probabilità $(\Omega, \mathscr{A}, p)$ tali che $p(B) \neq 0$. Si dice probabilità condizionale di A dato B $p(A|B) = \frac{p(A \cap B)}{p(B)}$*

Esempio 1.4.1. *Si considerino due urne $\alpha = \{R, R, R, V\}$ e $\beta = \{R, V\}$ e gli eventi $A =$ "scelgo l'urna α" $= \{\alpha R, \alpha V\}$ e $B =$ "pesco una pallina rossa" $= \{\alpha R, \beta R\}$. Allora, $p(A) = \frac{1}{2}$, $p(B|A) = \frac{3}{4}$ e $p(B|A^c) = \frac{1}{2}$*

Teorema 1.4.1. *Sia $B \in \mathscr{A}$ in uno spazio di probabilità $(\Omega, \mathscr{A}, p)$ tale che $p(B) \neq 0$. Allora, l'applicazione $A \mapsto p(A|B)$ è una probabilità su $(\Omega, \mathscr{A})$ e $p(A^c|B) = 1 - p(A|B)$*

Proof. (i) $p(A|B) = \frac{p(A \cap B)}{p(B)} \geqslant 0$
(ii) $p(\Omega|B) = \frac{p(\Omega \cap B)}{p(B)} = \frac{p(B)}{p(B)} = 1$
(iii) $p(\bigcup_{n=1}^{\infty} A_n|B) = \frac{\bigcup_{n=1}^{\infty} A_n \cap B}{p(B)} = \frac{\sum_{n=1}^{\infty} p(A_n \cap B)}{p(B)} = \sum_{n=1}^{\infty} p(A_n|B)$ □

Teorema 1.4.2 (Catena)**.** *Siano $A_1, ..., A_n \in \mathscr{A}$ in uno spazio di probabilità $(\Omega, \mathscr{A}, p)$ tale che $p(A_1 \cap ... \cap A_{n-1}) \neq 0$. Allora, $p(\bigcap_{i=1}^{n} A_i) = p(A_1) \prod_{i=2}^{n} p(A_i| \bigcap_{j=1}^{i-1} A_j)$*

Proof. Scrivendo ciascuna probabilità condizionata usando la definizione, si ottiene che i numeratori e i denominatori si cancellano in successione. □

Esempio 1.4.2. *$\Omega = \{\alpha R, \alpha V, \beta R, \beta V\}$ come prima. Si può calcolare ogni probabilità valutandola sui singoletti.*
$p(\{\alpha R\}) = p(A \cap B) = p(A)p(B|A) = \frac{1}{2}\frac{3}{4} = \frac{3}{8}$
$p(\{\alpha V\}) = p(A \cap B^c) = p(A)p(B^c|A) = \frac{1}{2}(1 - p(B|A)) = \frac{1}{2}(1 - \frac{3}{4}) = \frac{1}{8}$

Teorema 1.4.3 (Formula di Disintegrazione)**.** *Siano $(\Omega, \mathscr{A}, p)$ uno spazio di probabilità e sia $\{A_i\}_{i \in I}$ una partizione di Ω (quindi disgiunti). Allora, per ogni evento B si ha $p(B) = \sum_{i \in I} p(B \cap A_i) = \sum_{i \in I} p(A_i)p(B|A_i)$*

Proof. Essendo $\{A_i\}_{i \in I}$ una partizione, si ha $\Omega = \bigcup_{i \in I} A_i$ e, ovviamente, $B = B \cap \Omega$, dunque $B = \bigcup_{i \in I} B \cap A_i$, unione finita o numerabile di eventi disgiunti, da cui otteniamo $p(B) = \sum_{i \in I} p(B \cap A_i)$ □

Esempio 1.4.3. *Usando ancora l'esempio di prima e volendo calcolare la probabilità totale $p(B)$, si ha* $p(B) = p(B|A)p(A)+p(B|A^c)p(A^c) = \frac{3}{4}\frac{1}{2}+\frac{1}{2}\frac{1}{2} = \frac{5}{8}$

Teorema 1.4.4 (Teorema di Bayes)**.** *Siano $A, B \in \mathscr{A}$ con probabilità non nulla in uno spazio di probabilità $(\Omega, \mathscr{A}, p)$. Allora,* $p(A|B) = \frac{p(B|A)p(A)}{p(B)}$

Proof. $p(A|B) = \frac{p(A\cap B)}{p(B)} = \frac{p(A)p(B|A)}{p(B)}$ □

Esempio 1.4.4. *Nell'esempio di prima, vogliamo calcolare $p(A|B)$. Allora,* $p(A|B) = \frac{\frac{3}{4}\frac{1}{2}}{\frac{5}{8}} = \frac{3}{5}$

Teorema 1.4.5 (Paradosso di Simpson)**.** *I risultati che emergono dai dati divisi in diversi gruppi possono invertirsi o scomparire se quei dati vengono combinati.*

1.5 Indipendenza di Eventi

Definizione 1.5.1. *Due eventi $A, B \in \mathscr{A}$ in uno spazio di probabilità $(\Omega, \mathscr{A}, p)$ si dicono indipendenti se* $p(A \cap B) = p(A)p(B)$

Se $p(A) = 0$, allora $p(A \cap B) \leqslant p(A) = 0$ per ogni evento B, quindi gli eventi di probabilità 0 sono sempre indipendenti da qualsiasi altro evento.

Esempio 1.5.1. *Siano Alberto, Barbara e Carola tre persone estratte casualmente dalla popolazione e si considerino gli eventi D ="A e B hanno lo stesso compleanno", E ="A e C hanno lo stesso compleanno" e F ="B e C hanno lo stesso compleanno". Assumendo che i compleanni siano indipendenti e uniformemente distribuiti nell'anno, vogliamo mostrare che gli eventi sono indipendenti. Consideriamo $\Omega = K \times K \times K$, dove K è il calendario e prendiamo la probabilità uniforme. Allora, $|D| = |E| = |F| = 365^2$ e le probabilità sono $p(D) = p(E) = p(F) = \frac{1}{365}$. Se prendiamo $|D \cap E| = 365$, si ha* $p(D \cap E) = \frac{1}{365^2} = p(D)p(E)$

Definizione 1.5.2. *Siano $\{A_i\}_{i\in I} \subset \mathscr{A}$ eventi in uno spazio di probabilità $(\Omega, \mathscr{A}, p)$, essi si dicono indipendenti se $\forall J \subseteq I$ si ha* $p(\bigcap_{j\in J} A_j) = \prod_{j\in J} p(A_j)$

In generale, eventi indipendenti non sono disgiunti perché $p(A \cap B) = p(A)p(B) > 0$ se entrambi hanno probabilità non nulla.

Corollario 1.5.0.1. *Data una famiglia infinita di eventi, essi sono indipendenti se e solo se ogni sottofamiglia finita è formata da eventi indipendenti.*

Esempio 1.5.2. *Riprendendo l'esempio del calendario, mostriamo che* $p(D\cap E\cap F) \neq p(D)p(E)p(F)$*, ovvero sono dipendenti. Infatti,* $D\cap E\cap F = D\cap E$*, quindi* $p(D\cap E\cap F) = p(D\cap E) = p(D)p(E) \neq p(D)p(E)p(F)$

Teorema 1.5.1. *Siano* $n\in\mathbb{N}$ *e* $A_1,...,A_n$ *eventi. Allora, sono equivalenti:*
(i) $A_1,...,A_n$ *sono indipendenti*
(ii) Per ogni scelta di $B_1,...,B_n$*, dove* $B_i = A_i \vee B_i = A_i^c$*, si ha* $p(B_1\cap...\cap B_n) = p(B_1)...p(B_n)$

Proof. $(ii)\implies(i)$ Nel caso $n=2$, scelgo $B_1=A_1$ e $B_2=A_2$, quindi per la formula si ha $p(A_1\cap A_2)=p(A_1)p(A_2)$ che torna con la formula.
Consideriamo ora $n\geqslant 2$ e $J\subseteq\{1,...,n\}$ con $|J|\geqslant 2$. Se $|J|=n$, è immediato scegliendo $B_i=A_i$. WLOG, supponiamo $J\subseteq\{1,...,n-1\}$ per il caso $|J|\leqslant n-1$, applichiamo la formula di disintegrazione su $C=B_1\cap...B_{n-1}$, dove $B_i\in\{A_i,A_i^c\}$ $p(C)=p(B_1\cap...\cap B_{n-1}\cap A_n)+p(B_1\cap...\cap B_{n-1}\cap A_n^c)=p(B_1)...p(B_{n-1})p(A_n)+p(B_1)...p(B_{n-1})p(A_n^c)=p(B_1)...p(B_{n-1})(p(A_n)+p(A_n^c))=p(B_1)...p(B_{n-1})$
$(i)\implies(ii)$ WLOG basta mostrare che $p(C\cap A_k^c\cap D)p(A_1^c\cap...\cap A_k^c\cap A_{k+1}\cap...\cap A_n)=p(A_1^c)...p(A_k^c)p(A_{k+1})...p(A_n)$ per ogni $k=0,...,n$. Il caso $k=0$ è ovvio per definizione con $J=\{1,...,n\}$. Procediamo per induzione applicando la formula di disintegrazione $p(C\cap A_k^c\cap D)=p(C\cap D)-p(C\cap A_k\cap D)$, da cui $p(A_1^c\cap...A_{k-1}^c\cap A_{k+1}\cap...\cap A_n)-p(A_1^c\cap...\cap A_{k-1}^c\cap A_k\cap A_{k+1}\cap...\cap A_n)=p(A_1^c)...p(A_{k-1}^c)p(A_{k+1})...p(A_n)-p(A_1^c)...p(A_{k-1}^c)p(A_k)p(A_{k+1})...p(A_n)=p(A_1^c)...p(A_{k-1}^c)[1-p(A_k)]p(A_{k+1})...p(A_n)=p(A_1^c)...p(A_{k-1}^c)p(A_k^c)p(A_{k+1})...p(A_n)$ □

Corollario 1.5.1.1. *Siano* $\{A_i\}_{i\in I}$ *eventi indipendenti e* $I'\subset I$ *e definiamo* $\{C_i\}_{i\in I}$ *ponendo* $C_i=\begin{cases}A_i,\ i\in I\backslash I'\\ A_i^c,\ i\in I'\end{cases}$*. Allora,* $\{C_i\}_{i\in I}$ *sono eventi indipendenti.*

1.5.1 Prove Ripetute Indipendenti

Definizione 1.5.3. *Sia* $P\in[0,1]$ *e siano* $\{C_i\}_{i\in I}$ *eventi indipendenti in uno spazio di probabilità* $(\Omega,\mathscr{A},p)$ *indicizzati da un insieme* I *finito o numerabile. Diremo che tali eventi descrivono prove ripetute indipendenti con probabilità di successo* P*. Quando* $I=\{1,...,n\}$*, con* $n\in\mathbb{N}$*, o* $I=\mathbb{N}$*, adotteremo l'interpretazione* C_i *="la i-esima prova ha successo".*

Costruzione di spazi di probabilità per prove ripetute Fissiamo $n \in \mathbb{N}$, $P \in [0,1]$ e consideriamo lo spazio canonico $\Omega = \Omega_n = \{0,1\}^n = \{\omega = (\omega_1, ..., \omega_n) \mid \omega_j \in \{0,1\}\}$

Teorema 1.5.2. *Per ogni $n \in \mathbb{N}$ e per ogni $P \in [0,1]$ esiste ed è unica la probabilità p su $\Omega = \Omega_n$ tale che $C_1, ..., C_n$ siano eventi indipendenti con $p(C_i) = P$.*

Proof. (Unicità) Supponiamo che la probabilità esista, fissiamo $\omega \in \Omega$ e definiamo $B_i = \begin{cases} C_i, & w_i = 1 \\ C_i^c, & w_i = 0 \end{cases}$
Allora, deve essere $p(\{\omega\}) = p(B_1)...p(B_n) = P^{k(\omega)}(1-P)^{n-k(\omega)}$, dove $k(\omega) = |\{i = 1, ..., n \mid \omega_i = 1\} = \sum_{i=1}^{n} \omega_i$. Dunque, $p(\{\omega\}) = P^{\sum_{i=1}^{n} \omega_i}(1-P)^{\sum_{i=1}^{n}(1-\omega_i)} = \prod_{i=1}^{n}(P^{\omega_i}(1-P)^{1-\omega_i})$, dunque deve essere unica.
(Esistenza) Definiamo la funzione su Ω tale che $p(\omega) = \prod_{i=1}^{n}(P^{\omega_i}(1-P)^{1-\omega_i})$, osserviamo che $p(\omega) \geqslant 0$ e $\sum_{\omega \in \Omega} p(\omega) = \prod_{i=1}^{n} \sum_{\omega_i \in \{0,1\}} P^{\omega_i}(1-P)^{1-\omega_i} = \prod_{i=1}^{n}(1 - P + P) = 1$, dunque è una densità discreta e definisce una probabilità che indichiamo con la stessa lettera.
Dobbiamo mostrare che $p(C_i) = P$, mostriamolo su $C_n = \{\omega \in \Omega_n \mid \omega_n = 1\} = \{0,1\}^{n-1} \times \{1\} = \Omega_{n-1} \times \{1\}$ $p(C_n) = \sum_{\omega \in C_n} p(\omega) = \sum_{\omega \in C_n} \prod_{i=1}^{n} P^{\omega_i}(1-P)^{1-\omega_i} = P \sum_{\omega \in \Omega_{n-1}} \prod_{i=1}^{n-1} P^{\omega_i}(1-P)^{1-\omega_i} = P$, per simmetria dunque vale per ogni $i \in \{1, ..., n\}$
Siano $\{B_i\}_{i=1}^{n}$ s.t. $B_i = C_i \vee B_i = C_i^c$ e vogliamo mostrare che sono indipendenti $p(B_1 \cap ... \cap B_n) = p(\{\omega\}) = \prod_{i=1}^{n} P^{\omega_i}(1-P)^{1-\omega_i} = P^{\sum_{i=1}^{n} \omega_i}(1-P)^{1-\sum_{i=1}^{n} \omega_i} = \prod_{i=1}^{n} p(B_i)$, e quindi $C_1, ..., C_n$ sono indipendenti. Siano ora □

La costruzione per estendere a una successione infinita numerabile viene fatta con la scelta dello spazio $\Omega = \{0,1\}^{\mathbb{N}}$, che però ora ha cardinalità dei numeri reali. Consideriamo gli insiemi $C_{x_1,...,x_n} = \{w \in \Omega \mid w_1 = x_1, ..., w_n = x_n\}$ e osserviamo che è un π-sistema, ovvero è stabile per intersezioni finite,

e dunque prendiamo come σ-algebra $\mathscr{A} = \sigma(\{C_{x_1,...,x_n} \mid x_1, ..., x_n \in \{0,1\}\})$. Allora, si può dimostrare il seguente risultato.

Teorema 1.5.3. *Per ogni $n \in \mathbb{N}$ e per ogni $P \in [0,1]$ esiste ed è unica la probabilità p su $\Omega = \{0,1\}^{\mathbb{N}}$ tale che $C_1, ..., C_n$ siano eventi indipendenti con $p(C_i) = P$. Inoltre, i singoletti devono avere probabilità zero, dunque non è discreta.*

Almeno un successo nelle prove ripetute Consideriamo delle prove ripetute indipendenti e l'evento D_n ="almeno una di queste prove ha successo" $= \bigcup_{i=1}^{n} C_i$, allora $p(D_n^c) = p(C_1^c \cap ... \cap C_n^c) = p(C_1^c)...p(C_n^c) = (1-P)...(1-P) = (1-P)^n$; dunque, $p(D_n) = 1 - p(D_n^c) = 1 - (1-p)^n$. Facendo tendere il numero di prove all'infinito, si avrà che $p(D_n) = \begin{cases} 1, & p > 0 \\ 0, & p = 0 \end{cases}$
Dunque, se $p > 0$ esiste $n_0 = n_0(p) < \infty$ tale che $p(D_n) \geqslant 99,99\% \ \forall n \geqslant n_0$

Esempio 1.5.3 (Paradosso della scimmia di Borel)**.** *Su una tastiera ci sono $T = 100$ tasti e una scimmia li preme casualmente con probabilità uniforme $q = \frac{1}{100}$. Se assumiamo che i tasti siano premuti in modo indipendente, allora la probabilità che la scimmia componga la Divina Commedia senza errori è circa $p = q^N \cong (\frac{1}{100})^{510000} = 10^{-1020000} > 0$. Dunque, definitivamente sarà molto probabile che si abbia un successo.*

Se consideriamo delle prove ripetute infinite volte, sarà direttamente $p(D) = \begin{cases} 1, & p > 0 \\ 0, & p = 0 \end{cases}$

Numero di successi e istante di successo Fissiamo infinite prove ripetute e indipendenti, vogliamo ora studiare la probabilità di avere il primo successo entro la k-esima prova e di avere k-successi nelle prime n-prove.
Consideriamo, dunque, l'evento B_k ="il primo successo si verifica nella prova numero k" $= C_1^c \cap ...C_{k-1}^c \cap C_k$, dunque $p(B_k) = p(C_1^c)...p(C_{k-1}^c)p(C_k) = P(1-P)^{k-1}$
Ora consideriamo l'evento $A_{n,k}$ ="esattamente k successi nelle prime n prove" $= \bigcup_{I \subseteq \{1,...,n\} \ |I|=k} (\bigcap_{i \in I} C_i) \cap (\bigcap_{j \in \{1,...,n\} \setminus I} C_i^c)$, dunque $p(A_{n,k}) = \binom{n}{k} p^k (1-p)^{n-k}$

2 Variabili Aleatorie

2.1 Distribuzioni

Definizione 2.1.1. *Sia $(\Omega, \mathscr{A}, p)$ uno spazio di probabilità e $(E, \mathscr{E})$ uno spazio misurabile. Una variabile aleatoria è una funzione $X : \Omega \to E$ che sia misurabile rispetto a $\mathscr{A} - \mathscr{E}$*
Se $E = \mathbb{R}$, diremo che X è una variabile aleatoria reale (o scalare o di numero aleatorio).
Se $E = \mathbb{R}^d$, diremo che X è una variabile vettoriale (o vettore aleatorio).

Non sono da confondere con gli eventi: infatti gli eventi sono sottoinsiemi, mentre le variabili aleatorie sono funzioni. Tuttavia, ogni evento $A \in \mathscr{A}$ determina una variabile aleatoria $X = \chi_A$ e ogni variabile aleatoria determina una classe di eventi $\sigma(X) = \{X^{-1}(B) \mid B \in \mathscr{E}\} \subseteq \mathscr{A}$

Esempio 2.1.1. *Nel lancio di un dado a 6 facce, una variabile aleatoria è l'esito del dado, mentre un evento è "esce il numero* 6*"*

Esempio 2.1.2. *"Il politico Gianfilippo si presenta alla elezioni". Una variabile aleatoria è "numero di voti ottenuti da Gianfilippo", mentre un evento è "Gianfilippo non riceve alcun voto".*

Scriveremo $X^{-1}(B) = \{X \in B\} = \{\omega \in \Omega \mid X(\omega) \in B\}$, in questo modo un'espressione del tipo $p(\{X \in B\})$ è corretta.

Definizione 2.1.2. *Siano $(F, \mathscr{F})$ e $(E, \mathscr{E})$ spazi misurabili e $\phi : F \to E$ una funzione misurabile. Per ogni misura μ su $(F, \mathscr{F})$ è determinata la misura immagine $\mu_\phi = \phi_\# \mu$ che è la misura definita come $\mu_\phi(B) = \mu(\phi^{-1}(B)) \ \forall B \in \mathscr{E}$*

La misura immagine ha la stessa massa della misura di partenza, dunque se μ è una probabilità lo è anche μ_ϕ

Definizione 2.1.3. *Sia $X : (\Omega, \mathscr{A}, p) \to (E, \mathscr{E})$ una variabile aleatoria, si dice legge (o distribuzione) di X la misura immagine μ_X di p mediante X, ovvero $\mu_X(B) = p(X \in B) \ \forall B \in \mathscr{E}$*

Definizione 2.1.4. *Sia $X : (\Omega, \mathscr{A}, p) \to (E, \mathscr{E})$ una variabile aleatoria. Un sottoinsieme $I \in \mathscr{E}$ si dice spettro di X se e solo se I è un supporto di μ_X, ovvero $\mu_X(I) = 1$*

Esempio 2.1.3. *Lancio due dadi regolari a 6 facce e indico con X e Y gli esiti dei dadi e con $S = X + Y$ la loro somma. Abbiamo che $\Omega = \{1,2,3,4,5,6\}^2 = \{\omega = (\omega_1, \omega_2) \mid \omega_i \in \{1,2,3,4,5,6\}\}$, $\mathscr{A} = \mathscr{P}(\Omega)$ e p è la probabilità uniforme discreta. Allora, $X(\omega) = \omega_1$, $Y(\omega) = \omega_2$ e $S(\omega) = \omega_1 + \omega_2$. Uno spettro per X (e per Y) è $I = X(\Omega) = \{1,2,3,4,5,6\}$, infatti $\mu_X(I) = p(X \in \{1,2,3,4,5,6\}) = 1$, dunque μ_X e μ_Y sono probabilità discrete reali con supporto finito. Inoltre, $\mu_X(\{x\}) = p(X \in \{x\}) = p(X = x) = \frac{1}{6}$, dunque $\mu_X = \mu_Y$ è la probabilità uniforme su $\{1,2,3,4,5,6\}$*

Ricordiamo un risultato di teoria della misura per ottenerne un'applicazione utile.

Teorema 2.1.1. *Siano $(E, \mathscr{E})$ uno spazio misurabile, G una base di $\mathscr{E}$ e μ, μ' misure finite su $(E, \mathscr{E})$ con la stessa massa ($\mu(E) = \mu'(E)$). Se $\mu = \mu'$ su G, allora $\mu = \mu'$.*

Corollario 2.1.1.1. *Due probabilità μ, μ' su $\mathbb{R}^d$ che coincidono su una base di $\mathbb{R}^d$ sono la stessa probabilità.*

Definizione 2.1.5. *Sia E un insieme, si chiama misura del conteggio la misura $\mathscr{C} : \mathscr{P}(E) \to [0, \infty]$ definita da $A \mapsto |A|$*

Teorema 2.1.2 (Lemma)**.** *Siano E un insieme e $\{a(x)\}_{x \in E}$ una famiglia di numeri non negativi indicizzati da E, allora $\sum_{x \in E} a(x) = \int_E a d\mathscr{C}$*

Corollario 2.1.2.1. *Sia $(E, \mathscr{E})$ uno spazio misurabile che contiene tutti i singoletti. Una probabilità μ su E è discreta se e solo se ammette densità rispetto alla misura del conteggio $\mathscr{C}$ su E.*

Definizione 2.1.6. *Sia X una variabile aleatoria in $\mathbb{R}^d$, X si dice discreta se la sua legge è una probabilità discreta su $\mathbb{R}^d$.*
Analogamente, si dice assolutamente continua se la sua legge è una probabilità assolutamente continua su $\mathbb{R}^d$.

Se $E = \mathbb{R}^d$ e X è discreta con densità discreta $p_X(x) = p(X = x)$ uno spettro è $I = \{x \in \mathbb{R}^d \mid p_X(x) > 0\}$, se X è assolutamente continua con densità $f_X(x)$ uno spettro è $I = \{x \in \mathbb{R}^d \mid f_X(x) > 0\}$

Teorema 2.1.3 (Lemma)**.** *Una variabile aleatoria X in $\mathbb{R}^d$ è discreta se vale una delle seguenti condizioni:*

(i) X ammette uno spettro al più numerabile.
(ii) $p(X \in B) = \sum_{x \in B} p(X = x)$ *per ogni* $B \in \mathscr{B}(\mathbb{R}^d)$
(iii) $\sum_{x \in \mathbb{R}^d} p(X = x) = 1$ *(se* $d = 1$*, diventa* $\sum_{x \in \mathbb{R}} [F_X(x) - F_X(x^-)] = 1$*)*
(iv) $p(X \leqslant x) = \sum_{y \in (-\infty, x]} g(y)$*, per una funzione* $g : \mathbb{R}^d \to [0, \infty)$
In tale caso, la densità discreta di X *è data da* $g_X(x) = p(X = x)$

Teorema 2.1.4 (Lemma)**.** *Una variabile aleatoria in* $\mathbb{R}^d$ *è assolutamente continua se e solo se* $p(X \leqslant x) = \int_{(-\infty, x]} f(y)dy \ \forall x \in \mathbb{R}^d$*, per una funzione misurabile* $f : \mathbb{R}^d \to [0, \infty)$
In tal caso, $f(x) = f_X(x)$ *è densità di* X*, quindi* $p(X \in B) = \int_B f(x)x \ \forall B \in \mathscr{B}(\mathbb{R}^d)$

Definizione 2.1.7. *Sia* μ *una probabilità su* $\mathbb{R}^d$*, allora si dice funzione di ripartizione (o di distribuzione) associata a* μ *la funzione* $F_\mu : \mathbb{R}^d \to [0, 1]$ *tale che* $x \mapsto \mu((-\infty, x])$

Teorema 2.1.5. *Se* μ, μ' *sono probabilità su* $\mathbb{R}^d$ *tali che* $F_\mu = F_{\mu'}$*, allora* $\mu = \mu'$*. In altre parole, la funzione di ripartizione identifica la probabilità.*

Teorema 2.1.6. *Sia* μ *una probabilità su* $\mathbb{R}$*, allora la funzione di ripartizione soddisfa:*
(i) F_μ *è non decrescente.*
(ii) F_μ *è continua da destra.*
(iii) $F_\mu(-\infty) = 0$ *e* $F_\mu(\infty) = 1$
Viceversa, ogni funzione $F : \mathbb{R} \to [0, 1]$ *che soddisfa le proprietà precedenti è una funzione di ripartizione per qualche probabilità* ν *su* $\mathbb{R}$

Teorema 2.1.7. *Sia* μ *una probabilità su* $\mathbb{R}$ *con funzione di ripartizione* F_μ*. Allora,* $\mu((-\infty, x)) = F_\mu(x^-) = \lim_{y \to x^-} F_\mu(y)$*. Inoltre,*
$\mu(\{x\}) = F_\mu(x) - F_\mu(x^-)$
$\mu((a, b]) = F_\mu(b) - F_\mu(a)$
$\mu([a, b)) = F_\mu(b^-) - F_\mu(a^-)$
$\mu([a, b]) = F_\mu(b) - F_\mu(a^-)$
$\mu((a, b)) = F_\mu(b^-) - F_\mu(a)$

Proof. Osserviamo preliminarmente che seguono tutte dalla prima, in quanto
$\{x\} = (-\infty, x] \backslash (-\infty, x)$
$(a, b] = (-\infty, b] \backslash (-\infty, a]$

$[a,b) = (-\infty, b)\backslash(-\infty, a)$
$[a,b] = (-\infty, b]\backslash(-\infty, a)$
$(a,b) = (-\infty, b)\backslash(-\infty, a]$
Definiamo $A_n = (-\infty, x - \frac{1}{n}]$ e si ha $(-\infty, x) = \bigcup_{n\in\mathbb{N}_0} A_n$. Gli insiemi sono crescenti, dunque per continuità dal basso si ha $\mu((-\infty, x)) = \mu(\bigcup_{n\in\mathbb{N}_0} A_n) = \lim_{n\to\infty} \mu(A_n) = \lim_{n\to\infty} F_\mu(x - \frac{1}{n}) = \lim_{y\to x^-} F_\mu(y) = F_\mu(y^-)$ □

Teorema 2.1.8. *(i) Una probabilità μ su $\mathbb{R}$ è discreta se e solo se esiste $p : \mathbb{R} \to [0,\infty)$ s.t. $F_\mu(x) = \mu((-\infty, x]) = \sum_{y\leqslant x} p(y)$ e in tal caso p è la densità discreta associata a μ*
(ii) Una probabilità μ su $\mathbb{R}$ è assolutamente continua se e solo se esiste $f : \mathbb{R} \to [0,\infty)$ misurabile s.t. $F_\mu(x) = \mu((-\infty, x]) = \int_{-\infty}^{x} f(y)dy$ e in tal caso f è la densità associata a μ

Proof. (ii)
($\Longrightarrow$) Ovvio.
($\Longleftarrow$) $1 = F_\mu(+\infty) = \lim_{y\to\infty} F_\mu(y) = \lim_{n\to\infty} F_\mu(n) = \lim_{n\to\infty} \int_{-\infty}^{n} f(y)dy = \lim_{n\to\infty} \int_{\mathbb{R}} f(y)\chi_{(-\infty,n]}(y)dy = \int_{\mathbb{R}} f(y)dy$ per il TCM, dunque f è una densità. □

Definizione 2.1.8. *Sia $X : (\Omega, \mathscr{A}, p) \to (\mathbb{R}^d, \mathscr{B}(\mathbb{R}^d))$ una variabile aleatoria in $\mathbb{R}^d$, si chiama funzione di ripartizione di X la funzione di ripartizione della sua legge μ_X $F_X(x) = p(X \leqslant x)$ $\forall x \in \mathbb{R}^d$*

Dai teoremi precedenti, se due variabili aleatorie X, X' hanno la stessa funzione di ripartizione, allora $\mu_X = \mu_{X'}$

Definizione 2.1.9. *Una funzione $F : \mathbb{R} \to \mathbb{R}$ si dice $\mathscr{C}^1$ a tratti se esiste $N \subseteq \mathbb{R}$ senza punti di accumulazione tale per cui:*
(i) F è continua.
(ii) F è derivabile in $\mathbb{R}\backslash N$
(iii) $F' : \mathbb{R}\backslash N \to \mathbb{R}$ è continua in ogni punto di $\mathbb{R}\backslash N$

Teorema 2.1.9 (Lemma)**.** *Se $F : \mathbb{R} \to \mathbb{R}$ è $\mathscr{C}^1$ a tratti e monotona, allora $F(b) - F(a) = \int_a^b F'(x)dx$ $\forall a < b \in \mathbb{R}$.*
Se inoltre $F(-\infty) = \lim_{a\to-\infty} F(a) \in \mathbb{R}$ si ha $F(b) - F(-\infty) = \int_{-\infty}^{b} F'(x)dx$

Corollario 2.1.9.1. *Se una variabile aleatoria reale X ha funzione di ripartizione F_X $\mathscr{C}^1$ a tratti, allora F_X è assolutamente continua con densità $f_X = F'_x$*

Esempio 2.1.4. *Estraiamo un numero casuale ω uniformemente in $[0,1]$, siano X l'area del quadrato di lato ω e sia Y il perimetro dello stesso. Si ha $\Omega = [0,1]$, $\mathscr{A} = \mathscr{B}([0,1])$ e $p = U([0,1])$. Allora, $X(\omega) = \omega^2$ e $Y(\omega) = 4\omega$. Dato che se $0 \leqslant \omega \leqslant 1$, allora $0 \leqslant \omega^2 \leqslant 1$, quindi $X(\Omega) = [0,1]$ è uno spettro per X. In particolare, $F_X(x) = p(X \leqslant x) = \begin{cases} 0, & x < 0 \\ 1, & x > 1 \end{cases}$*
E' chiaro che $F_X(x) = p(X \leqslant x) = p([0,\sqrt{x}]) = U([0,\sqrt{x}]) = \sqrt{x}$. Dunque, $F_X(x) = \begin{cases} 0, & x < 0 \\ \sqrt{x}, & 0 \leqslant x \leqslant 1 \\ 1, & x > 1 \end{cases}$ e quindi F_X è $\mathscr{C}^1$ a tratti e dunque X è assolutamente continua con densità $F_X'(x) = \begin{cases} 0, & x \leqslant 0 \\ \frac{1}{2\sqrt{x}}, & 0 < x < 1 \\ 0, & x \geqslant 1 \end{cases}$, estendendo $F_X'(x) = 0$ per $x \in \{0,1\}$. X non è uniformemente distribuita e la densità diverge per $x \to 0^+$ e i valori della densità non sono delle probabilità. Similmente, si può calcolare F_Y e dedurre che Y è uniformemente distribuita in $[0,4]$

Sia X una variabile assolutamente continua in $\mathbb{R}^d$, allora $p(X = x) = 0$ per ogni $x \in \mathbb{R}^d$ perché è l'integrale su un singoletto. Dunque, in generale $p(X = x) \neq f_X(x)$ a meno che $f_X(x) = 0$
Il fatto che $p(X \in \mathbb{R}^d) = 1$ ma $p(X = x) = 0$ è dovuto al fatto che $\mathbb{R}^d = \bigcup_{x \in \mathbb{R}^d} \{x\}$ è un'unione più che numerabile.
Se poniamo $d = 1$ relazione tra la densità e la funzione di ripartizione è che $F_X'(x) = f_X(x)$, allora $f_X(x) = \lim\limits_{\varepsilon \to 0^+} \frac{F_X(x+\varepsilon) - F_X(x)}{\varepsilon} = \lim\limits_{\varepsilon \to 0^+} \frac{p(X \in (x, x+\varepsilon])}{\varepsilon}$, se F_X è derivabile in x. Da questo, deduciamo che $p(X \in [a,b]) = p(X \in (a,b)) = p(X \in (a,b]) = p(X \in [a,b))$.
Se consideriamo il grafico di f_X, osserviamo che sulle ascisse ci sono i valori assunti dalla variabile aleatoria e le regioni dove la densità f_X è maggiore, corrispondono a regioni di valori più probabili per la variabile aleatoria. In particolare, uno spettro di X è $I = \{x \in \mathbb{R}^d \mid f_X(x) > 0\}$
Notiamo infine che la densità di una variabile aleatoria assolutamente continua non è univocamente determinata, ad esempio una funzione g_X uguale quasi-ovunque a f_X è un'altra densità.

Esempio 2.1.5. *Siano $(E, \mathscr{E})$ uno spazio misurabile e μ una misura, possiamo costruire una variabile aleatoria prendendo $X : \Omega \to E$ ponendo $X = id$,*

infatti $\mu_X(B) = p(X \in B) = p(X^{-1}(B)) = \mu(B)$. *Questa è detta costruzione canonica di una variabile aleatoria di legge assegnata.*

Esempio 2.1.6. *Siano* $(\Omega, \mathscr{A}, p)$ *uno spazio di probabilità e* $c \in \mathbb{R}$, *allora possiamo definire* $X(\omega) = c$ *una variabile aleatoria costante. Allora,*

$$\mu_X(B) = p(X \in B) = p(X^{-1}(B)) = \begin{cases} p(\Omega) = 1, \ c \in B \\ p(\varnothing) = 0, \ c \notin B \end{cases} \quad \text{quindi } \mu_X = \delta_c$$

Esempio 2.1.7. *Sia* $(\Omega, \mathscr{A}, p)$, *possiamo considerare la variabile aleatoria* $X = \chi_A$ *per* $A \in \mathscr{A}$, *allora* μ_X *è la probabilità discreta con densità discreta*

$$p_X(x) = p(X = x) = \begin{cases} p(A) \ , x = 1 \\ p(A^c) = 1 - p(A), \ x = 0 \\ 0, \ x \notin 0, 1 \end{cases} \text{. Se poniamo } p = p(A) \in$$

$[0, 1]$, *possiamo scrivere* $\mu_X = p\delta_1 + (1-p)\delta_0$. *Le variabili aleatorie con tale legge si dicono Bernoulli di parametro* p *e scriveremo* $X \sim Be(p)$

Siano $X : (\Omega, \mathscr{A}, p) \to (E, \mathscr{E})$ una variabile aleatoria e $\phi : (E, \mathscr{E}) \to (F, \mathscr{F})$ una funzione misurabile, allora possiamo considerare la variabile aleatoria $Y = \phi \ o \ X$, la cui legge è $\mu_Y(C) = p(Y \in C) = p(\phi \ o \ X \in C) = p(X \in \phi^{-1}(C)) = \mu_X(\phi^{-1}(C))$ con $C \in \mathscr{F}$, cioè μ_Y è la misura immagine di μ_X mediante ϕ.

Teorema 2.1.10. *Nelle ipotesi precedenti, se* X *è discreta allora* Y *è discreta.*

Proof. Sappiamo che X ha spettro al più numerabile e definiamo $J = \phi(I)$, si ha che $|J| = |\phi(I)| \leqslant |I|$, dunque J è finito, e $1 \geqslant (Y \in J) = p(\phi \ o \ X \in J) = p(X \in \phi^{-1}(J)) \geqslant p(X \in I) = 1$, dunque J è uno spettro per Y. Concludiamo con la tesi. □

Invece, se X è assolutamente continua non è detto che lo sia anche la trasformata, ad esempio se ϕ è costante allora Y è una variabile aleatoria costante e dunque discreta.

Teorema 2.1.11. *Siano* X *una variabile aleatoria reale assolutamente continua con densità* f_X , $a, b \in \mathbb{R}$ *con* $a \neq 0$ *e definiamo* $Y = aX + b$. *Allora,* Y *è assolutamente continua con densità* $f_Y(y) = \frac{1}{|a|} f_X(\frac{y-b}{a})$

Proof. Siano per semplicità $a > 0$ e F_X derivabile, allora $F_Y(y) = p(aX + b \leqslant y) = p(X \leqslant \frac{y-b}{a}) = F_X(\frac{y-b}{a})$, dunque $f_Y(y) = F_Y'(y) = F_X'(\frac{y-b}{a})\frac{1}{a} = f_X(\frac{y-b}{a})\frac{1}{a}$ □

Teorema 2.1.12. *Siano X un vettore aleatorio in $\mathbb{R}^d$ assolutamente continuo e $Y = AX + b$ con $A \in \mathbb{R}^{d\times d}$ e $b \in \mathbb{R}^d$. Allora, Y è assolutamente continua con densità $f_Y(y) = \frac{1}{|det(A)|} f_X(A^{-1}(y-b))$ $\forall y \in \mathbb{R}^d$*

Teorema 2.1.13. *Siano X e Y variabili aleatorie definite su $(\Omega, \mathscr{A}, p)$ a valori in $(E, \mathscr{E})$. Se X e Y sono uguali quasi-ovunque ($X(\omega) = Y(\omega)$ per quasi-ovunque $\omega \in \Omega$), allora X e Y hanno la stessa legge se e solo se $p(X = Y) = 1$.*

Proof. $\mu_X(B) = p(X \in B) = p(X \in B, X = Y) = p(Y \in B, X = Y) = p(Y \in B) = \mu_Y(B)$ □

Teorema 2.1.14 (Conservazione della Legge)**.** *Siano X e Y variabili aleatorie a valori nello stesso spazio misurabile $(E, \mathscr{E})$ e $\phi : (E, \mathscr{E}) \to (F, \mathscr{F})$ misurabile. Se X e Y hanno la stessa legge, anche $\phi(X)$ e $\phi(Y)$ hanno la stessa legge.*

Proof. Sia $B \in \mathscr{F}$, allora $\mu_{\phi(X)}(B) = p(\phi(X) \in B) = p(X \in \phi^{-1}(B)) = \mu_X(\phi^{-1}(B)) = \mu_Y(\phi^{-1}(B)) = p'(Y \in \phi^{-1}(B)) = p'(\phi(Y) \in B) = \mu_{\phi(Y)}(B)$ ($p' \neq p$, in quanto non viene richiesto siano definite sullo stesso spazio di probabilità). □

2.2 Leggi Marginali e Legge Congiunta

Definizione 2.2.1. *Siano $(\Omega, \mathscr{A}, p)$ uno spazio di probabilità e X, Y variabili aleatorie a valori, rispettivamente, in $(E, \mathscr{E})$ e $(F, \mathscr{F})$ spazi misurabili, allora possiamo definire la variabile aleatoria congiunta $Z = (X, Y) : \Omega \to E \times F$.*
La distribuzione (o legge) della coppia $Z = (X, Y)$ si chiama distribuzione congiunta delle variabili aleatorie X e Y ed è una probabilità su $(E \times F, \mathscr{E} \otimes \mathscr{F})$.
Le distribuzioni delle variabili aleatorie X e Y si dicono distribuzioni marginali di X e Y.

Userò la lettera Z per indicare la variabile aleatoria congiunta da qui in avanti, a meno che non sia diversamente specificato.

Teorema 2.2.1. *La distribuzione congiunta di due variabili aleatorie X e Y come sopra determina le leggi marginali:*
$\mu_X(A) = \mu_Z(A \times F)$
$\mu_Y(B) = \mu_Z(E \times B)$

Proof. Mostriamola per il primo caso.
$\mu_X(A) = p(X \in A) = p(X \in A, Y \in F) = p(Z \in A \times F) = \mu_Z(A \times F)$ □

Il viceversa non è vero.

Esempio 2.2.1. *Lancio due dadi regolari a 6 facce e siano X e Y l'esito del primo e del secondo lancio, allora $\mu_X = \mu_Y = U(\{1,2,3,4,5,6\})$. Se consideriamo le coppie $Z = (X,Y)$ e $Z' = (X,X)$, hanno le stesse distribuzioni marginali ma distribuzione congiunta distinta. Infatti, $\mu_Z(\{4,6\}) = p(Z = (4,6)) = p(X = 4, Y = 6) = \frac{1}{36}$, mentre $\mu_{Z'}(\{4,6\}) = p(Z' = (4,6)) = p(X = 4, X = 6) = 0$*

Teorema 2.2.2. *Siano X e Y variabili aleatorie reali definite sullo stesso spazio di probabilità.*
(i) Se (X,Y) è assolutamente continua, allora lo sono anche X e Y con densità $f_X(x) = \int_{\mathbb{R}} f_{(X,Y)}(x,y)dy$ e $f_Y(y) = \int_{\mathbb{R}} f_{(X,Y)}(x,y)dx$ quasi-ovunque.
(ii) Se (X,Y) è discreta, allora lo sono anche X e Y con densità discreta $p_X(x) = \sum_{y \in \mathbb{R}} p_{(X,Y)}(x,y)$ e $p_Y(y) = \sum_{x \in \mathbb{R}} p_{(X,Y)}(x,y)$

Non fatta. (i) Sia $A \in \mathscr{B}(\mathbb{R})$, allora $\mu_X(A) = \mu_Z(A \times \mathbb{R}) = \int_{A \times \mathbb{R}} f_Z(x,y)dxdy = \int_{\mathbb{R}^2} \chi_{A \times \mathbb{R}}(x,y) f_Z(x,y)dxdy = \int_{\mathbb{R}} (\int_{\mathbb{R}} \chi_{A \times \mathbb{R}}(x,y) f_Z(x,y)dy)dx = \int_{\mathbb{R}} \chi_A(x)(\int_{\mathbb{R}} f_Z(x,y)dy)dx$ che, ponendo $g(x) = \int_{\mathbb{R}} f_Z(x,y)dy$, si ha $\mu_X(A) = \int_A g(x)dx$, che è una densità perché scegliendo $A = \mathbb{R}$ si ha $\int_{\mathbb{R}} g(x)dx = 1$ □

Esempio 2.2.2. *Sia Z un punto scelto uniformemente nel 2-disco unitario e prendiamo X la scelta dell'ascissa e Y la scelta dell'ordinata. Sappiamo che Z è assolutamente continua con densità $f_Z(z) = \begin{cases} \frac{1}{\pi}, & z \in D \\ 0, & z \notin D \end{cases}$ Per il teorema precedente, si ha che $f_X(x) = \int_{\mathbb{R}} f_Z(x,y)dy = 0$ per $x \notin [-1,1]$, altrimenti si ha $f_Z = \frac{1}{\pi}$ e $y^2 \leqslant 1 - x^2$, dunque $f_Z(x,y) = \begin{cases} \frac{1}{\pi}, & y \in [-\sqrt{1-x^2}, \sqrt{1-x^2}] \\ 0, & \text{altrimenti} \end{cases}$ e quindi $f_X(x) = \int_{\mathbb{R}} f_Z(x,y) = \int_{\mathbb{R}} \frac{1}{\pi} \chi_{[-\sqrt{1-x^2}, \sqrt{1-x^2}]}(y)dy = \frac{1}{\pi} 2\sqrt{1-x^2}$.*
Concludiamo che $f_X(x) = \begin{cases} \frac{2}{\pi}\sqrt{1-x^2}, & x \in [-1,1] \\ 0, & x \notin [-1,1] \end{cases}$ e quindi $X(\Omega) = [-1,1]$.
Per simmetria, Y ha la stessa distribuzione.

Teorema 2.2.3. *Siano X e Y variabili aleatorie discrete, allora $Z = (X,Y)$ è discreta.*

Proof. Siano I e J gli spettri di X e di Y, dunque al più numerabili. Allora, $K = I \times J$ è al più numerabile ed è uno spettro per Z perché $p(Z \in K) = p((X,Y) \in I \times J) = p(X \times I, Y \in J) = 1$ (intersezione di eventi con probabilità 1). □

Esempio 2.2.3 (Controesempio per assolutamente continue)**.** *Sia X una variabile aleatoria arbitraria e $Z = (X, X)$, allora Z non può essere assolutamente continua. Si consideri a tal proposito la diagonale D e per costruzione si ha $Z(\omega) \in D$, dunque $p(Z \in D) = 1$. Supponiamo per assurdo che sia assolutamente continua con densità f_Z, allora $p(Z \in D) = \int_D f_Z(x,y)dxdy = \int_{\mathbb{R}^2} f_Z(z)\chi_D(z)m(dz) = 0$ perché D ha misura nulla, generando un assurdo.*

Le affermazioni fatte finora si estendono naturalmente al caso in cui ci siano un numero finito di variabili aleatorie.

2.3 Indipendenza di variabili aleatorie

Definizione 2.3.1. *Siano X e Y variabili aleatorie definite su uno spazio di probabilità $(\Omega, \mathscr{A}, p)$ a valori, rispettivamente, in $(E, \mathscr{E})$ e $(F, \mathscr{F})$. Esse si dicono indipendenti se $p(X \in A, Y \in B) = p(X \in A)p(Y \in B)$*

Ricordando che $\sigma(X) = \{\{X \in A\} = X^{-1}(A) \mid A \in \mathscr{E}\} \subseteq \mathscr{A}$ è la classe degli eventi generati da X, allora X e Y sono indipendenti se e solo se ogni evento generato da X è indipendente da ogni evento generato da Y.

Definizione 2.3.2. *Siano $X_1, ..., X_n$ variabili definite su uno spazio di probabilità $(\Omega, \mathscr{A}, p)$ a valori, rispettivamente, in $(E_1, \mathscr{E}_1)$, ..., $(E_n, \mathscr{E}_n)$. Esse si dicono indipendenti se $p(\bigcap_{i=1}^{n} \{X_i \in A_i\}) = \prod_{i=1}^{n} p(X_i \in A_i)$.*
Se sono in una quantità numerabile, allora si dicono indipendenti se ogni sottofamiglia finita è indipendente.

Teorema 2.3.1. *Siano X e Y variabili aleatorie come sopra. Esse si dicono indipendenti se e solo se la distribuzione congiunta è il prodotto delle distribuzioni marginali $\mu_Z = \mu_X \otimes \mu_Y$*

Proof. X e Y sono indipendenti se e solo se $p(X \in A, Y \in B) = p(X \in A)p(Y \in B) \iff \mu_Z(A \times B) = \mu_X(A)\mu_Y(B) = (\mu_X \otimes \mu_Y)(A \times B) \iff \mu_Z(C) = (\mu_X \otimes \mu_Y)(C)\ \forall C = A \times B$, con $A \in \mathscr{E}, B \in \mathscr{F} \iff \mu_Z(C) = (\mu_X \otimes \mu_Y)(C)\ \forall C \in \mathscr{E} \otimes \mathscr{F}$ □

Teorema 2.3.2. *Siano X e Y variabili aleatorie reali (o vettoriali).*
(i) Se X e Y sono assolutamente continue, allora sono indipendenti se e solo se Z è assolutamente continua con densità $f_Z(x,y) = f_X(x)f_Y(y)$ quasi-ovunque.
(ii) Se X e Y sono discrete, allora sono indipendenti se e solo se Z è discreta con densità discreta $p_Z(x,y) = p_X(x)p_Y(y)$

Proof. (i) Dal teorema precedente si ha che sono indipendenti se e solo se $\mu_Z = \mu_X \otimes \mu_Y$, quindi basta mostrare che quest'ultimo è assolutamente continua con densità $g(x,y) = f_X(x)f_Y(y)$. Sappiamo che g è misurabile e $\int_{\mathbb{R}^2} g(x,y)dxdy = \int_{\mathbb{R}}(\int_{\mathbb{R}} f_X(x)f_Y(y)dy)dx = \int_{\mathbb{R}} f_X(x)(\int_{\mathbb{R}} f_Y(y)dy)dx = \int_{\mathbb{R}} f_X(x)dx = 1$, dunque g è una densità.
Sia p la probabilità assolutamente continua associata alla densità g, cioè $p(C) = \int_C g(x,y)dxdy$ e dobbiamo verificare che coincide con $\mu_X \otimes \mu_Y$. Scegliamo come base dei borelliani di gli insiemi prodotto dei borelliani su $\mathbb{R}$, allora per $A, B \in \mathscr{B}(\mathbb{R})$ si ha $\mu_X \otimes \mu_Y(A \times B) = \mu_X(A)\mu_Y(B) = (\int_A f_X(x)dx)(\int_B f_Y(y)dy) = \int_{A\times B} f_X(x)f_Y(y)dxdy = \int_{A\times B} g(x,y)dxdy = p(A\times B)$ □

Teorema 2.3.3 (Conservazione dell'Indipendenza)**.** *Siano X e Y variabili aleatorie indipendenti definite su $(\Omega, \mathscr{A}, p)$ a valori, rispettivamente, in $(E, \mathscr{E})$ e $(F, \mathscr{F})$, $\phi : (E, \mathscr{E}) \to (E', \mathscr{E}')$ e $\psi : (F, \mathscr{F}) \to (F', \mathscr{F}')$ misurabili. Allora, le variabili aleatorie $\phi(X)$ e $\psi(Y)$ sono indipendenti.*

Proof. Siano $A \in \mathscr{E}'$ e $B \in \mathscr{F}'$, allora $p(\phi(X) \in A, \psi(Y) \in B) = p(X \in \phi^{-1}(A), Y \in \psi^{-1}(B)) = p(X \in \phi^{-1}(A))p(Y \in \psi^{-1}(B)) = p(\phi(X) \in A)p(\psi(Y) \in B)$ □

Teorema 2.3.4 (Indipendenza a Blocchi)**.** *Siano $m, n \in \mathbb{N}_0$ e siano $X_1, ..., X_{n+m}$ variabili aleatorie indipendenti. Allora, i vettori $Y = (X_1, ..., X_n)$ e $T = (X_{n+1}, ..., X_{n+m})$ sono indipendenti.*

Corollario 2.3.4.1. *Se $X_1, ..., X_{n+m}$ sono variabili aleatorie indipendenti, allora le variabili aleatorie $S = X_1 + ... + X_n$ e $T = X_{n+1} + ... + X_{n+m}$ sono indipendenti.*

Proof. Discende dall'indipendenza a blocchi e dalla conservazione dell'indipendenza con le funzioni misurabili $\phi(x_1, ..., x_n) = x_1 + ... + x_n$ e $\psi(z_1, ..., z_m) = z_1 + ...z_m$ □

2.4 Trasformazioni di variabili aleatorie

Teorema 2.4.1 (Lemma)**.** *Siano X e Y variabili aleatorie reali definite su $(\Omega, \mathscr{A}, p)$, allora $S = X + Y$ ha funzione di ripartizione $F_S(s) = p(S \leqslant s) = \mu_Z(A_s)$, dove $A_s = \{(x, y) \in \mathbb{R}^2 \mid x + y \leqslant s\}$*

Proof. Per definizione, $\{S \leqslant s\} = \{X + Y \leqslant s\} = \{Z \in A_s\}$, dunque $F_S(s) = p(S \leqslant s) = p(Z \in A_s) = \mu_Z(A_s)$ □

Teorema 2.4.2. *Siano X e Y variabili aleatorie reali tali che Z è assolutamente continua. Allora, la variabile aleatoria $S = X + Y$ è assolutamente continua con densità $f_S(s) = \int_{\mathbb{R}} f_Z(x, s - x)dx = \int_{\mathbb{R}} f_Z(s - y, y)dy$*

Proof. Per il lemma precedente, $F_S(s) = \mu_Z(A_s) = \int_{A_s} f_Z(x, y)dxdy$ e sia $t = x+y$. Allora, $F_S(s) = \int_{\mathbb{R}^2} \chi_{A_s}(x, t-x)f_Z(x, t-x)dxdt = \int_{\mathbb{R}^2} \chi_{\{t \leqslant s\}} f_Z(x, t-x)dxdt = \int_{\mathbb{R}} \chi_{\{t \leqslant s\}}(\int_{\mathbb{R}} f_Z(x, t - x)dx)dt = \int_{-\infty}^{s}(\int_{\mathbb{R}} f_Z(x, t - x)dx)dt$. Concludiamo che S è assolutamente continua con densità $h(t) = \int_{\mathbb{R}} f_Z(x, t - x)dx$ □

Teorema 2.4.3. *Siano X e Y variabili aleatorie reali tali che Z è discreta. Allora, la variabile aleatoria $S = X + Y$ è discreta con densità discreta $p_S(s) = \sum_{x \in \mathbb{R}} p_Z(x, s - x) = \sum_{y \in \mathbb{R}} p_Z(s - y, y)$*

Corollario 2.4.3.1. *Siano X e Y variabili reali indipendenti.*
(i) Se sono assolutamente continue, $S = X+Y$ è assolutamente continua con densità $f_S(s) = \int_{\mathbb{R}} f_X(x)f_Y(s - x)dx = \int_{\mathbb{R}} f_X(s - y)f_Y(y)dy = (f_X * f_Y)(s)$ (la convoluzione di f_X e f_Y)
(ii) Se sono discrete, allora $S = X+Y$ è discreta con densità discreta $p_S(s) = \sum_{x \in \mathbb{R}} p_X(x)p_Y(s - x) = \sum_{y \in \mathbb{R}} p_X(s - y)p_Y(y)$

Teorema 2.4.4. *Siano X e Y variabili aleatorie reali indipendenti definite sullo stesso spazio di probabilità. Allora, posti $M = \max\{X, Y\}$ e $W = \min\{X, Y\}$ si ha $F_M(t) = F_X(t)F_Y(t)$ e $F_W(t) = 1 - (1 - F_X(t))(1 - F_Y(t))$*

Teorema 2.4.5. *Siano $U \subseteq \mathbb{R}^d$, X un vettore aleatorio a valori in U e $\phi : U \to V$ un diffeomorfismo. Se X è assolutamente continua, allora anche $Y = \phi(X)$ lo è e ha densità $f_Y(y) = \begin{cases} f_X(\phi^{-1}(y))\lvert det(D\phi^{-1}(y))\rvert, \ y \in V \\ 0, \ y \notin V \end{cases}$*

Proof. Dobbiamo mostrare che $p(Y \in B) = \int_B f_Y(y)dy$, ma $Y = \phi(X) \in B \iff X \in \phi^{-1}(B)$, dunque $p(Y \in B) = p(X \in \phi^{-1}(B)) = \int_{\phi^{-1}(B)} f_X(x)dx = \int_U f_X(x)\chi_{\phi^{-1}(B)}(x)dx$, facendo il cambio di variabili $\psi = \phi^{-1}$, $p(Y \in B) = \int_V f_X(\phi^{-1}(y))\chi_{\phi^{-1}(B)}(\phi^{-1}(y))|det(D\phi^{-1}(y))dy = \int_B f_X(\phi^{-1}(y))|det(D\phi^{-1}(y))dy = \int_B f_Y(y)dy$ □

Corollario 2.4.5.1. *Siano X assolutamente continua in $\mathbb{R}^d$, $A \in \mathbb{R}^{d\times d}$ non singolare e $b \in \mathbb{R}^d$, allora anche $Y = AX + b$ è assolutamente continua con densità discreta $f_Y(y) = f_X(A^{-1}(y-b))|det(A^{-1})|$*

2.5 Valore Medio, Momenti, Varianza e Covarianza

2.5.1 Valore medio

Definizione 2.5.1. *Una funzione misurabile $f : E \to \overline{\mathbb{R}}$ tale che $I_\mu(f^+) < \infty$ o $I_\mu(f^-) < \infty$ è detta semi-integrabile.*

Definizione 2.5.2. *La classe delle variabili aleatorie integrabili è indicata con $L^1(\Omega, \mathscr{A}, p)$*

Definizione 2.5.3. *Sia X una variabile aleatoria reale (estesa) definita su uno spazio di probabilità. Se X è semi-integrabile, l'integrale di X si indica con $E[X] = I_p(x) = \int_\Omega X dp = \int_\Omega X(\omega)dp(\Omega)$ e si chiama valore medio (o media, o aspettativa, o valore atteso, o speranza matematica) della variabile aleatoria X.*

Teorema 2.5.1. *Il valore medio soddisfa le seguenti proprietà:*
(i) $E[\alpha X + \beta Y] = \alpha E[X] + \beta E[Y]$ per ogni $X, Y \in L^1$ e $\alpha, \beta \in \mathbb{R}$
(ii) Se $X \leqslant Y$, allora $E[X] \leqslant E[Y]$
(iii) $|E[X]| \leqslant E[|X|]$

Teorema 2.5.2 (Formula di Trasferimento)**.** *Sia $X : (\Omega, \mathscr{A}, p) \to (E, \mathscr{E})$ una variabile aleatoria e sia $\phi : (E, \mathscr{E}) \to \overline{\mathbb{R}}$ misurabile. Allora, $E[\phi(X)] = \int_E \phi d\mu_X$*

Proof. Dimostriamolo per classi crescenti di ϕ.
Se $\phi = \chi_B$, allora $E[\phi(X)] = E[\chi_B(x)] = E[\chi_{X\in B}] = \int_\Omega \chi_{X\in B}dp = p(X \in B) = \mu_X(B) = \int_E \chi_B d\mu_X = \int_E \phi d\mu_X$
Se ϕ è semplice, deriva dalla linearità di entrambi i membri.
Se ϕ è positiva, deriva dalla convergenza monotona di entrambi i membri.
Se ϕ ha segno qualunque, è vera per differenza $\phi = \phi^+ - \phi^-$ a condizione che almeno uno dei due ammetta valore medio finito. □

Corollario 2.5.2.1 (Calcolo del valore medio)**.** *Sia X una variabile aleatoria reale con densità f_X. Allora, se gli integrali sono definiti, valgono le seguenti formule:*
$E[\phi(X)] = \int_{\mathbb{R}} \phi(x) f_X(x) dx$
$E[X^p] = \int_{\mathbb{R}} x^p f_X(x) dx$
Se (X, Y) è un vettore aleatorio,
$E[\phi(X,Y)] = \int_{\mathbb{R}^2} \phi(x,y) f_Z(x,y) dxdy$
$E[XY] = \int_{\mathbb{R}^2} xy f_Z(x,y) dxdy$
Se X e Y sono discrete con densità discrete p_X e p_Y, allora
$E[\phi(X)] = \sum_{x \in \mathbb{R}} \phi(x) p_X(x)$
$E[X^p] = \sum_{x \in \mathbb{R}} x^p p_X(x)$
$E[XY] = \sum_{(x,y) \in \mathbb{R}^2} xy p_Z(x,y)$

Corollario 2.5.2.2. *Due variabili aleatorie con la stessa legge hanno lo stesso valore medio.*

Proof. Deriva dalla formula di trasferimento e dal fatto che il valore medio di una variabile aleatoria reale dipende solo dalla sua legge $E[X] = \int_{\mathbb{R}} x d\mu_X(x)$ □

Interpretazione del valore medio Sia X una variabile aleatoria uniforme discreta in $I = \{x_1, ..., x_n\} \subseteq \mathbb{R}$, allora $E[X] = \sum_{x \in \mathbb{R}} x p_X(x) = \sum_{i=1}^{n} x_i \frac{1}{n}$. Notiamo che se interpretiamo le x_I come le posizioni di punti materiali, il valore medio coincide col baricentro. Notiamo che può non essere uno dei valori assunti dalla variabile aleatoria.
Sia ora non uniforme, allora $E[X] = \sum_{x \in \mathbb{R}} x p_X(x) = \frac{x_1 p_1 + ... + x_n p_n}{p_1 + ... + p_n}$, che è il baricentro di n punti materiali con masse p_i e posizioni x_i.
Consideriamo una famiglia di variabili aleatorie IID tali che il valore medio $m = E[X_i]$ esista finito. Intuitivamente, le X_i possono rappresentare osservazioni ripetuta di una medesima quantità aleatoria di ripetizioni indipendenti in uno stesso esperimento aleatorio.

2.5.2 Varianza, Covarianza e Deviazione Standard

Definizione 2.5.4. *Siano X e Y variabili aleatorie reali (estese) definite sullo stesso spazio di probabilità tali che $X, Y, X \cdot Y, X^2 \in L^1$.*

Si definisce covarianza di X e Y la quantità $Cov[X,Y] = E[(X-E[X])(Y-E[Y])] = E[XY] - E[X]E[Y] \in \mathbb{R}$
Si definisce varianza di X la quantità $Var[X] = Cov[X,X] = E[(X-E[X])^2] = E[X^2] - E[X]^2 \in [0,\infty)$
Si definisce deviazione standard di X la quantità $\sigma_X = SD[X] = \sqrt{Var[X]} \in [0,\infty)$

Intuitivamente, se $E[X]$ rappresenta il centro della distribuzione dei valori assunti da X, la deviazione standard è una misura della larghezza o dispersione dei valori assunti da X rispetto al centro.

Definizione 2.5.5. *Definiamo* $L^2 = L^2(\Omega, \mathscr{A}, p) = \{X : (\Omega, \mathscr{A}, p) \to \overline{\mathbb{R}} \mid E[X^2] \in \mathbb{R}\}$

Teorema 2.5.3. *La covarianza è un operatore simmetrico, bilineare. Inoltre, se X è quasi-ovunque costante, allora* $Cov[X,Y] = 0$

Teorema 2.5.4. *La varianza non è lineare e* $Var[\alpha X + \beta] = \alpha^2 Var[X]$. *Inoltre,* $Var[X] = 0$ *se e solo se X è quasi-ovunque costante e* $Var[\sum_{i=1}^{n} X_i] = \sum_{i=1}^{n} Var[X_i] + 2 \sum_{1 \leqslant i \leqslant j \leqslant n} Cov[X_i, X_j]$

Teorema 2.5.5. *Siano X e Y variabili aleatorie reali (estese). Se $X, Y \in L^1$ o $X, Y \geqslant 0$, allora $XY \in L^1$ e* $E[XY] = E[X]E[Y]$.

Proof. Se $X = \chi_A$ e $Y = \chi_B$, allora sono indipendenti se e solo se A e B lo sono.
$E[XY] = E[\chi_A \chi_B] = E[\chi_{A \cap B}] = p(A \cap B) = p(A)p(B) = E[\chi_A]E[\chi_B] = E[X]E[Y]$. Con ragionamenti simili a quelli fatti per il valore medio, possiamo estenderlo a variabili aleatorie di segno qualunque. □

Corollario 2.5.5.1. *Se X e Y sono variabili aleatorie reali indipendenti e integrabili, allora* $Cov[X,Y] = 0$. *Si dice che X e Y sono scorrelate.*

2.6 Spazi L^P

Definizione 2.6.1. *Sia X una variabile reale estesa. Allora, per ogni $P \in (0,\infty)$ si definisce momento assoluto di ordine P di X la quantità* $E[|X|^P] \in [0,\infty]$
Se $P = k \in \mathbb{N}_0$, si definisce momento di ordine k di X la quantità $E[X^k] \in [0,\infty]$

Definizione 2.6.2. *Siano $P \in [0,\infty]$ e $(\Omega, \mathscr{A}, p)$ uno spazio di probabilità. Si definisce $L^P = L^P(\Omega, \mathscr{A}, p) = \{X : (\Omega, \mathscr{A}, p) \to \overline{\mathbb{R}} \mid E[|X|^P] < \infty\}$*

Teorema 2.6.1. *Sia $(\Omega, \mathscr{A}, p)$ uno spazio di probabilità.*
(i) L^P è uno spazio vettoriale per ogni $P \in (0,\infty)$
(ii) $L^q \subseteq L^P$ per ogni $0 < P < q < \infty$ (solo per spazi di misura finita)
(iii) Se $X \in L^2$ e $Y \in L^2$, allora $XY \in L^1$

Proof. (i) Sia $X \in L^P$ e $\alpha \in \mathbb{R}$, allora $E[|\alpha X|^P] = |\alpha| E[|X|^P] < \infty$, dunque $\alpha X \in L^P$. Siano ora $X, Y \in L^P$, allora $E[|X+Y|^P] \leqslant E[2^P(|X|^P + |Y|^P)] = 2^P(E[|X|^P] + E[|Y|^P]) < \infty$, in quanto $\forall x, y \in \mathbb{R}$ si ha $|x+y|^P \leqslant (|x|+|y|)^P \leqslant (2\max\{|x|,|y|\})^P = 2^P \max\{|x|^P, |y|^P\}$
(ii) Siano $0 < P < q < \infty$ e sia $X \in L^q$. Sappiamo che $|x|^P \leqslant \begin{cases} |x|^q, & |x| \geqslant 1 \\ 1, & |x| \leqslant 1 \end{cases} \leqslant$ $|x|^q + 1$, dunque $E[|X|^P] \leqslant E[|X|^q + 1] = E[|X|^q] + 1 < \infty$
(iii) Siano $x, y \in \mathbb{R}^2$, allora $(x \pm y)^2 = x^2 + y^2 \pm 2xy \geqslant 0$, cioè $\mp 2xy \leqslant x^2 + y^2$ e quindi $|xy| \leqslant \frac{1}{2}(x^2 + y^2)$. Quindi, $E[|XY|] \leqslant E[\frac{1}{2}(X^2 + Y^2)] = \frac{1}{2}(E[X^2] + E[Y^2]) < \infty$ □

Corollario 2.6.1.1. *Se $X, Y \in L^2$, allora $X, Y, XY \in L^1$ e quindi $Cov[X,Y]$ è ben definita.*

Teorema 2.6.2. *La covarianza come operatore $Cov : L^2 \times L^2 \to \mathbb{R}$ è simmetrica e bilineare. Inoltre, $Cov[X,Y] = 0$ se X è costante quasi-ovunque.*

Proof. La simmetria è ovvia.
Dato che $(\alpha X + \alpha' X')Y = \alpha XY + \alpha' X'Y$, segue $E[(\alpha X + \alpha' X')Y] = \alpha E[XY] + \alpha' E[X'Y]$ e quindi $E[\alpha X + \alpha' X']E[Y] = \alpha E[X]E[Y] + \alpha' E[X']E[Y]$.
Concludiamo che $Cov[\alpha X + \alpha' X', Y] = \alpha E[XY] + \alpha' E[X'Y] - \alpha E[X]E[Y] - \alpha' E[X']E[Y] = \alpha Cov[X,Y] + \alpha' Cov[X',Y]$
Sia $X = c$ quasi-ovunque, allora $E[X] = c$. Inoltre, $XY = cY$ quasi-ovunque, quindi $E[XY] = E[cY] = cE[Y] = E[X]E[Y]$, cioè $Cov(X,Y) = E[XY] - E[X]E[Y] = 0$ □

Teorema 2.6.3. *La varianza come operatore $Var : L^2 \to [0,\infty)$ non è lineare e $Var[\alpha X + \beta] = \alpha^2 Var[X]$. Inoltre, $Var[X] = 0$ se e solo se X è quasi-ovunque costante e $Var[\sum_{i=1}^{n} X_i] = \sum_{i=1}^{n} Var[X_i] + 2 \sum_{1 \leqslant i \leqslant j \leqslant n} Cov[X_i, X_j]$*

Proof. Sia $Y = \alpha X + \beta$, allora $E[Y] = \alpha E[X] + \beta$ e quindi $Y - E[Y] = \alpha(X - E[X])$, dunque $Var[Y] = E[(Y - E[Y])^2] = E[[\alpha(x - E[x])]^2] = \alpha^2 E[(X - E[X])^2] = \alpha^2 Var[X]$.
Sia $X = c$ quasi-ovunque, dato che $Cov[X, Y] = 0$ per ogni scelta di Y, vale anche per $Y = X$ $0 = Cov[X, X] = Var[X]$.
Sia $X \in L^2$ tale che $Var[X] = 0$, allora $0 = Var[X] = E[(X - E[X])^2] = E[R] = 0$, ma $R \geqslant 0$ quindi $R = 0$ quasi-ovunque ma $R = (X - E[X])^2$ e dunque $X - E[X] = 0$ quasi-ovunque.
Siano $X, Y \in L^2$, allora $Var[X + Y] = Cov[X + Y, X + Y] = Cov[X, X + Y] + Cov[Y, X + Y] = Cov[X, X] + Cov[X, Y] + Cov[Y, X] + Cov[Y, Y] = Var[X] + Var[Y] + 2Cov[X, Y]$ □

Mentre due variabili aleatorie reali in L^2 indipendenti sono scorrelate, non è sempre vero il viceversa.

Esempio 2.6.1 (Controesempio)**.** *Siano $W, M \in L^2$ variabili aleatorie IID e definiamo $X = W + M$ e $Y = W - M$. Allora $Cov[X, Y] = Var[W] - Var[M] = 0$ perché hanno la stessa distribuzione. Se prendiamo W e M gli esiti del lancio di due dadi, allora X e Y non sono indipendenti, in quanto $p(X = 12, Y = 1) = 0$, ma $p(X = 12) = \frac{1}{36}$ e $p(Y = 1) = \frac{5}{36}$*

Teorema 2.6.4. *X e Y sono indipendenti se e solo se $Cov[\phi(X), \psi(Y)] = 0$ per ogni scelta di ϕ, ψ misurabili e limitate.*

Esempio 2.6.2. *Sia $X = c$ quasi-ovunque, allora $E[X] = \int_\Omega c dp = c \int_\Omega 1 dp = cp(\Omega) = c$ e $Var[X] = E[(X - E[X])^2] = E[(X - c)^2] = E[0^2] = 0$*

Teorema 2.6.5. *Se X è una variabile aleatoria reale quasi-ovunque limitata, allora X è integrabile.*

Proof. $|E[X]| \leqslant E[|X|] \leqslant E[c]c < \infty$, dove $|X| \leqslant c$ quasi-ovunque. □

Teorema 2.6.6. *Sia X una variabile aleatoria reale estesa positiva. Allora,*
(i) $E[X] = \int_0^\infty p(X \geqslant t)dt = \int_0^\infty p(X > t)dt$
(ii) Se X è a valori in $\mathbb{N}$, $E[X] = \sum_{n=1}^{\infty} p(X \geqslant n) = \sum_{m=0}^{\infty} p(X > m)$

Proof. (i) Sia $x > 0$, allora $x = \int_0^x 1dt = \int_0^\infty \chi_{\{t \leqslant x\}} dt$, allora $E[X] = \int_\Omega X(\omega) p(d\omega) = \int_\Omega (\int_0^\infty \chi_{\{t \leqslant X(\omega)\}} dt) p(d\omega) = \int_0^\infty (\int_\Omega \chi_{\{t \leqslant X(\omega)\}} dp(\omega)) dt = \int_0^\infty p(X \geqslant t)dt$.
Sia $I = \{t \in \mathbb{R} \mid p(X \geqslant t) \neq p(X > t)\} = \{t \in \mathbb{R} \mid F_X$ è discontinua in

$t\} \iff p(X=t)>0 \iff F_X(t) \neq F_X(t^-)$, dunque I è al più di cardinalità numerabile e quindi $m(I)=0$, ovvero $\int_0^\infty p(X \geqslant t)dt = \int_0^\infty p(X>t)dt$
(ii) Dato che X è a valori in $\mathbb{N}$, si ha $p(X \geqslant t) = p(X \geqslant n)$ per ogni $n \in \mathbb{N}_0$ e per ogni $t \in (n-1, n]$. Applicando il punto precedente, si ha $E[X] = \int_0^\infty p(X \geqslant t)dt = \sum_{n=1}^{\infty} \int_{n-1}^{n} p(X \geqslant t)dt = \sum_{n=1}^{\infty} p(X \geqslant n) \int_{n-1}^{n} 1dt = \sum_{n=1}^{\infty} p(X \geqslant n)$. Facendo il cambio di variabili $n = m+1$, si ha $p(X \geqslant n) = p(X \geqslant m+1) = p(X > m)$. □

Teorema 2.6.7 (Assenza di memoria)**.** *La proprietà* $p(X > s+t) = p(X > s)p(X>t)\ \forall s,t \geqslant 0$ *caratterizza le variabili aleatorie esponenziali.*

Il nome deriva dalla seguente osservazione. Siano $p^{(s)}(A) = p(A|X>s)$ e $X^{(s)} = X - s$, allora la proprietà vale se e solo se $p^{(s)}(X^{(s)} > t) = p(X > t) \iff p^{(s)}(X^{(s)} \leqslant t) = p(X \leqslant t) \iff X^{(s)}$ ha la stessa legge di X rispetto a $p^{(s)}$. Dunque, la proprietà afferma che, fissato un tempo $s \geqslant 0$, l'informazione $X > s$ non cambia la distribuzione del tempo residuo $X^{(s)}$.

Esempio 2.6.3 (Strategia del raddoppio)**.** *Immaginiamo di entrare al casinò con* $1023 = 2^{10}-1$ *e puntare* 1 *euro sul rosso. Se esce rosso, ricevo* 2 *euro e mi ritiro. Altrimenti, punto* 2 *euro sul rosso, se esce ricevo* 4 *euro e mi ritiro e procedo così fino a un massimo di 10 volte. Sia* X *il guadagno (con segno) alla fine del gioco e calcoliamo* μ_X*. Sappiamo che* $X(\Omega) = \{-1023, 1\}$*, dunque* X *è discreta. Allora,* μ_X *è determinata dalla densità discreta* $p_X(-1023) = p(X=-1023) = p($*non esce mai rosso in* 10 *giri*$) = (\frac{19}{37})^{10} \approx 0.1\%$ *e* $p_X(1) = 1 - p_X(-1023) \approx 99.9\%$*. Dunque,* $E[X] = (-1023)p_X(-1023) + 1p_X(1) = 1 - 1024(\frac{19}{37})^{12} = 1 - (\frac{38}{37})^1 0 < 0$

Esempio 2.6.4. *Siano* $\alpha \in (0,\infty)$ *e* X *una variabile aleatoria a valori in* $\mathbb{N}_0$ *con* $p_X(k) = p(X=k) = \begin{cases} \frac{c}{k^{1+\alpha}},\ k \in \mathbb{N}_0 \\ 0,\ k \notin \mathbb{N}_0 \end{cases}$ *con* $c = (\sum_{k=1}^{\infty} \frac{1}{k^{1+\alpha}})^{-1}$*. Allora,*

$$E[X^P] = \sum_{x \in \mathbb{R}^+} x^P p_X(x) = \sum_{k=1}^{\infty} k^P \frac{c}{k^{1+\alpha}} \begin{cases} < \infty,\ p < \alpha \\ = \infty,\ p \geqslant \alpha \end{cases}$$

Quindi, $X \in L^P$ *per* $P \in (0,\alpha)$ *e* $X \notin L^P$ *per* $P \in [\alpha, \infty)$*. Dunque, per* $0 < P < q < \infty$ *esiste una variabile aleatoria* X *tale che* $X \in L^P \backslash L^q$
Scegliendo $\alpha \in (0,1]$*, si ha* $X \notin L^1$ *e* $X < \infty$ *quasi-ovunque, in quanto* $p(X < \infty) = p(X \in \mathbb{N}_0) = \sum_{k \in \mathbb{N}_0} p_X(k) = 1$

Esempio 2.6.5. *Una variabile aleatoria reale X si dice Cauchy (standard) se è assolutamente continua con $f_X(x) = \frac{1}{\pi}\frac{1}{1+x^2}$. Allora, X non ammette valore medio in quanto $E[X^+] = \int_{\mathbb{R}} x^+ d\mu_X(x) = \int_{\mathbb{R}} x^+ f_X(x)dx = \int_0^\infty \frac{x}{\pi(1+x^2)}dx = \infty$. Per simmetria, avviene anche per $E[X^-]$*

2.7 Disuguaglianze

Teorema 2.7.1 (Disuguaglianza di Markov)**.** *Sia X una variabile aleatoria estesa positiva, allora $p(X \geqslant t) \leqslant \frac{E[X]}{t}$*

Proof. Sia $t > 0$, allora $X \geqslant t\chi_{\{X \geqslant t\}}$ e quindi $X(\omega) \geqslant t\chi_{\{X\geqslant t\}}(\omega)$, dunque $E[X] \geqslant E[t\chi_{\{X\geqslant t\}}] = tp(X \geqslant t)$ □

Teorema 2.7.2 (Lemma)**.** *Sia X una variabile aleatoria estesa positiva (non-negativa), allora:*
(i) $E[X] = 0$ se e solo se $X = 0$ quasi-ovunque.
(ii) Se $E[X] < \infty$, allora $X < \infty$, quasi-ovunque.

Proof. (i) $(\Longrightarrow)$ $\{X > 0\} = \bigcup_{n\in\mathbb{N}_0} \{X \geqslant \frac{1}{n}\} \Longrightarrow p(X > 0) \leqslant \sum_{n\in\mathbb{N}_0} p(X \geqslant \frac{1}{n})$. Ma $p(X \geqslant t) \leqslant \frac{E[X]}{t} = 0$, dunque vale anche per $t = \frac{1}{n}$, ovvero $p(X > 0) = 0$. Dunque $p(X \leqslant 0) = 1$, ovvero $X \leqslant 0$ quasi-ovunque, ma per la positività si ha $X = 0$ quasi-ovunque.
(ii) $\{X = \infty\} \subseteq \{X \geqslant t\} < \infty \ \forall t > 0$, dunque $p(X = \infty) \leqslant p(X \geqslant t) \leqslant \frac{E[X]}{t} \to 0$ □

Definizione 2.7.1. *Il metodo dei momenti consiste nell'utilizzare informazioni sui momenti $E[|X|^P]$ di una variabile reale X per dedurre informazioni sulla distribuzione di X, cioè della probabilità $p(X \in A)$ con $A \in \mathscr{B}(\mathbb{R})$*
Nel caso $P = 1$, prende il nome di metodo del momento primo e si usa la disuguaglianza di Markov.

Esempio 2.7.1 (Mescolamento di carte d'identità)**.** *Si mescolino e redistribuiscano le carte d'identità di un gruppo di n persone, chiamiamo X_n il numero di persone che ricevono la propria carta d'identità. Allora, X_n è a valori in $\{0, ..., n\}$ e sappiamo che $p(X_n = 0) = \sum_{k=0}^n \frac{(-1)^k}{k!} \to e^{-1}$. Vogliamo valutare $E[X_n]$, definiamo A_i l'evento "la persona i riceve la propria carta d'identità, allora $p(A_i) = \frac{1}{n}$, dunque $X_n = \sum_{i=1}^n \chi_{A_i} \Longrightarrow E[X_n] =$*

$\sum_{i=1}^{n} E[\chi_{A_i}] = \sum_{i=1}^{n} p(A_i) = 1$. *Per la disuguaglianza di Markov, si ha che* $p(X_n \geqslant t) \leqslant \frac{E[X_n]}{t} = \frac{1}{t}$, *dunque* $\sup_{n\in\mathbb{N}_0} p(X_n \geqslant t) \leqslant \frac{1}{t}$

Esempio 2.7.2 (Collezionista di figurine)**.** *Consideriamo un album di* N *figurine, le acquisto una dopo l'altra e mi chiedo quante ne dovrò ancora acquistare per completare l'album, chiamiamo le figurine con i numeri associati* $\{1, ..., N\}$ *considerate equiprobabili. Dunque, stiamo considerando* X_i *variabili aleatorie IID* $Unif\{1, ..., N\}$ *con* $X_i = i-$*esima figurina acquistata. Definiamo* T_N *il numero di figurine necessarie per completare l'album, allora* T_N *è una variabile aleatoria a valori in* $\{N, ...\} \cup \{\infty\}$ *ed è* $T_N = \min\{n \in \mathbb{N}_0 \mid \bigcup_{i=1}^{n}\{X_i\} = \{1, ..., N\}\}$. *Fissiamo* $k \in \mathbb{N}_0$ *e sia* Y_k *il numero di figurine mancanti dopo aver acquistato* k *figurine, allora* $\{T_N > k\} = \{Y_k \geqslant 1\} \implies p(T_N > k) = p(Y_k \geqslant 1) \leqslant \frac{E[Y_k]}{1} = E[Y_k]$. *Detti* $A_i^{(k)}$ *="la figurina* i *non compare tra le prime* k *acquistate", si ha* $Y_k = \sum_{i=1}^{N} \chi_{A_i^{(k)}} \implies E[Y_k] = \sum_{i=1}^{N} E[\chi_{A_i^{(k)}}] = \sum_{i=1}^{N} p(A_i^{(k)}) = p(X_1 \neq i, ..., X_k \neq i) = p(X_1 \neq i)...p(X_k \neq i) = (\frac{N-1}{N})^k = (1 - \frac{1}{N})^k$, *dunque* $E[Y_k] = N(1 - \frac{1}{N})^k$. *Infine,* $p(T_N > k) \leqslant N(1 - \frac{1}{N})^k \leqslant Ne^{-\frac{k}{N}}$. *Sia* $k = (1 + \varepsilon)M \log N$ *con* $\varepsilon > 0$, *allora* $p(T_N > (1 + \varepsilon)N \log N) \leqslant Ne^{-(1+\varepsilon)\frac{N}{N}\log N} = \frac{1}{N^\varepsilon} \to 0$. *Dunque, con grande probabilità, è sufficiente acquistare* $(1 + \varepsilon)N \log N$ *figurine per completare l'album.*

Teorema 2.7.3 (Disuguaglianza di Chebychev)**.** *Sia* $X \in L^2$, *allora* $p(|X - E[X]| \geqslant \varepsilon) \leqslant \frac{Var[X]}{\varepsilon^2}$

Proof. Sia $Y = (X - E[X])^2 \geqslant 0$, allora $p(|X - E[X]| \geqslant \varepsilon) = p(|X - E[X]|^2 \geqslant \varepsilon^2) = p(Y \geqslant \varepsilon^2) \leqslant \frac{E[Y]}{\varepsilon^2} = \frac{E[(X-E[X])^2]}{\varepsilon^2} = \frac{Var[X]}{\varepsilon^2}$ □

Viene usata nel metodo del momento secondo.
Osserviamo che $p(|X - E[X]| < \varepsilon) \geqslant 1 - (\frac{\sigma}{\varepsilon})^2$. Sia $m = E[X]$, allora $p(|X-m| < \varepsilon) = p(X \in (m-\varepsilon, m+\varepsilon)) \geqslant 1-(\frac{\sigma}{\varepsilon})^2$. Siano $t \geqslant 0$ e $\varepsilon = t\sigma$, allora $p(X \in (m - t\sigma, m + t\sigma)) \geqslant 1 - \frac{1}{t^2}$, mostrando che qualitativamente σ fornisce una stima della dispersione. Ad esempi, per $t = 3$ i valori nell'intervallo $(m - 3\sigma, m + 3\sigma)$ vengono assunti con probabilità maggiore dell'89%.

Esempio 2.7.3 (Collezionista di figurine)**.** *Riprendiamo l'esempio precedente e mostriamo che per* $\varepsilon > 0$, $p((1 - \varepsilon)N \log N \leqslant T_N \leqslant (1 + \varepsilon)N \log N) \to 1$.

Osserviamo che $\{T_N \leqslant k\} = \{Y_k = 0\} = \{Y_k \leqslant 0\} \Longrightarrow p(T_N \leqslant k) = p(Y_k \leqslant 0) = p(Y_k - E[Y_k] \leqslant -E[Y_k]) \leqslant p(|Y_k - E[Y_k]| \geqslant E[Y_k]) \leqslant \frac{Var[Y_k]}{E[Y_k]^2}$, *dunque calcoliamo* $Var[Y_k]$. *Sapendo che* $Y_k = \sum_{i=1}^{N} \chi_{A_i^{(k)}} \Longrightarrow Var[Y_k] = \sum_{i=1}^{N} Var[\chi_{A_i^{(k)}}] + 2 \sum_{1 \leqslant i < j \leqslant N} Cov[\chi_{A_i^{(k)}}, \chi_{A_j^{(k)}}]$. *Affermo che* $Cov[\chi_{A_i^{(k)}}, \chi_{A_j^{(k)}}] \leqslant 0$, *allora posso dire* $Var[Y_k] \leqslant \sum_{i=1}^{N} Var[\chi_{A_i^{(k)}}]$, *ma* $\chi_{A_i^{(k)}} \sim Be(P)$ *con* $P = p(A_i^{(k)})$, *dunque* $Var[\chi_{A_i^{(k)}}] = P(1-P) \leqslant P = p(A_i^{(k)})$. *Infine,* $Var[Y_k] \leqslant \sum_{i=1}^{n} p(A_i^{(k)}) = \sum_{i=1}^{n} E[\chi_{A_i^{(k)}}] = E[Y_k]$, *dunque* $p(T_N \leqslant k) \leqslant \frac{Var[Y_k]}{E[Y_k]^2} \leqslant \frac{1}{E[Y_k]} \leqslant \frac{1}{N^\varepsilon} \to 0$. *Prendendo* $k = (1-\varepsilon)N \log N$, $E[Y_k] = (1 - \frac{1}{N})^k = (1 - \frac{1}{N})^{(1-\varepsilon)N \log N} \sim N^\varepsilon$.
Mostriamo che l'affermazione sulla covarianza è vera, $Cov[\chi_{A_i^{(k)}}, \chi_{A_j^{(k)}}] = E[\chi_{A_i^{(k)}} \chi_{A_j^{(k)}}]] - E[\chi_{A_i^{(k)}}] E[\chi A_j^{(k)}] = p(A_i^{(k)} \cap A_j^{(k)}) - p(A_i^{(k)}) p(A_j^{(k)})$, *dunque mostrando che* $p(A_i^{(k)} \cap A_j^{(k)}) \leqslant p(A_i^{(k)}) p(A_j^{(k)})$ *si ha l'asserto.*

Teorema 2.7.4 (Disuguaglianza di Jensen)**.** *Sia* X *una variabile aleatoria a valori in* (a,b) *e sia* $\phi : (a,b) \to \mathbb{R}$ *convessa. Se* $X \in L^1$, *allora* $\phi(X)$ *è semi-integrabile e* $\phi(E[X]) \leqslant E[\phi(X)]$.
Inoltre, se ϕ *è strettamente convessa e* X *non è quasi-ovunque costante, allora* $\phi(E[X]) < E[\phi(X)]$

Proof. Sia $x_0 = E[X]$ e sia $\lambda = \lambda(x_0)$, allora usiamo la definizione di convessità $\phi(x) \geqslant \lambda(x - E[X]) + \phi(E[X])$. Pongo $x = X(\omega)$, allora $\phi(X) \geqslant \lambda(X - E[X]) + \phi(E[X])$ e per monotonia $E[\phi(X)] \geqslant E[\lambda(X - E[X])] + E[\phi(E[X])] = \lambda(E[X] - E[X]) + \phi(E[X])$ □

Corollario 2.7.4.1. *Siano* $0 < P < q < \infty$, *allora per ogni variabile aleatoria reale* X *si ha* $E[|X|^P]^{\frac{1}{P}} \leqslant E[|X|^q]^{\frac{1}{q}}$

Proof. Usiamo il teorema con la funzione convessa $\phi(x) = |x|^{\frac{q}{P}}$ □

Teorema 2.7.5 (Disuguaglianza di Cauchy-Schwarz)**.** *Siano* $X, Y \in L^2$, *allora* $|E[XY]| \leqslant \sqrt{E[X^2]E[Y^2]}$. *Inoltre, vale l'uguaglianza se e solo se* X *e* Y *sono proporzionali nel senso che* $Y = cX$ *quasi-ovunque per* $c \in \mathbb{R}$

Proof. Se $X = 0$ o $Y = 0$ quasi-ovunque, allora è immediato perché $XY = 0$ quasi-ovunque ed è un'uguaglianza. Assumiamo WLOG che $p(X = 0), p(Y = 0) < 1$, allora $E[X^2] > 0$ e $E[Y^2] > 0$ e definiamo $X_* = \frac{X}{\sqrt{E[X^2]}}$ e $Y_* = \frac{Y}{\sqrt{E[Y^2]}}$. Osserviamo che $(X_* \pm Y_*)^2 \geqslant 0$, cioè $\mp X_* Y_* \leqslant \frac{X_*^2+Y_*^2}{2} \implies |X_* Y_*| \leqslant \frac{X_*^2+Y_*^2}{2}$. Dunque, $E[|X_* Y_*|] \leqslant \frac{1}{2}(E[X_*^2] + E[Y_*^2]) = 1$ e $\frac{E[|XY|]}{\sqrt{E[X^2]}\sqrt{E[Y^2]}} \leqslant 1$; cioè. $|E[XY]| \leqslant E[|XY|] \leqslant \sqrt{E[X^2]}\sqrt{E[Y^2]}$. Infine, $|E[XY]| = \sqrt{E[X^2]}\sqrt{E[Y^2]} \iff (X_* \pm Y_*)^2 = 0$ quasi-ovunque $\iff X_* = \mp Y_*$ quasi-ovunque $\iff X = cY$ quasi-ovunque con $c = \frac{\sqrt{E[X^2]}}{\sqrt{E[Y^2]}}$ □

Corollario 2.7.5.1. *Siano $X, Y \in L^2$, allora la loro covarianza è ben definita e $|Cov[X, Y]| \leqslant \sqrt{Var[X]Var[Y]}$. Inoltre, assumendo $Var[X] \neq 0$, vale l'uguaglianza se e solo se $Y = aX + b$, dove $a, b \in \mathbb{R}$ e a ha lo stesso segno di $Cov[X, Y]$*

Proof. Si tratta di applicare Cauchy-Schwarz su $X' = X - E[X]$ e $Y' = Y - E[Y]$.
($\implies$) Per Cauchy-Schwarz, si ha che $Y - E[Y] = Y' = cX' = cX - cE[X] \iff Y = cX - cE[X] + E[Y]$ quasi-ovunque.
($\impliedby$) Se $Y = aX + b$ quasi-ovunque, allora $Cov[X, Y] = Cov[X, aX + b] = aCov[X, X] + Cov[X, b] = aVar[X]$ □

Definizione 2.7.2. *Siano $X, Y \in L^2$ con $Var[X], Var[Y] \neq 0$. Si definisce il coefficiente di correlazione lineare $\rho[X, Y] = \frac{Cov[X,Y]}{\sigma[X]\sigma[Y]} = \frac{Cov[X,Y]}{\sqrt{Var[X]Var[Y]}}$*

Corollario 2.7.5.2. *Siano $X, Y \in L^2$ con $Var[X], Var[Y] \neq 0$, allora $|\rho[X, Y]| \leqslant 1$. Inoltre, $\rho[X, Y] = 1 \iff \exists a > 0, b \in \mathbb{R}$ tali che $Y = aX + b$. Analogamente il caso negativo con $a < 0$.*

2.8 Variabili Aleatorie Notevoli

2.8.1 Variabili aleatorie ricorrenti

Esempio 2.8.1 (Uniforme discreta)**.** *Sia $D \subset \mathbb{R}$ (o $\mathbb{R}^d$) con $0 < |D| < \infty$. Allora X è uniforme discreta in D, e scriveremo $X \sim Unif(D)$ se e solo se $X(\Omega) = D, p_X(x) = \frac{1}{|D|}\chi_D(x)$*

Teorema 2.8.1 (Potenziale follia?)**.** *Sia X è una v.a. assolutamente continua su $\mathbb{R}^d$, allora $X \sim U((a, b])$*

Proof. $p(X \in (a,b)) = p(X \in [a,b]) = p(x \in [a,b)) \implies X \sim U((a,b)) \iff X \sim U([a,b]) \iff X \sim U([a,b)) \iff X \sim U((a,b])$ □

Esempio 2.8.2 (Quasi-ovunque Costante)**.** *Sia $c \in \mathbb{R}$ (o $\mathbb{R}^d$). Allora X è quasi-ovunque costante, e scriveremo $X = c$ q.o., se e solo se $X(\Omega) = \{c\}$ e $p_X(x) = \chi_{\{c\}}(x)$*

Esempio 2.8.3 (Bernoulli)**.** *Sia $p \in [0,1]$. Allora X è Bernoulli di parametro P, e scriveremo $X \sim Be(P)$, se e solo se $X(\Omega) = \{0,1\}$ e $p_X(k) = P^k(1-P)^{1-k}$*

Si ha inoltre che X è discreta con distribuzione discreta $p_X(x) = \begin{cases} P, \ x = 1 \\ 1-P, \ x = 0 \\ 0, \ \textit{altrimenti} \end{cases}$

Dunque, $E[X] = \sum\limits_{x \in \mathbb{R}} x p_X(x) = 0p_X(0) + 1p_X(1) = P$, $E[X^2] = \sum_{x \in \mathbb{R}} x^2 p_X(x) = 0^2 p_X(0) + 1^2 p_X(1) = P$ *e* $Var[X] = E[X^2] - E[X]^2 = P - P^2 = P(1-P)$

Esempio 2.8.4 (Binomiale)**.** *Siano $n \in \mathbb{N}_0$ e $P \in [0,1]$. Allora X è binomiale di parametri n e P, e scriveremo $X \sim Bin(n,P)$ se e solo se $X(\Omega) = \{0,...,n\}$ e* $p_X(k) = \begin{cases} \binom{n}{k} P^k (1-P)^{n-k}, \ k \in \{0,...n\} \\ 0, \ \textit{altrimenti} \end{cases}$

Inoltre, $E[X] = \sum\limits_{x \in \mathbb{R}} x p_X(x) = \sum\limits_{k=0}^{n} k \binom{n}{k} P^k (1-P)^{n-k} = nP$ *e* $Var[X] = \sum\limits_{k=0}^{n} k^2 \binom{n}{k} P^k (1-P)^{n-k} - (nP)^2 = nP(1-P)$

Esempio 2.8.5 (Geometrica)**.** *Sia $P \in (0,1]$. Allora, X è geometrica di parametro P, e scriveremo $X \sim Geo(P)$, se e solo se $X(\Omega) = \mathbb{N}_0$ e* $p_X(k) = \begin{cases} P(1-P)^{k-1}, \ k \in \mathbb{N}_0 \\ 0, \ \textit{altrimenti} \end{cases}$

Dato che $p(X > m) = \sum\limits_{k=m+1}^{\infty} p(X = k) = \sum\limits_{k=m+1}^{\infty} P(1-P)^{k-1} = \sum\limits_{n=m}^{\infty} P(1-P)^n = P(1-P)^m \sum\limits_{n=m}^{\infty} (1-P)^{n-m} = P(1-P)^m \sum\limits_{l=0}^{\infty} (1-P)^l = P(1-P)^m \frac{1}{1-(1-P)} = (1-P)^m$, *otteniamo che* $E[X] = \sum\limits_{m=0}^{\infty} p(X > m) = \sum\limits_{m=0}^{\infty} (1-P)^m = \frac{1}{1-(1-P)} = \frac{1}{P}$

In alternativa, $E[X] = \int_{\mathbb{R}} x d\mu_X(x) = \sum_{x\in\mathbb{R}} x p_X(x) = \sum_{k=1}^{\infty} kP(1-P)^{k-1} =$
$P\sum_{k=1}^{\infty} -\frac{d}{dP}(1-P)^k = P(-\frac{d}{dP}\sum_{k=0}^{\infty}(1-P)^k) = P(-\frac{d}{dP}(\frac{1}{P})) = \frac{1}{P}$

Esempio 2.8.6 (Poisson)**.** *Sia* $\lambda \in (0,\infty)$*. Allora,* X *è Poisson di parametro* λ*, e scriveremo* $X \sim Pois(\lambda)$*, se e solo se* $X(\Omega) = \mathbb{N}$ *e* $p_X(k) = \begin{cases} e^{-\lambda}\frac{\lambda^k}{k!}, & k \in \mathbb{N} \\ 0, & altrimenti \end{cases}$

2.8.2 Variabili aleatorie assolutamente continue

Esempio 2.8.7. *Sia* $D \subseteq \mathbb{R}$ *(o* $\mathbb{R}^d$*) con* $0 < m(D) < \infty$*, allora* X *è uniforme continua in* D*, e scriveremo* $X \sim U(D)$*, se e solo se* $X(\Omega) = D$ *e* $f_X(x) = \frac{1}{m(D)}\chi_D(x)$
Se $D = (a,b)$*, allora* X *è uniforme in* D *se e solo se lo è in* $[a,b]$ *o* $[a,b)$ *o* $(a,b]$

Esempio 2.8.8. *Sia* $\lambda \in (0,\infty)$*, allora* X *è esponenziale di parametro* λ*, e scriveremo* $X \sim Exp(\lambda)$*, se e solo se* $X(\Omega)$ *e* $f_X(x) = \lambda e^{-\lambda x}\chi_{[0,\infty)}(x)$
Si ha che $F_X(x) = 0$ *per* x *non-positive, alternativamente si ha* $F_X(x) = p(X \leqslant x) = \int_{(-\infty,x]} f_X(t)dt = \int_0^x \lambda e^{-\lambda t}dt = [-e^{-\lambda t}]_0^x = 1 - e^{-\lambda x}$*. Invece,* $p(X > x) = 1 - F_X(x)$

Definizione 2.8.1. *La funzione Gamma di Eulero è* $\Gamma : (0,\infty) \to (0,\infty)$ *tale che* $\Gamma(\alpha) = \int_0^\infty x^{\alpha-1}e^{-x}dx$

Studiamone delle proprietà.
$\Gamma(\alpha+1) = \int_0^\infty x^{\alpha+1-1}e^{-x}dx = [-x^\alpha e^{-x}]_0^\infty + \int_0^\infty \alpha x^{\alpha-1}e^{-x}dx = 0 + \alpha\Gamma(\alpha)$
$\Gamma(1) = \int_0^\infty e^{-x}dx = [-e^{-x}]_0^\infty = 1$, dunque $\Gamma(n+1) = n!$ per ogni $n \in \mathbb{N}$

Esempio 2.8.9. *Siano* $\alpha, \lambda \in (0,\infty)$*, allora* X *è gamma di parametro* α *e* λ*, e scriveremo* $X \sim Gamma(\alpha,\lambda)$*, se e solo se* $X(\Omega) = (0,\infty)$ *e* $f_X(x) = \frac{\lambda^\alpha x^{\alpha-1}e^{-\lambda x}}{\Gamma(\alpha)}\chi_{(0,\infty)}(x)$
Notiamo infatti che $\int_{\mathbb{R}} f_X(x)dx = \int_0^\infty \frac{\lambda^\alpha x^{\alpha-1}e^{-\lambda x}}{\Gamma(\alpha)}dx = \frac{\lambda^\alpha}{\Gamma(\alpha)}\int_0^\infty x^{\alpha-1}e^{-\lambda x}dx =$
$\frac{\lambda^\alpha}{\Gamma(\alpha)}\int_0^\infty \frac{t^{\alpha-1}}{\lambda^{\alpha-1}}e^{-t}\frac{1}{\lambda}dt = \frac{1}{\Gamma(\alpha)}\int_0^\infty t^{\alpha-1}e^{-t}dt = 1$

Teorema 2.8.2. *Siano* $\alpha, \beta, \lambda \in (0,\infty)$*,* $X \sim Gamma(\alpha,\lambda)$ *e* $Y \sim Gamma(\beta,\lambda)$ *variabili aleatorie indipendenti. Allora,* $S = X + Y \sim Gamma(\alpha+\beta,\lambda)$

Proof. Sappiamo che S è assolutamente continua con densità $f_S(s) = (f_X * f_Y)(s)$, dobbiamo mostrare che coincide con $\frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha+\beta)} s^{\alpha+\beta-1} e^{-\lambda s} \chi_{(0,\infty)}(s)$. Dato che $f_S(s) = 0$ per $s < 0$, dunque supponiamo $s > 0$ e quindi dobbiamo richiedere $x > 0$ e $s - x > 0$, ovvero $0 < x < s$. Allora, $f_S(s) = \int_0^s \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \frac{\lambda^\beta}{\Gamma(\beta)} (s-x)^{\beta-1} e^{-\lambda(s-x)} dx = \frac{\lambda^{\alpha+\beta} e^{-\lambda s}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^s x^{\alpha-1}(s-x)^{\beta-1} dx = \frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha)\Gamma(\beta)} (\int_0^1 t^{\alpha-1}(1-t)^{\beta-1} dt) s^{\alpha+\beta-1} e^{-\lambda s} \chi_{(0,\infty)}(s) = C s^{\alpha+\beta-1} e^{-\lambda s} \chi_{(0,\infty)}(s)$. Sappiamo che la densità di $Gamma(\alpha+\beta, \lambda)$ è la funzione $g(s) = C' s^{\alpha+\beta-1} e^{-\lambda s} \chi_{(0,\infty)}(s)$, dunque deve essere $C = C'$ poiché $C' \int_0^\infty s^{\alpha+\beta-1} e^{-\lambda s} ds = \int_{\mathbb{R}} g(s) ds = 1 = \int_{\mathbb{R}} = C \int_0^\infty s^{\alpha+\beta-1} e^{-\lambda s} ds$ □

Corollario 2.8.2.1. $B(\alpha, \beta) = \int_0^1 t^{\alpha-1}(1-t)^{\beta-1} dt = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$

Corollario 2.8.2.2. *Siano X e Y variabili aleatorie indipendenti entrambe $Exp(\lambda)$. Allora, $S \sim Gamma(2, \lambda)$. Si può estendere a n variabili aleatorie indipendenti.*

Proof. Deriva dal fatto che $X \sim Gamma(1, \lambda)$ è identico a $X \sim Exp(\lambda)$ □

Teorema 2.8.3. *Siano $X \sim Exp(\lambda)$ e $Y \sim Exp(\mu)$ variabili aleatorie indipendenti. Allora, $W = \min\{X, Y\} \sim Exp(\lambda + \mu)$*

Proof. Sappiamo che $1 - F_W(t) = (1 - F_X(t))(1 - F_Y(t))$ e che $X \sim Exp(t) \iff 1 - F_X(t) = \begin{cases} e^{-\lambda t}, & t \geqslant 0 \\ 1, & t < 0 \end{cases}$. Da ciò, segue che $1 - F_W(t) = \begin{cases} e^{-(\lambda+\mu)t}, & t \geqslant 0 \\ 1, & t < 0 \end{cases}$ □

2.8.3 Variabili aleatorie normali

Definizione 2.8.2. *Una variabile aleatoria reale Z si dice normale standard se è assolutamente continua con densità $f_Z(z) = \frac{e^{-\frac{z^2}{2}}}{\sqrt{2\pi}}$. Scriveremo $Z \sim N(0, 1)$*

Osserviamo che:
$E[Z] = \int_{\mathbb{R}} z f_Z(z) dz = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z e^{-\frac{z^2}{2}} dz = 0$
$E[Z^2] = \int_{\mathbb{R}} z^2 f_Z(z) dz = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z z e^{-\frac{z^2}{2}} dz = 0 + \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{z^2}{2}} dz = 1$
$Var[Z] = E[Z^2] - E[Z]^2 = 1$

Definizione 2.8.3. *Una variabile aleatoria con la distribuzione $X = \mu + \sigma Z$, dove $\mu \in \mathbb{R}, \sigma \in [0, \infty)$ e $Z \sim N(0, 1)$, è detta normale di media μ e varianza σ^2. Scriveremo $X \sim N(\mu, \sigma^2)$*

Notiamo che effettivamente $E[X] = \mu + \sigma E[Z] = \mu$ e $Var[X] = \sigma^2 Var[Z] = \sigma^2$

Notiamo che se $\sigma = 0$, allora $X = \mu$ quasi-ovunque, altrimenti X è assolutamente continua con densità $f_X(x) = \frac{1}{\sigma} f_Z(\frac{x-\mu}{\sigma}) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

Teorema 2.8.4. *Siano $X \sim N(\mu, \sigma^2)$ e $a, b \in \mathbb{R}$, allora $Y = aX + b$ è normale e $Y \sim N(a\mu + b, a^2\sigma^2)$*

Proof. $X \sim N(\mu, \sigma^2) \Longrightarrow X = \sigma Z + \mu$, con $Z \sim N(0, 1)$, dunque $aX + b = a(\sigma Z + \mu) + b = a\sigma Z + a\mu + b \Longrightarrow aX + b \sim N(a\mu + b, (a\sigma)^2)$ □

Teorema 2.8.5. *Siano $X \sim N(\mu_1, \sigma_1^2)$ e $Y \sim N(\mu_2, \sigma_2^2)$ variabili aleatorie indipendenti, allora $S = X + Y$ è normale e $S \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$*

Proof. Se $\sigma_1 = 0$ oppure $\sigma_2 = 0$, deriva dalla precedente proposizione. Assumiamo WLOG che $\sigma_1, \sigma_2 > 0$ e $\mu_1 = \mu_2 = 0$, infatti nel caso generale basta scrivere $S = X + Y = \mu_1 + \mu_2 + (X - \mu_1) + (Y - \mu_2) = \mu_1 + \mu_2 + X' + Y'$, ma $X' \sim N(0, \sigma_1^2)$ e $Y' \sim N(0, \sigma_2^2)$ per la proposizione precedente e si ha $X' + Y'$ normale implica $X + Y = \mu_1 + \mu_2 + (X' + Y')$ normale.
Supponiamo ora che $S = X + Y$ è assolutamente continua con $f_S(s) = (f_X * f_Y)(s) = \int_{\mathbb{R}} f_X(x) f_Y(s - x) dx = \frac{1}{\sqrt{2\pi\sigma_1^2}} \frac{1}{\sqrt{2\pi\sigma_2^2}} \int_{-\infty}^{\infty} e^{-\frac{x^2}{2\sigma_1^2}} e^{-\frac{(s-x)^2}{2\sigma_2^2}} dx$ Unendo gli esponenziali, si ottiene che $f_S(s) = \int_{-\infty}^{\infty} e^{-\frac{(x-\xi s)^2}{2\hat{\sigma}^2} - \frac{s^2}{2(\sigma_1^2+\sigma_2^2)}}$, dove $\xi = \frac{\sigma_1^2}{\sigma_1^2+\sigma_2^2}$ e $\hat{\sigma}^2 = (\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2})^{-1} = \frac{\sigma_1\sigma_2}{\sqrt{\sigma_1^2+\sigma_2^2}}$ Quindi, $f_S(s) = \frac{e^{-\frac{s^2}{2(\sigma_1^2+\sigma_2^2)}}}{\sqrt{2\pi\sigma_1^2}\sqrt{2\pi\sigma_2^2}} \int_{-\infty}^{\infty} e^{-\frac{(x-\xi s)^2}{2\hat{\sigma}^2}} dx = \frac{e^{-\frac{s^2}{2(\sigma_1^2+\sigma_2^2)}}}{\sqrt{2\pi\sigma_1^2}\sqrt{2\pi\sigma_2^2}} \sqrt{2\pi\hat{\sigma}^2} \int_{-\infty}^{\infty} \frac{e^{-\frac{z^2}{2\hat{\sigma}^2}}}{\sqrt{2\pi\hat{\sigma}^2}} = \frac{e^{-\frac{s^2}{2(\sigma_1^2+\sigma_2^2)}}}{\sqrt{2\pi\frac{\sigma_1^2\sigma_2^2}{\hat{\sigma}^2}}}$, che è la densità di $N(0, \sigma_1^2+\sigma_2^2)$ □

Corollario 2.8.5.1. *La combinazione lineare di n variabili aleatori normali indipendenti è normale.*

2.9 Prove Ripetute Indipendenti

Riprendendo la descrizione delle prove ripetute indipendenti, sia $\{C_i\}_{i\in\mathbb{N}}$ una famiglia di eventi indipendenti tali che $p(C_i) = c$. Possiamo descrivere la stessa situazione usando variabili aleatorie $\{X_i\}_{i\in\mathbb{N}}$ definite da $X_i = \chi_{C_i}$. E' naturale assumere che $\{X_i\}_{i\in\mathbb{N}}$ siano indipendenti e identicamente distribuite (IID) tali che $X_i \sim Be(P)\ \forall i \in \mathbb{N}$

Definizione 2.9.1. *Si chiama processo stocastico di Bernoulli di parametro* $P \in [0,1]$ *un insieme di variabili aleatorie definite sullo stesso spazio di probabilità e a valori nello stesso spazio misurabile* $\{X_i\}_{i\in\mathbb{N}}$ *di variabili aleatorie IID tali che* $X_i \sim Be(P)\ \forall i \in \mathbb{N}$

Teorema 2.9.1. *Siano* $\{X_i\}_{i\in\mathbb{N}_0}$ *variabili aleatorie IID tali per cui* $X_i \sim Be(P)\ \forall i \in \mathbb{N}_0$
(i) Detto $T : \Omega \to \mathbb{N}_0 \cup \{\infty\}$ *l'istante del primo successo* $T(\omega) = \min\{i \in \mathbb{N}_0 \mid X_i(\omega) = 1\}$, *allora* $T \sim Geo(P)$
(ii) Detto S_n *il numero di successi nelle prime* n *prove* $S_n(\omega) = |\{i \in \{1,...,n\} \mid X_i(\omega) = 1\}| = \sum_{i=1}^{n} X_i(\omega)$, *allora* $S_n \sim Bin(n,P)$

Proof. (i) Sia $k \in \mathbb{N}_0$, allora $p(T=k) = p(X_1 = 0,...,X_{k-1} = 0, X_k = 1) = p(X_1 = 0)...p(X_{k-1} = 0)p(X_k = 1) = (1-P)...(1-P)P = P(1-P)^{k-1}$ e $p(T = \infty) = 1 - p(T \neq \infty) = 1 - p(T \in \mathbb{N}_0) = 1 - \sum_{k\in\mathbb{N}_0} p(T = k) = 1 - \sum_{k\in\mathbb{N}_0} P(1-P)^{k-1} = 1 - 1 = 0$
(ii) Notiamo preliminarmente che, dato che $X_i \in \{0,1\}$, l'evento $\{S_n = k\}$ coincide con $\{S_n = k\} = \bigcup_{I\subseteq\{1,...,k\},|I|=k} A_I$, dove $A_I = \{X_i = 1\ \forall i \in I, X_j = 0\ \forall j \in I^c\} = \bigcap_{i\in I}\{X_i = 1\} \cap \bigcap_{j\in I^c}\{X_j = 0\}$. Osserviamo anche che $A_I \cap A_{I'} = \varnothing\ \forall I \neq I'$, dunque $p(S_n = k) = \sum_{I\subseteq\{1,...,n\},|I|=k} p(A_I) = \sum_{I\subseteq\{1,...,n\},|I|=k} \prod_{i\in I} p(X_i = 1) \prod_{j\in I^c} p(X_j = 0) = P^{|I|}(1-P)^{|I^c|} = P^k(1-P)^{n-k} = \binom{n}{k}P^k(1-P)^{n-k}$ □

Teorema 2.9.2. *Fissiamo* $m,n \in \mathbb{N}_0$ *e* $P \in [0,1]$ *e siano* $S \sim Bin(n,P)$ *e* $T \sim Bin(m,P)$ *variabili aleatorie indipendenti. Allora,* $S + T \sim Bin(n+m,P)$

Proof. Siano $X_1,...,X_{n+m}$ variabili aleatorie IID Bernoulli di parametro P, definiamo $S' = X_1 + ... + X_n$ e $T' = X_{n+1} + ... + X_{n+m}$. Allora, per il teorema precedente si ha $S' \sim Bin(n,P)$ e $T' \sim Bin(m,P)$ e sono indipendenti, dunque per il teorema precedente $S' + T' \sim Bin(n+m,P)$. Vogliamo ora mostrare che ha la stessa distribuzione di $S+T$. Iniziamo notando che S ha la stessa distribuzione di S' ($Bin(n,P)$) e T ha la stessa distribuzione di T' ($Bin(m,P)$) e che, per costruzione, S e T sono indipendenti. Da ciò segue che (S,T) ha la stessa distribuzione congiunta del vettore (S',T') in quanto $\mu_{(S,T)} = \mu_S \otimes \mu_T = \mu_{S'} \otimes \mu_{T'} = \mu_{(S',T')}$. Infine, per conservazione della legge,

$\phi(S,T)$ ha la stessa distribuzione di $\phi(S',T')$, quale sia la funzione misurabile $\phi : \mathbb{R}^2 \to \mathbb{R}$ e scegliendo $\phi(x,y) = x + y$ si ha la tesi. □

Teorema 2.9.3. *Siano $\lambda, \tau \in (0,\infty)$, $X \sim Pois(\lambda)$ e $Y \sim Pois(\tau)$ variabili aleatorie indipendenti. Allora, $S = X + Y \sim Pois(\lambda + \tau)$*

Proof. Per ipotesi, $p(X = k) = e^{-\lambda}\frac{\lambda^k}{k!}\chi_{\mathbb{N}}(k)$ e $p(Y = r) = e^{-\tau}\frac{\tau^r}{r!}\chi_{\mathbb{N}}(r)$ e $X(\Omega) = \mathbb{N} = Y(\Omega)$, allora $S(\Omega) = \mathbb{N}$ e dunque $p(S = l) = 0\ \forall l \notin \mathbb{N}$. Calcoliamola negli altri casi, $p(S = l) = p(X + Y = l) = \sum_{k=0}^{l} p(X = k, Y = l - k) = \sum_{k=0}^{l} p(X = k)p(Y = l-k) = \sum_{k=0}^{l} e^{-\lambda}\frac{\lambda^k}{k!}e^{-\tau}\frac{\tau^{l-k}}{(l-k)!} = e^{-(\lambda+\tau)}\frac{1}{l!}\sum_{k=0}^{l}\binom{l}{k}\lambda^k\tau^{l-k}\frac{(\lambda+\tau)^l}{(\lambda+\tau)^l} = e^{-(\lambda+\tau)}\frac{(\lambda+\tau)^l}{l!}\sum_{k=0}^{l}\binom{l}{k}P^k(1-P)^{l-k} = e^{-(\lambda+\tau)}\frac{(\lambda+\tau)^l}{l!}$ □

Teorema 2.9.4 (Legge dei Piccoli Numeri)**.** *Siano $\lambda \in (0,\infty)$ e $\{p_n\}_{n\in\mathbb{N}_0}$ tali che $0 \leqslant p_n \leqslant 1$ e $p_n \sim \frac{\lambda}{n}$. Siano inoltre $S_n \sim Bin(n, p_n)$ e $S \sim Pois(\lambda)$, allora S_n converge a S in distribuzione nel senso che $p(S_n = k) \to p(S = k)$*

2.10 Costruzione e simulazione di variabili aleatorie indipendenti

Teorema 2.10.1. *Sia I un insieme non vuoto, per ogni $i \in I$ siano $(E_i, \mathscr{E}_i)$ spazi misurabili e μ_i probabilità su $(E_i, \mathscr{E}_i)$. Allora, sullo spazio prodotto esiste ed è unica la probabilità μ tale che $\mu(A_1 \times ... \times A_d \times E_{d+1} \times ...) = \mu_1(A_1)...\mu_d(A_d)$*

Teorema 2.10.2. *Sia I un insieme non vuoto, per ogni $i \in I$ siano $(E_i, \mathscr{E}_i)$ spazi misurabili e μ_i probabilità su $(E_i, \mathscr{E}_i)$. Allora, esiste uno spazio di probabilità $(\Omega, \mathscr{A}, p)$ su cui sono definite $X_i : (\Omega, \mathscr{A}, p) \to (E_i, \mathscr{E}_i)$ tali che $\{X_i\}_{i\in I}$ sono variabili aleatorie indipendenti e X_i ha legge μ_i per ogni $i \in I$.*

Proof. Sia $I = \{1\}$, allora uso la costruzione canonica scegliendo $(\Omega, \mathscr{A}, p) = (E_1, \mathscr{E}_1, \mu_1)$ e definiamo X_1 l'identità. Allora, $\mu_{X_1}(B) = p(X_1 \in B) = p(X_1^{-1}(B)) = \mu_1(B)$
Sia $I = \{1, ..., d\}$, allora dobbiamo costruire un vettore aleatorio $X = (X_1, ..., X_d)$ a valori in $(E_1 \times ... \times E_d, \mathscr{E}_1 \otimes ... \otimes \mathscr{E}_d)$ con distribuzione (congiunta) $\mu_X = \mu = \mu_1 \otimes ... \mu_d$, quindi ci riconduciamo al caso precedente e proseguiamo analogamente.

Sia I un insieme infinito, prendiamo WLOG $I = \mathbb{N}_0$, vogliamo costruire $X = \{X_i\}_{i\in\mathbb{N}_0}$ di variabili aleatorie indipendenti a valori nei rispettivi spazi misurabili. Consideriamo $\Omega = \bigtimes_{i\in\mathbb{N}_0} E_i = \{x \in \{x_i\}_{i\in\mathbb{N}_0} \mid x_i \in E_i\}$ e prendiamo $\mathscr{A} = \bigotimes_{i\in\mathbb{N}_0} \mathscr{E}_i$, definita come la più piccola σ-algebra su Ω che contiene $\mathscr{C}$ cilindrici definiti come $\mathscr{C} = \{C = \bigtimes_{i=1}^{d} A_i \times \bigtimes_{j=d+1}^{\infty} E_j\}$. Dunque, $\{X_i\}_{i\in\mathbb{N}_0}$ sono indipendenti se e solo se per ogni scelta di C si ha $p(X \in C) = p(X_1 \in A_1, ..., X_d \in A_d) = p(X_1 \in A_1)...p(X_d \in A_d) = \mu_1(A_1)...\mu_d(A_d)$ se e solo se la legge μ_X dell'intera successione è una probabilità μ su $(\Omega, \mathscr{A})$ tale che $\mu(A_1 \times ... \times A_d \times E_{d+1} \times ...) = \mu_1(A_1)...\mu_d(A_d)$, che sappiamo esistere per il precedente teorema. Dunque, applichiamo la costruzione canonica. □

Definizione 2.10.1. *Sia $F : \mathbb{R} \to [0,1]$ una funzione con le proprietà delle funzioni di ripartizione (crescente, continua da destra e che vale 0 a meno infinito e 1 a infinito), si definisce pseudo-inversa sinistra di F la funzione $q_F : (0,1) \to \mathbb{R}$ ponendo $q_F(y) = \sup\{z \in \mathbb{R} \mid F(z) < y\} = \inf\{z \in \mathbb{R} \mid F(z) \geqslant y\}$*

Teorema 2.10.3 (Lemma)**.** *Per ogni $x \in \mathbb{R}$ e $y \in (0,1)$ si ha $q_F(y) \leqslant x \iff F(x) \geqslant y$*

Proof. ($\Longleftarrow$) Detto $I(y) = \{z \in \mathbb{R} \mid F(z) \geqslant y\}$, deve essere $x \in I(y)$ e dunque $x \geqslant \inf I(y) = q_F(y)$
($\Longrightarrow$) Sia $F(x) < y$, allora esiste $\varepsilon > 0 \mid F(x+\varepsilon) < y$ (continuità da destra) e dunque $F(z) < y \ \forall z \leqslant x + \varepsilon$ implica $x + \varepsilon \leqslant \inf I(y) = q_F(y)$ e dunque $x < q_F(y)$ □

Teorema 2.10.4. *Ogni funzione $F : \mathbb{R} \to [0,1]$ del tipo descritto sopra è la funzione di ripartizione di una variabile aleatoria reale. Sia $U \sim U(0,1)$ e sia q_F la pseudo-inversa sinistra di F, allora la variabile aleatoria $X = q_F(U)$ ha funzione di ripartizione F tale che $F_X(x) = p(X \leqslant x) = F(x) \ \forall x \in \mathbb{R}$*

Proof. Sappiamo che $q_F(y) \leqslant x \iff y \leqslant F(x) \ \forall x \in \mathbb{R}, \forall y \in (0,1)$. Scelgo $y = U$, allora $F_X(x) = p(X \leqslant x) = p(q_F(U) \leqslant x) = p(U \leqslant F(x))$. Ma $U \sim U(0,1)$, quindi $p(U \leqslant \alpha) = \alpha \ \forall \alpha \in [0,1]$, ponendo $\alpha = F(x)$ ottengo la tesi. □

Corollario 2.10.4.1. *La costruzione di una successione di variabili aleatorie reali indipendenti con leggi μ_i assegnate è equivalente a costruire una famiglia di variabili reali indipendenti $X_i \sim U(0,1)$*

Proof. ($\Longleftarrow$) Definiamo $X_i = q_{F_i}(U_i)$, dove $F_i(x) = \mu_i((-\infty, x])$ e otteniamo una famiglia di variabili aleatorie indipendenti (per conservazione dell'indipendenza) con leggi $\mu_{X_i} = \mu_i$ perché $F_{X_i} = F_i = F_{\mu_i}$ □

Teorema 2.10.5. *Ogni numero reale $u \in [0,1)$ ammette una scrittura come espansione binaria $u = 0.x_1x_2...$ e le funzioni $\psi_k : [0,1) \to \{0,1\}$ tali che $u \mapsto x_k(u)$ hanno come successione di funzioni $\psi = \{\psi_k\}_{k\in\mathbb{N}_0}$ inversa sinistra $\rho : \{0,1\}^{\mathbb{N}_0} \to [0,1)$ tale che $\{x_k\}_{k\in\mathbb{N}_0} \mapsto u$*

Teorema 2.10.6 (Teorema A)**.** *Sia $U \sim U(0,1)$, allora le variabili aleatorie $(X_k = \psi_k(U))_{k\in\mathbb{N}_0}$ sono variabili aleatorie IID $Be(\frac{1}{2})$, ovvero $p(X_k = 0) = p(X_k = 1) = \frac{1}{2}$*
Viceversa, se $\{X_k\}_{k\in\mathbb{N}_0}$ sono variabili aleatorie IID di tipo $Be(\frac{1}{2})$, allora le variabili aleatorie $U = \rho((X_k)_{k\in\mathbb{N}_0}) = \sum_{k=1}^{\infty} \frac{X_k}{2^k}$ è una variabile aleatorie $U(0,1)$

Teorema 2.10.7 (Teorema B)**.** *Siano $\{X_k\}_{k\in\mathbb{N}_0}$ variabili aleatorie IID di tipo $Be(\frac{1}{2})$, $\mathbb{P}$ l'insieme dei numeri primi e definiamo per $i, j \in \mathbb{N}_0$ $Y_j^{(i)} = X_{(p_i)^j}$. Allora, per ogni $i \in \mathbb{N}_0$ si ha una successione $Y^{(i)} = \{Y_j^{(i)}\}_{j\in\mathbb{N}_0}$. Le variabili aleatorie $\{Y^{(i)}\}_{i\in\mathbb{N}_0}$ sono indipendenti e la successione $Y^{(i)}$ è formata da una famiglia di variabili aleatorie IID di tipo $Be(\frac{1}{2})$*

Teorema 2.10.8. *Sia U una variabile aleatoria $U(0,1)$e si considerino $\phi_n : [0,1] \to [0,1]$ misurabili per ogni $n \in \mathbb{N}_0$. Definendo, $U_n = \phi_n(U)$, le variabili aleatorie $\{U_n\}_{n\in\mathbb{N}_0}$ sono indipendenti e $U_n \sim U(0,1)$ $\forall n \in \mathbb{N}_0$*

Proof. Sia U di tipo $U(0,1)$, allora $\{X_k\}_{k\in\mathbb{N}_0} = \{\psi_k(U)\}_{k\in\mathbb{N}_0}$ come nel teorema A è una famiglia di variabili aleatorie IID di tipo $Be(\frac{1}{2})$. Consideriamo $Y^{(i)}$ come nel teorema B, applicando il teorema A definiamo $U_i = \rho(Y^{(i)}) = \sum_{j=1}^{\infty} \frac{Y_j^{(i)}}{2^j}$ che è di tipo $U(0,1)$ per ogni $i \in \mathbb{N}_0$. Per conservazione dell'indipendenza, concludiamo che $\{U_i\}_{i\in\mathbb{N}_0}$ sono indipendenti. □

3 Convergenza e Teoremi Limite

3.1 Limiti superiori e inferiori di eventi

Definizione 3.1.1. *Sia $\{A_n\}_{n\in\mathbb{N}_0} \subset \mathscr{A}$ una famiglia di eventi in uno spazio di probabilità $(\Omega, \mathscr{A}, p)$.*

Si definisce il limsup della famiglia come $\limsup_{n\in\mathbb{N}_0} A_n = \bigcap_{k\in\mathbb{N}_0}\bigcup_{n\geqslant k} A_n = \{\omega \in \Omega \mid \omega \in A_n \text{ frequentemente}\}$*, dunque l'evento "si verificano infiniti tra gli eventi* A_n*".*
Si definisce il liminf della famiglia come $\liminf_{n\in\mathbb{N}_0} A_n = \bigcup_{k\in\mathbb{N}_0}\bigcap_{n\geqslant k} A_n = \{\omega \in \Omega \mid \omega \in A_n \text{ definitivamente}\}$

Teorema 3.1.1. *Sia* $\{A_n\}_{n\in\mathbb{N}_0} \subset \mathscr{A}$ *una famiglia di eventi, allora:*
(i) $(\liminf_{n\in\mathbb{N}_0} A_n)^c = \limsup_{n\in\mathbb{N}_0} A_n^c$
(ii) $\limsup_{n\in\mathbb{N}_0} A_n \subseteq \Omega$ *e* $\liminf_{n\in\mathbb{N}_0} A_n \subseteq \Omega$
(iii) $\chi_{\limsup_{n\in\mathbb{N}_0} A_n}(\omega) = \limsup_{n\in\mathbb{N}_0} \chi_{A_n}(\omega)$ *e* $\chi_{\liminf_{n\in\mathbb{N}_0} A_n}(\omega) = \liminf_{n\in\mathbb{N}_0} \chi_{A_n}(\omega)$

Teorema 3.1.2 (Lemma di Borel-Cantelli)**.** *Siano* $\{A_n\}_{n\in\mathbb{N}_0} \subset \mathscr{A}$ *eventi in uno spazio di probabilità* $(\Omega, \mathscr{A}, p)$*.*
(i) Se $\sum_{n\in\mathbb{N}_0} p(A_n) < \infty$*, allora* $p(\limsup_{n\in\mathbb{N}_0} A_n) = 0$
(ii) Se $\sum_{n\in\mathbb{N}_0} p(A_n) = \infty$ *e gli* $\{A_n\}_{n\in\mathbb{N}_0}$ *sono indipendenti, allora* $p(\limsup_{n\in\mathbb{N}_0} A_n) = 1$

Proof. (i) Sia $X : \Omega \to \mathbb{N}_0 \cup \{\infty\}$ la variabile aleatoria che conta quanti eventi della famiglia si verificano $X = \sum_{n\in\mathbb{N}_0} \chi_{A_n}$. Allora, $\limsup_{n\in\mathbb{N}_0} A_n = \{X = \infty\} = \{\omega \in \Omega \mid X(\omega) = \infty\}$. Dobbiamo mostrare che la sua probabilità è nulla, ovvero $p(X < \infty) = 1$, da cui $X < \infty$ quasi-ovunque che implica $E[X] < \infty$. $E[X] = E[\sum_{n\in\mathbb{N}_0} \chi_{A_n}] = \sum_{n\in\mathbb{N}_0} E[\chi_{A_n}] = \sum_{n\in\mathbb{N}_0} p(A_n) < \infty$
(ii) Vogliamo mostrare che $p((\limsup_{n\in\mathbb{N}_0} A_n)^c) = 0$, ma $p((\limsup_{n\in\mathbb{N}_0} A_n)^c) = p((\bigcap_{k\in\mathbb{N}_0} B_k)^c) = p(\bigcup_{k\in\mathbb{N}_0} B_k^c) \leqslant \sum_{k\in\mathbb{N}_0} p(B_k^c)$. Sappiamo inoltre che $p(B_k^c) = p(\bigcap_{n\geqslant k} A_n^c) = \lim_{N\to\infty} p(\bigcap_{n=k}^{N} A_n^c) = \lim_{N\to\infty} \prod_{n=k}^{N} p(A_n^c) \leqslant \lim_{N\to\infty} \prod_{n=k}^{N} e^{-p(A_n)} = \lim_{N\to\infty} e^{-\sum_{n=k}^{N} p(A_n)} = e^{-\lim_{N\to\infty}\sum_{n=k}^{N} p(A_n)} = 0$, dunque otteniamo la tesi. □

Esempio 3.1.1. *Fissiamo* $\{p_n\}_{n\in\mathbb{N}_0}$ *con* $0 \leqslant p_n \leqslant 1$ *e siano* $\{X_n\}_{n\in\mathbb{N}_0}$ *variabili aleatorie indipendenti con* $X_n \sim Be(p_n)$*; ovvero,* $p(X_n = 1) = p_n$ *e* $p(X_n = 0) = 1 - p_n$*. Pensiamo ad esempio* $\{X_n = 1\}$ *="esce testa nel lancio n-esimo", ci chiediamo quale sia la probabilità di avere infinite teste.*

$$p(\limsup_{n\in\mathbb{N}_0}\{X_n=1\})=\begin{cases}0, & \sum_{n\in\mathbb{N}_0} p_n<\infty\\ 1, & \sum_{n\in\mathbb{N}_0} p_n=\infty\end{cases}$$

Se $p_n = P \in (0,1)$, allora le probabilità di ottenere infinite croci o teste coincidono in analogia al paradosso della scimmia di Borel.
Se $p_n = \frac{1}{n^\gamma}$ con $\gamma \in (0,\infty)$, allora $p_n \to 0$ e dunque $1-p_n \to 1$ e $\sum_{n\in\mathbb{N}_0}(1-p_n)=\infty$, quindi la probabilità delle infinite croci è 1. Invece, $\sum_{n\in\mathbb{N}_0} p_n = \sum_{n\in\mathbb{N}_0}\frac{1}{n^\gamma}\begin{cases}<\infty, & \gamma>1\\ =\infty, & \gamma\leqslant 1\end{cases}$ quindi la probabilità di ottenere infinite teste è $p(\limsup_{n\in\mathbb{N}_0}\{X_n=1\})=\begin{cases}1, & \gamma\leqslant 1\\ 0, & \gamma>1\end{cases}$

3.2 Convergenza di variabili aleatorie

Definizione 3.2.1. *Siano $\{X_n\}_{n\in\mathbb{N}_0}$ variabili aleatorie reali definite su uno stesso spazio di probabilità $(\Omega,\mathscr{A},p)$. Diremo che:*
$X_n \to X$ quasi-certamente se e solo se $\lim_{n\to\infty} X_n(\omega)=X(\omega)$ quasi-ovunque se e solo se $p(X_n\to X)=1$, dove $\{X_n\to X\}=\{\omega\in\Omega \;\; X_n(\omega)\to X(\omega)\}$
$X_n \to X$ in probabilità se e solo se $\lim_{n\to\infty} p(|X_n-X|\geqslant\varepsilon)=0\ \forall\varepsilon>0$
$X_n \to X$ in L^P con $P\in(0,\infty)$ se e solo se $\lim_{n\to\infty} E\big[|X_n-X|^P\big]=0$

Teorema 3.2.1. *(i) La convergenza quasi-certa implica la convergenza in probabilità.*
(ii) La convergenza in L^P (per qualche $P\in(0,\infty)$) implica la convergenza in probabilità.

Proof. (i) Sia $\varepsilon>0$ e definiamo $Y_n=\chi_{\{|X_n-X|\geqslant\varepsilon\}}$, allora si ha $X_n(\omega)\to X(\omega)$ quasi-ovunque, dunque $|X_n(\omega)-X(\omega)|\to 0$. Ma allora, $|X_n(\omega)-X(\omega)|<\varepsilon$ definitivamente e quindi $Y_n(\omega)=0$ definitivamente. Applichiamo il teorema di convergenza dominata e, dato che $Y_n\to 0$ quasi-ovunque e $|Y_n|\leqslant 1\in L^1$, implica $p(|X_n-X|\geqslant\varepsilon)=E[Y_n]=\int_\Omega Y_n(\omega)dp(\omega)\to E[0]=0$
(ii) $p(|X_n-X|\geqslant\varepsilon)=p(|X_n-X|^P\geqslant\varepsilon^P)\leqslant\frac{E[|X_n-X|^P]}{\varepsilon^P}\to 0$ □

Teorema 3.2.2. *La convergenza in probabilità è più debole di quella quasi-certa e in L^P. Inoltre, la convergenza quasi-certa e in L^P non sono confrontabili.*

Proof. (i) Mostriamo che esistono successioni che convergono in probabilità ma non negli altri sensi. Consideriamo $\{Z_n\}_{n\in\mathbb{N}_0}$ indipendenti tali che $Z_n \sim Be(\frac{1}{n})$, abbiamo mostrato che $p(\limsup_{n\in\mathbb{N}_0}\{Z_n = 1\}) = p(Z_n = 1 \text{ frequentemente}) =$ 1 cioè si ha $Z_n(\omega) = 1$ frequentemente e quasi-ovunque. Definiamo $X_n = 2^n Z_n$ e osserviamo che $X_n(\Omega) = \{0, 2^n\}$
$p(|X_n - 0| \geqslant \varepsilon) = p(X_n \geqslant \varepsilon) \subseteq p(X_n = 2^n) = p(Z_n = 1) = \frac{1}{n} \to 0$, dunque converge in probabilità.
Sappiamo che $Z_n(\omega) = 1$ frequentemente e quasi-ovunque, dunque $X_n(\omega) = 2^n Z_n(\omega) = 2^n$ frequentemente e quasi-ovunque, dunque $X_n(\omega)$ non tende a 0 e quindi non converge quasi-certamente.
$E[|X_n - 0|^P] = E[X_n^P] = E[(2^n Z_n)^P] = 2^{nP} E[Z_n^P] = 2^{nP} E[Z_n] = \frac{2^{nP}}{n} \to \infty$, dunque non converge in L^P
(ii) Mostriamo che esistono successioni che convergono quasi-certamente ma non in L^P. Siano $\{Y_n\}_{n\in\mathbb{N}_0}$ indipendenti $Y_n \sim Be(\frac{1}{n^2})$, allora per Borel-Cantelli $p(\limsup_{n\in\mathbb{N}_0}\{Y_n = 1\}) = p(Y_n = 1 \text{ frequentemente}) = 0$, ovvero $Y_n(\omega) = 0$ definitivamente quasi-ovunque. definiamo $X_n = 2^n Y_n$ e $X = 0$. Sappiamo che quasi-ovunque $Y_n = 0$ definitivamente, dunque anche $X_n = 0$ e segue che $X_n \to 0$ definitivamente quasi-ovunque.
$E[|X_n - 0|^P] = E[(X_n)^P] = E[(2^n Y_n)^P] = 2^{nP} E[Y_n^P] = 2^{nP} E[Y_m] = \frac{2^{nP}}{n^2} \to \infty$
(iii) Mostriamo che esistono successioni che convergono in L^P ma non quasi-certamente. Siano $\{Z_n\}_{n\in\mathbb{N}_0}$ con $Z_n \sim Be(\frac{1}{n})$ indipendenti, allora $E[|X_n - 0|^P] = E[(X_n)^P] = E[Z_n^P] = E[Z_n] = \frac{1}{n} \to 0$
Abbiamo già osservato che $Z_n = 1$ frequentemente quasi-ovunque, dunque la probabilità che non converga a 0 è 1, da cui la probabilità $p(X_n \to 0) = 0$, ovvero non converge a 0 quasi-certamente. □

Teorema 3.2.3 (Lemma)**.** $\{X_n \to X\}^c = \bigcup_{\varepsilon>0} \limsup_{n\in\mathbb{N}_0}\{|X_n - X| \geqslant \varepsilon\} = \bigcup_{k\in\mathbb{N}_0} \limsup_{n\in\mathbb{N}_0}\{|X_n - X| \geqslant \frac{1}{k}\}$

Proof. Sia $A_\varepsilon = \{|X_n - X| \geqslant \varepsilon \text{ frequentemente}\}$ è decrescente in ε, cioè $A_\varepsilon \subseteq A_{\varepsilon'}\ \forall \varepsilon' < \varepsilon$.
Per quanto riguarda la seconda uguaglianza, si ha $\bigcup_{\varepsilon>0} A_\varepsilon \supseteq \bigcup_{k\in\mathbb{N}_0} A_{\frac{1}{k}}$ perché $A = \frac{1}{k}$ è A_ε con $\varepsilon = \frac{1}{k}$
Viceversa, per ogni $\varepsilon > 0$ se fisso $k \in \mathbb{N}_0$ tale che $\frac{1}{k} < \varepsilon$ si ottiene l'inclusione inversa.

Mostriamo ora la prima uguaglianza, $\omega \in \{X_n \to X\}^c$ se e solo se non è vero che $\lim_{n\to\infty} X_n(\omega) = X(\omega)$ se e solo se non è vero che per ogni $\varepsilon > 0$ si ha $|X_n(\omega) - X(\omega)| < \varepsilon$ definitivamente. Dunque, esiste $\varepsilon > 0$ per cui $|X_n(\omega) - X(\omega)| \geqslant \varepsilon$ frequentemente ovvero $\omega \in \limsup_{n\in\mathbb{N}_0}\{|X_n - X| \geqslant \varepsilon\} = A_\varepsilon$ □

Corollario 3.2.3.1. *(i) $X_n \to X$ quasi-certamente se e solo se per ogni $\varepsilon > 0$ si ha $p(\limsup_{n\in\mathbb{N}_0}\{|X_n - X| \geqslant \varepsilon\}) = 0$*
(ii) Se per ogni $\varepsilon > 0$ si ha $\sum_{k\in\mathbb{N}_0} p(|X_n - X| \geqslant \varepsilon) < \infty$, allora $X_n \to X$ quasi-certamente.

Teorema 3.2.4. *Se $X_n \to X$ in probabilità, allora esiste una sottosuccessione $\{n_k\}_{k\in\mathbb{N}_0}$ di $\{n\}_{n\in\mathbb{N}_0}$ tale per cui $X_{n_k} \to X$ (per $k \to \infty$) quasi-certamente.*

Proof. Se per ogni $\varepsilon > 0$ $p(|X_n - X| \geqslant \varepsilon) \to 0$, allora scelto $\varepsilon = \frac{1}{k}$ per ogni $k \in \mathbb{N}_0$ in modo che esista $n_k < \infty$ per cui $p(|X_n - X| \geqslant \frac{1}{k}) \leqslant \frac{1}{k^2}$. Fissato $\varepsilon > 0$, sia $k_0 = k_0(\varepsilon) \in \mathbb{N}_0$ per cui $\frac{1}{k_0} < \varepsilon$, allora per ogni $k \geqslant k_0$ si ha $\frac{1}{k} \leqslant \varepsilon$. Allora, $p(|X_{n_k} - X| \geqslant \varepsilon) \leqslant p(|X_{n_k} - X| \geqslant \frac{1}{k}) \leqslant \frac{1}{k^2}$, dunque $\sum_{k=k_0}^{\infty} p(|X_{n_k} - X| \geqslant \varepsilon) \leqslant \sum_{k=k_0}^{\infty} \frac{1}{k^2} < \infty$. Dato che $p(|X_{n_k} - X| \geqslant \varepsilon) \leqslant 1$, i termini precedenti non contati nella serie non inficiano la convergenza. □

Teorema 3.2.5. *Se $X_n \to X$ in probabilità e $|X_n| \leqslant Y$, con $Y \in L^P$, allora converge in L^P*

Proof. Definiamo $W_n = |X_n - X|^P$ e assumiamo $X_n \to X$ quasi-certamente, allora $W_n \to 0$ quasi-certamente. Osserviamo che $|X| = \lim_{n\to\infty} |X_n| \leqslant Y$ quasi-certamente, allora $|X_n - X| \leqslant |X_n| + |Z| \leqslant 2Y$ quasi-certamente, dunque $|X_n - X|^P \leqslant 2^P Y^P$, cioè $|W_n| \leqslant Z$ con $Z = 2^P Y^P \in L^1$. Dunque, per convergenza dominata si ha $\lim_{n\to\infty} E[W_n] = E[\lim_{n\to\infty} W_n] = E[0] = 0$
Assumiamo ora $X_n \to X$ in probabilità ma non in L^P, allora esiste $\varepsilon > 0$ e una sottosuccessione $\{n_k\}_{k\in\mathbb{N}_0}$ di $\{n\}_{n\in\mathbb{N}_0}$ tale che $E[|X_{n_k} - X|^P] \geqslant \varepsilon > 0$, contraddizione. □

Teorema 3.2.6 (Unicità del limite)**.** *Siano $\{X_n\}_{n\in\mathbb{N}_0}, X, X'$ variabili aleatorie tali per cui $X_n \to X$ e $X_n \to X'$ in probabilità. Allora, $X = X'$ quasi-ovunque.*

Proof. Estraiamo una sottosuccessione $\{n_k\}_{k\in\mathbb{N}_0}$ di $\{n\}_{n\in\mathbb{N}_0}$ tale per cui $X_{n_k} \to X$ quasi-certamente. Dato che $X_n \to X'$ in probabilità, anche $X_{n_k} \to X'$ in probabilità. Possiamo estrarre una sottosuccessione $\{k_l\}_{l\in\mathbb{N}_0}$ di $\{k\}_{k\in\mathbb{N}_0}$ tali che $X_{n_{k_l}} \to X'$ quasi-certamente. Infine, essendo $\{X_{n_{k_l}}\}_{l\in\mathbb{N}_0}$ sottosuccessione di $\{X_{n_k}\}_{k\in\mathbb{N}_0}$ che converge quasi-certamente a X, anche $X_{n_{k_l}} \to X$ quasi-certamente. Quindi, quasi-certamente si ha $X = \lim_{l\to\infty} X_{n_{k_l}} = X'$ □

Teorema 3.2.7. *Se $X_n \to X$ in L^P e se $X \in L^P$, allora $E[|X_n|^P] \to E[|X|^P]$. Se inoltre $P \in \mathbb{N}_0$, anche $E[X_n^P] \to E[X^P]$*
In particolare, la convergenza in L^1 implica la convergenza dei valori medi, la convergenza in L^2 implica anche la convergenza delle varianze.

Proof. Sfrutta il fatto che $||x|^P - |y|^P| \leqslant c|x-y|^P$ □

Teorema 3.2.8 (Lemma)**.** *$X_n \to X$ in probabilità se e solo se $E[\phi(|X_n - X|)] \to 0$ per ogni $\phi : \mathbb{R}^+ \to \mathbb{R}^+$ continua, limitata, nulla in 0 e strettamente crescente.*

Proof. ($\Longleftarrow$) Per $\varepsilon > 0$, $p(|X_n - X| \geqslant \varepsilon) = p(\phi(|X_n - X|) \geqslant \phi(\varepsilon)) \leqslant \frac{E[\phi(|X_n - X|)]}{\phi(\varepsilon)}$, per monotonia e Markov.
($\Longrightarrow$) Sapendo che $\forall\varepsilon > 0$ si ha $p(|X_n - X| \geqslant \varepsilon) \to 0$, prendo una sottosuccessione $\{n_k\}_{k\in\mathbb{N}_0}$ e dunque vale che $X_{n_k} \to X$ in probabilità, perciò esiste una sotto-sottosuccessione $\{n_{k_m}\}_{m\in\mathbb{N}_0}$ per cui $X_{n_{k_m}} \to X$ q.c. Ma allora, $X_{n_{k_m}} - X \to 0$ q.c. e quindi $\phi(|X_{n_{k_m}} - X|) \to 0 = \phi(0)$ q.c., per cui ϕ è limitata. Allora, per il TCD si ha che $E[\phi(|X_{n_{k_m}} - X|)] \to 0$ e dunque $E[\phi(|X_n - X|)] \to 0$
La conclusione è tratta dal fatto che è equivalente che una successione converga a un limite l e che da ogni sottosuccessione è possibile estrarre una sotto-sottosuccessione per cui il limite sia l. □

3.3 Geometria degli spazi L^P

Siano $(\Omega, \mathscr{A}, p)$ uno spazio di probabilità e $\{X_n\}_{n\in\mathbb{N}_0}$ variabili aleatorie in L^P, allora la quantità $E[|X_n - X|^P]$ è finita perché L^P è uno spazio vettoriale. Vogliamo capire se la nozione di convergenza in L^P è indotta da una topologia o da una distanza.

3.3.1 Caso $p \in [1, \infty)$

Definiamo la quantità $\|X\|_P = (E[|X|^P])^{\frac{1}{P}} < \infty$, detta (semi-)norma p di X. E' una semi-norma su L^P perché soddisfa:
(i) $\|X\|_P \geqslant 0$
(ii) $\|\lambda X\|_P = |\lambda| \|X\|_P$
(iii) $\|X + Y\|_P \leqslant \|X\|_P + \|Y\|_P$ (disuguaglianza di Minkowski)
Non è una norma perché $\|X\|_P = 0$ non implica $X = 0$ ma solo $X = 0$ quasi-ovunque. Definiamo la relazione di equivalenza $X \sim Y \iff X = Y$ quasi-ovunque ($p(X = Y) = 1$) e consideriamo lo spazio quoziente $\mathscr{L}^P = \frac{L^P}{\sim}$. Allora, $\| \cdot \|_P$ è una norma su $\mathscr{L}^P$ che è quindi uno spazio vettoriale normato ed è uno spazio metrico con la distanza $d_P(X, Y) = \|X - Y\|_P$

3.3.2 Caso $p \in (0, 1)$

La disuguaglianza di Minkowski non è rispettata per la norma definita precedentemente, dunque definiamo la pseudo-distanza $d_P(X, Y) = E[|X - Y|^P]$, infatti:
(i) $d_P(X, Y) \geqslant 0$
(ii) $d_P(X, X) = 0$
(iii) $d_P(X, Y) \leqslant d_P(X, Z) + d_P(Z, Y)$
Non è una distanza perché $d_P(X, Y) = 0$ implica solo $X = Y$ quasi-ovunque. Replicando il processo fatto poc'anzi, otteniamo lo spazio $\mathscr{L}^P$ che è metrico ma non normato.

3.3.3 Caso generale

Lo spazio $\mathscr{L}^P$ può essere dotato in generale della distanza $d_P(X, Y) = \begin{cases} E[|X - Y|^P], \ p \in (0, 1) \\ \|X - Y\|_P = E[|X - Y|^P]^{\frac{1}{P}}, \ p \in [1, \infty) \end{cases}$ e tale distanza induce la nozione di convergenza in L^P.

Teorema 3.3.1. *L'insieme $\mathscr{L}^P$ munito di d_P è uno spazio metrico completo. Inoltre, se $p \geqslant 1$ è uno spazio di Banach perché la distanza è indotta dalla norma $|| \cdot ||_P$, se $p = 2$ è uno spazio di Hilbert perché $|| \cdot ||_P$ è indotta dal prodotto scalare $< X, Y >= E[XY]$*

3.4 Legge dei Grandi Numeri

Definizione 3.4.1. *Siano $\{X_n\}_{n\in I}$ variabili aleatorie, allora la media campionaria è $\overline{X}_N = \frac{S_N}{N}$*

Teorema 3.4.1 (Legge Forte dei Grandi Numeri in L^1)**.** *Siano $\{X_n\}_{n\in\mathbb{N}}$ variabili aleatorie IID in L^1 e $m = E[X_n] \in \mathbb{R}$. Allora, $\overline{X}_N \to m$ quasicertamente.*

Teorema 3.4.2 (Legge Debole dei Grandi Numeri in L^2)**.** *Siano $\{X_n\}_{n\in\mathbb{N}_0}$ variabili aleatorie reali in L^2 scorrelate con valore medio $m = E[X_n]$ e varianza $\sigma^2 = Var[X_n]$. Allora vale la legge debole dei grandi numeri $\overline{X}_N \to m$ in probabilità.*

Proof. $E[S_N] = E[X_1 + ... + X_N] = mN$, dunque $E[\overline{X}_N] = \frac{E[S_N]}{N} = \frac{mN}{N} = m$
$Var[S_N] = \sum_{i=1}^{N} Var[X_i] + 2 \sum_{1\leqslant i<j\leqslant N} Cov[X_i, X_j] = \sigma^2 N$, quindi $Var[\overline{X}_N] = \frac{Var[S_N]}{N^2} = \frac{\sigma^2 N}{N^2} = \frac{\sigma^2}{N}$
Infine, per Chebychev, $p(|\overline{X}_N - m| \geqslant \varepsilon) = p(|\overline{X}_N - E[|\overline{X}_N]| \geqslant \varepsilon) \leqslant \frac{Var[\overline{X}_N]}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2 N} \to 0$, che implica la tesi. □

Definizione 3.4.2. *Sia $f : [0,1] \to \mathbb{R}$ continua, il polinomio di Bernstein di f è $p_n^f(x) = \sum_{k=0}^{n} \binom{n}{k} f(\frac{k}{n}) x^k (1-x)^{n-k}$*

Teorema 3.4.3 (Teorema di approssimazione di Weierstrass)**.** *Per ogni funzione continua $f : [a,b] \to \mathbb{R}$ esiste una successione di polinomi $\{p_n\}_{n\in\mathbb{N}_0}$ tale per cui $\|f - p_n\|_\infty \to 0$ uniformemente.*

Teorema di Bernstein. Stiamo considerando il caso $a = 0$ e $b = 1$ e definiamo $M = \sup_{x\in[0,1]} |f(x)| < \infty$ e per continuità uniforme $\forall \varepsilon > 0\ \exists \delta_\varepsilon > 0$ per cui per ogni $x, y \in [0,1]$ tale che $|x - y| \leqslant \delta_\varepsilon \implies |f(x) - f(y)| \leqslant \frac{\varepsilon}{2}$. La funzione f è limitata e uniformemente continua, fissiamo $x \in [0,1]$ e $n \in \mathbb{N}_0$ e consideriamo $\{X_i\}_{i=1,\dots,n}$ variabili IID di tipo $Be(x)$. Allora, detta $g(Z) = f(\frac{Z}{n})$, $E[f(\overline{X}_n)] = E[f(\frac{S_n}{n})] = E[g(S_n)] = \sum_{x\in\mathbb{R}} g(x) p_{S_n}(x) = \sum_{k=0}^{n} f(\frac{n}{k}) \binom{n}{k} x^k (1-x)^{n-k} = p_n^f(x)$, perché $S_n \sim Bin(n, x)$, dunque $p(S_n = k) = \binom{n}{k} x^k (1-x)^{n-k} \chi_{\{0,\dots,n\}}(x)$. Inoltre, $|p_n^f(x) - f(x)| = |E[f(\overline{X}_n)] - f(x)| = |E[f(\overline{X}_n) - f(x)]| \leqslant E[|f(\overline{X}_n) - f(x)|]$

Sia $\varepsilon > 0$ e definiamo $A_{n,\varepsilon} = \{|\overline{X}_n - x| \geqslant \delta_\varepsilon\}$, allora $|p_n^f(x) - f(x)| \leqslant E[|f(\overline{X}_n) - f(x)|\chi_{A_{n,\varepsilon}}] + E[|f(\overline{X}_n) - f(x)|\chi_{A_{n,\varepsilon}^c}] = \alpha + \beta$
$\alpha \leqslant E[(|f(\overline{X}_n)| + |f(x)|)\chi_{A_{n,\varepsilon}}] \leqslant 2Mp(A_{n,\varepsilon}) \leqslant 2M\frac{\sigma^2}{\delta_\varepsilon^2 n}$
$\beta = E[|f(\overline{X}_n) - f(x)|\chi_{A_{n,\varepsilon}^c}] \leqslant \frac{\varepsilon}{2}p(A_{n,\varepsilon}^c) \leqslant \frac{\varepsilon}{2}$
Concludiamo che $|f(x) - p_n^f(x)| \leqslant \alpha + \beta \leqslant \frac{M}{2\delta_\varepsilon^2 n} + \frac{\varepsilon}{2} \implies ||f - p_n^f||_\infty = \sup_{x\in[0,1]} |f(x) - p_n^f(x)| \leqslant \frac{M}{2\delta_\varepsilon^2 n} + \frac{\varepsilon}{2}$. Per $n \geqslant \frac{M}{\varepsilon\delta_\varepsilon^2}$, ottengo $\|f - p_n^f\|_\infty \leqslant \varepsilon$, da cui la tesi. □

Teorema 3.4.4 (Legge dei Grandi Numeri in L^2)**.** *Siano $\{X_n\}_{n\in\mathbb{N}_0}$ variabili aleatorie reali in L^2 scorrelate con stessi valori medi $m = E[X_n] \in \mathbb{R}$ e varianze $\sigma^2 = Var[X_n]$. Allora, $\overline{X}_N \to m$ quasi-certamente.*

Proof. Assumiamo WLOG che $m = 0$, il caso generale segue da questo caso definendo $X_n' = X_n - m$, e definiamo $Y_N = \overline{X}_{N^2} = \frac{S_{N^2}}{N^2}$. Osserviamo che $\sum_{N\in\mathbb{N}_0} p(|Y_N - 0| \geqslant \varepsilon) \leqslant \sum_{N\in\mathbb{N}_0} \frac{Var[Y_N]}{\varepsilon^2} = \sum_{N\in\mathbb{N}_0} \frac{\sigma^2}{\varepsilon^2 N^2} < \infty$, dunque $Y_N \to 0$ quasi-certamente.
Siano ora $\Delta_N = \max_{N^2<k<(N+1)^2} |S_k - S_{N^2}|$ e sia $Z_n = \frac{\Delta_N}{N^2}$, quindi $p(|Z_N - 0| \geqslant \varepsilon) = p(|Z_N| \geqslant \varepsilon) = p(Z_N^2 \geqslant \varepsilon^2) \leqslant \frac{E[Z_N^2]}{\varepsilon^2} = \frac{E[\Delta_N^2]}{\varepsilon^2 N^4}$. Ma sappiamo anche che $\Delta_N^2 \leqslant \sum_{k=N^2+1}^{(N+1)^2-1} (S_k - S_{N^2})^2$, dunque $E[\Delta_N^2] \leqslant \sum_{k=N^2+1}^{(N+1)^2-1} E[(S_k - S_{N^2})^2] \leqslant \sum_{k=N^2+1}^{(N+1)^2-1} Var[\sum_{i=N^2+1}^{k} X_i] \leqslant \sigma^2 2N[(N+1)^2 - 1 - N^2] = \sigma^2 4N^2$; perciò, $Z_N \to 0$ quasi-certamente.
Siano $N \in \mathbb{N}_0$ e $k \in \{N^2, ..., (N+1)^2 - 1\}$, allora $0 \leqslant |\overline{X}_k| = \frac{|S_k|}{k} \leqslant \frac{|S_k|}{N^2} \leqslant \frac{|S_{N^2}| + |S_k - S_{N^2}|}{N^2} \leqslant |\frac{S_{N^2}}{N^2}| + \frac{\Delta_N}{N^2} = |Y_N| + |Z_N| \to 0$ quasi-certamente. □

3.5 Convergenza di probabilità

Definizione 3.5.1. *Siano $\{\mu_n\}_{n\in\mathbb{N}_0}$ probabilità su $\mathbb{R}$, diremo che $\{\mu_n\}_{n\in\mathbb{N}_0}$ converge debolmente verso μ se e solo se $\int_\mathbb{R} \phi d\mu_n \to \int_\mathbb{R} \phi d\mu$ per ogni $\phi : \mathbb{R} \to \mathbb{R}$ continua e limitata.*

Definizione 3.5.2. *Siano $\{X_n\}_{n\in\mathbb{N}_0}$ variabili aleatorie reali, non necessariamente definite sullo stesso spazio di probabilità. Diremo che $\{X_n\}_{n\in\mathbb{N}_0}$ converge verso X in distribuzione (o debolmente) se e solo se $\int_\mathbb{R} \phi \, d\mu_{X_n} \to \int_\mathbb{R} \phi \, d\mu_X$ per ogni $\phi \in \mathscr{C}_b(\mathbb{R})$*

Non è sufficiente che sia misurabile e limitata, si può prendere come controesempio $\nu_n = \delta_{\frac{1}{n}}$ (vedi lezione 29) La definizione si può estendere a probabilità su uno spazio topologico arbitrario munito della σ-algebra di Borel.

Teorema 3.5.1 (Lemma)**.** *Siano μ, μ' probabilità su $\mathbb{R}$ tali che $\int_{\mathbb{R}} \phi d\mu = \int_{\mathbb{R}} \phi d\mu'$, allora $\mu = \mu'$ (ovvero $\mu(A) = \mu'(A)$)*

Proof. E' sufficiente mostrare che coincidono su ogni chiuso C (base dei borelliani), ovvero $\int_{\mathbb{R}} \chi_C d\mu = \int_{\mathbb{R}} \chi_C d\mu'$. Definiamo $d(x, A) = \inf\{|x - y \mid y \in A\}$, allora $|d(x, A) - d(z, A)| \leqslant d(x, z) = |x - z|$, dunque $z \mapsto d(z, A)$ è una funzione chiusa e, se $A = C$ è chiuso, allora $d(x, C) = 0 \iff x \in C$. Definiamo ora le funzioni $\phi_n(x) = \begin{cases} 1 - nd(x, C), \ d(x, C) \leqslant \frac{1}{n} \\ 0, \ d(x, C) > \frac{1}{n} \end{cases}$, che sono continue, rispettano $|\phi_n| \leqslant 1$ e $\lim_{n\to\infty} \phi_n(x) = \chi_C(x) = \begin{cases} 1, \ x \in C \\ 0, \ x \notin C \end{cases}$, dunque otteniamo $\mu(C) = \int_{\mathbb{R}} \chi_C d\mu \leftarrow \int_{\mathbb{R}} \phi_n d\mu = \int_{\mathbb{R}} \phi_n d\mu' \to \int_{\mathbb{R}} \chi_C d\mu' = \mu'(C)$ per ogni chiuso C. □

Teorema 3.5.2 (Unicità del limite debole)**.** *Siano $\{\mu_n\}_{n\in\mathbb{N}_0}$, μ, μ' probabilità su $\mathbb{R}$ tali che $\mu_n \to \mu$ e $\mu_n \to \mu'$ debolmente, allora $\mu = \mu'$.*
Se $\{X_n\}, X, X'$ sono variabili aleatorie reali tali che $X_n \to X$ e $X_n \to X'$ debolmente, allora $\mu_X = \mu_{X'}$

Siano $\{z_n\}_{n\in\mathbb{N}_0}, z$ numeri reali tali che $z_n \to z$, allora definendo $\mu_n = \delta_{z_n}$ e $\mu = \delta_z$, si ha che $\mu_n \to \mu$ debolmente in quanto $\int_{\mathbb{R}} d\mu_n = \phi(z_n) \to \phi(z) = \int_{\mathbb{R}} \phi d\mu$

Teorema 3.5.3. *Se $\mu_n \to \mu$ debolmente, allora $\mu_n(A) \to \mu(A)$ per ogni $A \in \mathscr{B}(\mathbb{R})$ tale che $\mu(\partial A) = 0$*

Teorema 3.5.4 (Lemma)**.** *Sia $\{z_n\}_{n\in\mathbb{N}_0}$ una successione in uno spazio topologico E e sia $z \in E$. Allora $z_n \to E$ se e solo se per ogni sottosuccessione $\{z_{n_k}\}_{k\in\mathbb{N}_0}$ esiste una sotto-sottosuccessione $\{z_{n_{k_l}}\}_{l\in\mathbb{N}_0}$ tale che $z_{n_{k_l}} \to z$ (per $l \to \infty$).*

Teorema 3.5.5. *Siano $\{X_n\}_{n\in\mathbb{N}}, X$ variabili aleatorie reali tali che $X_n \to X$ in probabilità. Allora, $X_n \to X$ debolmente.*

Proof. Sia $\phi \in C_b(\mathbb{R})$ (insieme delle funzioni continue e limitate) e sia $\{n_k\}_{k\in\mathbb{N}_0}$ sottosuccessione di $\{n\}_{n\in\mathbb{N}_0}$. Per ipotesi, $X_n \to X$ in probabilità e dunque anche $X_{n_k} \to X$ in probabilità. Sappiamo che esiste una sotto-sottosuccessione

$X_{n_{k_l}} \to X$ quasi-certamente, dunque $\phi(X_{n_{k_l}}) \to \phi(X)$ quasi-certamente perché ϕ è continua. Inoltre, $|\phi(X_{n_{k_l}})| \leqslant c \in \mathbb{R}$ perché ϕ è limitata. Per convergenza dominata, si ha $E[\phi(X_{n_{k_l}})] \to E[\phi(X)]$, ovvero $z_{n_{k_l}} \to z$ □

Esempio 3.5.1 (Controesempio dell'inversa)**.** *Fissiamo $X \sim Unif\{-1,1\}$ e definiamo la variabile aleatoria $X_n = (-1)^n X$, allora $\mu_{X_n} = \mu_X = Unif\{-1,1\}$, dunque $X_n \to X$ debolmente. Tuttavia, X_n non converge in probabilità; in quanto, se convergesse, si avrebbe $X_{2n} \to Y$ e $X_{2n+1} \to Y$ in probabilità, ovvero $X = -X$ quasi-certamente, il che è verificato se e solo se $X = 0$ quasi-certamente che è assurdo.*

Teorema 3.5.6. *Se $X_n \to X$ debolmente e $X = c \in \mathbb{R}$ quasi-ovunque, allora $X_n \to X$ in probabilità.*

Proof. Può essere dimostrato che $X_n \to X$ in probabilità se e solo se $E[\phi(|X_n - X|)] \to 0$, con $\phi(x) = \arctan(x)$, quindi mostriamo che vale la seconda.
$E[\phi(|X_n - X|)] = E[\phi(|X_n - x|)] = E[\psi(X_n)] \to E[\psi(X)] = E(\phi(|X - c|)) = E[\phi(|c - c|)] = \phi(a) = 0$ □

Esempio 3.5.2. *Sia $X_n \sim U((-\frac{1}{n}, \frac{1}{n}))$, allora $E[\phi(X_n)] = \int_{\mathbb{R}} \phi(x) f_{X_n}(x)dx = \frac{n}{2}\int_{-\frac{1}{n}}^{\frac{1}{n}} \phi(x)dx \to \phi(0) = E[\phi(X)]$, dunque $X_n \to X = 0$ debolmente.*

Esempio 3.5.3. *Sia $X_n \sim Unif\{\frac{k}{n}\}_{k=1,\dots,n}$, allora $X_n \to X \sim U(0,1)$ debolmente. Sappiamo che $p(X_n = \frac{k}{n}) = \frac{1}{n}$, dunque $E[\phi(X_n)] = \int_{\mathbb{R}} \phi d\mu_{X_n} = \sum_{x \in \mathbb{R}} \phi(x) p(X_n = x) = \sum_{i=1}^{n} \phi(\frac{k}{n})\frac{1}{n} = \sum_{i=1}^{n} \phi(t_k)(t_k - t_{k-1}) \to \int_0^1 \phi(x)dx = \int_{\mathbb{R}} \phi d\mu_X = E[\phi(X)]$, dove $t_k = \frac{k}{n}$, dunque $X_n \to X \sim U(0,1)$ debolmente.*

Teorema 3.5.7. *Siano X una variabile aleatoria reale, $\mu = \mu_X$ la sua legge e $F(x) = F_X(x) = F_\mu(x) = p(X \leqslant x) = \mu((-\infty, x])$ la funzione di ripartizione. Allora, detto $I_F = \{x \in \mathbb{R} \mid F \text{ è continua nel punto } x\}$, I_F^c è al più numerabile.*

Credo sia la dimostrazione. Sappiamo che $F(x^-) = p(X < x) = \mu((-\infty, x))$, dunque $F(x) - F(x^-) = p(X = x) = \mu(\{x\})\ \forall x \in \mathbb{R}$ □

Teorema 3.5.8. *Siano $\{\mu_n\}_{n \in \mathbb{N}_0}, \mu$ probabilità su $\mathbb{R}$ e $\{F_n\}_{n \in \mathbb{N}_0}, F$ le loro funzioni di ripartizione. Allora, sono equivalenti:*
(i) $\mu_n \to \mu$ debolmente
(ii) $\int_{\mathbb{R}} \phi d\mu_n \to \int_{\mathbb{R}} \phi d\mu\ \forall \phi \in \mathscr{C}_b^\infty(\mathbb{R})$
(iii) $F_n(x) \to F(x)\ \forall x \in I_F$
(iv) $F_n(x) \to F(x)$ per ogni $x \in J \subset \mathbb{R}$ denso.

Proof. $(i) \Longrightarrow (ii)$ Deriva dal fatto che $\mathscr{C}_b^\infty(\mathbb{R}) \subseteq \mathscr{C}_b(\mathbb{R})$
$(ii) \Longrightarrow (iii)$ Dobbiamo mostrare che $F(x^-) \leqslant \liminf_{n\to\infty} F_n(x) \leqslant \limsup_{n\to\infty} F_n(x) \leqslant F(x)$, ovvero che per ogni $x \in \mathbb{R}$ e per ogni $\varepsilon > 0$ si ha $F(x-\varepsilon) \leqslant \liminf_{n\to\infty} F_n(x)$ e dunque che per ogni $s < t \in \mathbb{R}$ si ha $F(s) \leqslant \liminf_{n\to\infty} F_n(t)$. Sappiamo esistere $\phi = \phi_{s,t} \in \mathscr{C}_b^\infty(\mathbb{R})$ tale che $\chi_{(-\infty,s]} \leqslant \phi \leqslant \chi_{(-\infty,t]}$, dunque $F(s) = \int \chi_{(-\infty,s]} d\mu \leqslant \int \phi d\mu$ e $\int \phi d\mu_n \leqslant \int \chi_{(-\infty,t]} d\mu_n = F_n(t)$. Quindi, $\liminf_{n\to\infty} F_n(t) \geqslant \liminf_{n\to\infty} \int \phi d\mu_n = \int \phi d\mu \geqslant F(s)$. In modo analogo, si mostra che $\limsup_{n\to\infty} F_n(s) \leqslant F(t)$
$(iii) \Longrightarrow (iv)$ Deriva dal fatto che I_F è denso. $(iv) \Longrightarrow (i)$ Sia $\phi \in \mathscr{C}_b(\mathbb{R})$ e $\varepsilon > 0$, mostriamo che definitivamente $|\int_{\mathbb{R}} \phi d\mu_n - \int_{\mathbb{R}} \phi d\mu| < \varepsilon$. Sia $\zeta = \frac{\varepsilon}{8M} > 0$, con $M = \sup_{x\in\mathbb{R}} |\phi(x)|$, e $A, B \in J$ tali che $F(A) < \zeta$ e $F(B) > 1 - \zeta$; dato che $F_n(A) \to F(A) < \zeta$ e $F_n(B) \to F(B) > 1 - \zeta$, esiste $n_1 \in \mathbb{R}$ tale che definitivamente $F_n(A) < \zeta$ e $F_n(B) > 1 - \zeta$
$|\int_{\mathbb{R}} \phi d\mu_n - \int_{\mathbb{R}} \phi d\mu| = |(\int_{(A,B]} \phi d\mu_n - \int_{(A,B]} \phi d\mu) + (\int_{(A,B)^c} \phi d\mu_n - \int_{(A,B]^c} \phi d\mu)| \leqslant$
$|\int_{(A,B]} \phi d\mu_n - \int_{(A,B]} \phi d\mu| + |\int_{(A,B)^c} \phi d\mu_n| + |\int_{(A,B]^c} \phi d\mu|$
Osserviamo che $|\int_{(A,B]^c} \phi d\mu_n| \leqslant M\mu_n((A,B]^c) = M[\mu_n((-\infty, A]) + \mu_n((B,\infty))] =$
$M[F_n(A) + 1 - F_n(B)] \leqslant M[\zeta + \zeta] = M2\zeta = \frac{\varepsilon}{4}$
Consideriamo $\phi : [A, B] \to \mathbb{R}$, uniformemente continua in quanto continua, esiste $\delta = \delta(\varepsilon) > 0$ tale per cui per ogni $x, y \in [A, B]$ si ha $|x - y| \leqslant \delta \Longrightarrow |\phi(x) - \phi(y)| < \frac{\varepsilon}{8}$. Suddividiamo $[A, B]$ in m punti $A = t_0 < ... < t_m = B$ tali che $|t_i - t_{i-1}| \leqslant \delta(\varepsilon)$ e $t_i \in J$ e definiamo $\psi : (A, B] \to \mathbb{R}$ ponendo $\psi(x) = \phi(t_i)$, cioè $\psi(x) = \sum_{i=1}^m \phi(t_i)\chi_{(t_{i-1},t_i]}(x)$. Allora, $|\psi(x) - \phi(x)| \leqslant |\phi(t_i) - \phi(x)| < \frac{\varepsilon}{8}$. Infine, scrivendo $\int \phi = \int \psi + \int(\phi - \psi)$, si ha $|\int_{(A,B]} \phi d\mu_n - \int_{(A,B]} \phi d\mu| \leqslant |\int_{(A,B]} \psi d\mu_n - \int_{(A,B]} \psi d\mu| + |\int_{(A,B]} (\phi - \psi) d\mu_n| + |\int_{(A,B]} (\phi - \psi) d\mu|$, ma $|\int_{(A,B]} (\phi - \psi) d\mu_n| \leqslant \sup_{x\in(A,B]} |\phi(x) - \psi(x)| \mu_n((A, B]) \leqslant \frac{\varepsilon}{8}$, dunque
$|\int_{(A,B]} \phi d\mu_n - \int_{(A,B]} \phi d\mu| \leqslant |\int_{(A,B]} \psi d\mu_n - \int_{(A,B]} \psi d\mu| + \frac{\varepsilon}{8} + \frac{\varepsilon}{8}$
Per concludere, vogliamo mostrare che $|\int_{(A,B]} \psi d\mu_n - \int_{(A,B]} \psi d\mu| < \frac{\varepsilon}{4}$, ovvero dobbiamo mostrare che $\lim_{n\to\infty} \int_{(A,B]} \psi d\mu_n = \int_{(A,B]} \psi d\mu$, ma $\psi = \sum_{i=1}^m \phi(t_i)\chi_{(t_{i-1},t_i]}$, quindi $\int_{(A,B]} \psi d\mu_n = \sum_{i=1}^m \phi(t_i) \int_{(A,B]} \chi_{(t_{i-1},t_i]} d\mu_n = F_n(t_i) - F_n(t_{i-1})$. Dunque,
$\lim_{n\to\infty} \int_{(A,B]} \phi d\mu_n = \sum_{i=1}^m \phi(t_i) \lim_{n\to\infty} [F_n(t_i) - F_n(t_{i-1})] = \sum_{i=1}^m \phi(t_i)\mu((t_{i-1}, t_i]) =$

$\sum_{i=1}^{n} \phi(t_i) \int_{(A,B]} \chi_{(t_{i-1},t_i]} d\mu = \int_{(A,B]} \psi d\mu$ □

Corollario 3.5.8.1. *Siano $\{X_n\}_{n\in\mathbb{N}_0}$ variabili aleatorie reali. Allora, $X_n \to X$ debolmente se e solo se $F_{X_n}(x) \to F_X(x)$ per ogni $x \in J \subseteq \mathbb{R}$ denso (si può scegliere $J = I_{F_X}$)*

Teorema 3.5.9 (Lemma di Scheffé)**.** *Siano $(E, \mathscr{E})$ uno spazio misurabile, μ misura su $(E, \mathscr{E})$ e $\{f_n\}_{n\in\mathbb{N}_0}, f$ misurabili non-negative e assumiamo che $f_n(x) \to f(x)$ quasi-ovunque per μ. Allora, $\int_E |f_n(x) - f(x)|\mu(dx) \to 0$ se e solo se $\int_E f_n(x)\mu(dx) \to \int_E f(x)\mu(dx)$*

Teorema 3.5.10. *Siano $\{X_n\}_{n\in\mathbb{N}_0}$ variabili aleatorie reali.*
(i) Se $\{X_n\}_{n\in\mathbb{N}_0}, X$ sono assolutamente continue e se c'è convergenza puntuale quasi-ovunque delle densità, cioè se $f_{X_n}(x) \to f_X(x)$ quasi-ovunque allora $X_n \to X$ debolmente.
(ii) Se $\{X_n\}_{n\in\mathbb{N}_0}, X$ sono discrete e se c'è convergenza puntuale quasi-ovunque delle densità discrete, cioè se $p_{X_n}(x) = p(X_n = x) \to p_X(x) = p(X = x)$, allora $X_n \to X$ debolmente.

Proof. (i) Sia ϕ misurabile e limitata. Allora, $|E[\phi(X_n)] - E[\phi(X)]| = |\int_{\mathbb{R}} \phi(x) f_{X_n}(x)dx - \int_{\mathbb{R}} \phi(x) f_X(x)dx| \leqslant \int_{\mathbb{R}} |\phi(x)||f_{X_n}(x) - f_X(x)|dx \leqslant M \int_{\mathbb{R}} |f_{X_n}(x) - f_X(x)|dx \to 0$ per il Lemma di Scheffé. □

Esempio 3.5.4. *Consideriamo la distribuzione $Pois(\lambda)$ che ha densità discreta $p_\lambda(x) = e^{-\lambda}\frac{\lambda^x}{x!}\chi_{\mathbb{N}}(x)$. Osserviamo che $\lambda \mapsto p_\lambda(x)$ è continua, allora se $\{\lambda_n\}_{n\in\mathbb{N}_0}, \lambda$ sono tali che $\lambda_n \to \lambda$, allora $Pois(\lambda_n) \to Pois(\lambda)$ debolmente.*

Esempio 3.5.5. *La distribuzione $U(a, b)$ ha densità $f_{(a,b)}(x) = \frac{1}{b-a}\chi_{(a,b)}(x)$, quindi $(a, b) \mapsto f_{(a,b)}(x)$ è continua nel dominio ad esclusione di a e b. Dunque, dati $\{a_n\}_{n\in\mathbb{N}_0}, \{b_n\}_{n\in\mathbb{N}_0}$ e a, b tali che $a_n < b_n, a < b$ e $a_n \to a, b_n \to b$, si ha $U(a_n, b_n) \to U(a, b)$ perché la densità converge $f_{(a_n,b_n)}(x) \to f_{(a,b)}(x)\ \forall x \in \mathbb{R}\backslash\{a, b\}$*

Teorema 3.5.11 (Legge dei Piccoli Numeri)**.** *Siano $\{p_n\}_{n\in\mathbb{N}_0} \subseteq [0, 1]$ e $\lambda \in (0, \infty)$ tali che $p_n \sim \frac{\lambda}{n}$. Allora, $X_n \sim Bin(n, p_n) \to X \sim Pois(\lambda)$ debolmente. Più precisamente,*
$\binom{n}{k} p_n^k (1 - p_n)^{n-k} = p_{X_n}(k) = p(X_n = k) \to p_X(k) = p(X = k)\ \forall k \in \mathbb{N}_0 = e^{-\lambda}\frac{\lambda^k}{k!}$

Proof. Assumiamo per semplicità $p_n = \frac{\lambda}{n}$. Allora, $\binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{n!}{(n-k)!}\frac{1}{k!}\frac{\lambda^k}{n^k}(1-\frac{\lambda}{n})^n \frac{1}{(1-\frac{\lambda}{n})^k}$. Ci basta mostrare che $\lim_{n\to\infty} \frac{1}{(1-\frac{\lambda}{n})^k} = 1$ e $\lim_{n\to\infty} \frac{n!}{(n-k)!}\frac{1}{n^k} = 1$ □

3.6 Teorema Limite Centrale

Vogliamo capire quanto velocemente avviene la convergenza della Legge dei Grandi Numeri.

Definizione 3.6.1. *Sia $Y \in L^2$ una variabile aleatoria reale con $Var[Y] \neq 0$. Si chiama standardizzata di Y la variabile aleatoria $Z = \frac{Y - E[Y]}{\sqrt{Var[Y]}}$*

Per costruzione si ha $E[Z] = 0$ e $Var[Z] = 1$.

Teorema 3.6.1 (Lemma)**.** *Siano V, Y, W variabili aleatorie indipendenti con $Y, W \in L^3$, $E[Y] = E[W]$ e $Var[Y] = Var[W]$. Allora, per ogni $\phi \in \mathscr{C}_b^3(\mathbb{R})$, si ha $|E[\phi(V+Y)] - E[\phi(V+W)]| \leqslant \frac{C}{6}(E[|Y|^3] + E[|W|^3])$, con $C = ||\phi'''||$*

Proof. Per $x, h \in \mathbb{R}$, applichiamo lo sviluppo di Taylor a $\phi(x+h) = \phi(x) + \phi'(x)h + \frac{1}{2}\phi''(x)h^2 + R(x,h)$, con $R(x,h) = \frac{1}{2}\int_x^{x+h}(x+h-t)^2\phi'''(t)dt$. Dato che $|\phi'''(t)| \leqslant C$, si ha $|R(x,h)| \leqslant \frac{C}{2}|\int_x^{x+h}(x+h-t)^2dt| = \frac{C}{2}|\int_0^h s^2 ds| = \frac{C}{6}|h|^3$
Prendendo $x = V$ e $h \in \{Y, W\}$, scriviamo gli sviluppi e otteniamo i rispettivi valori medi.
$E[\phi(V+Y)] = E[\phi(V)] + E[\phi'(V)]E[Y] + \frac{1}{2}E[\phi''(V)]E[Y^2] + E[R(V,Y)]$
$E[\phi(V+W)] = E[\phi(V)] + E[\phi'(V)]E[W] + \frac{1}{2}E[\phi''(V)]E[W^2] + E[R(V,W)]$
Dunque, $|E[\phi(V+Y) - E[\phi(V+W)]] = |E[R(V,Y)] - E[R(V,W)]| \leqslant E[|R(V,Y)|] + E[|R(V,W)|] \leqslant \frac{C}{6}\{E[|Y|^3] + E[|W|^3]\}$ □

Teorema 3.6.2 (forse ipotesi da rivedere)**.** *Siano $\{Y_i\}_{i\in\mathbb{N}_0}, \{W_i\}_{i\in\mathbb{N}_0}$ variabili aleatorie IID in L^3 con $E[Y_i] = E[W_i] = 0$, $Var[Y_i] = 1$ e $Var[W_i] = 0$. Allora, per ogni $\phi \in \mathscr{C}_b^3(\mathbb{R})$, ponendo $C = ||\phi'''|| = \sup_{x\in\mathbb{R}}|\phi'''(x)|$, si ha $|E[\phi(\frac{Y_1+\ldots+Y_N}{\sqrt{N}})] - E[\phi(\frac{W_1+\ldots+W_N}{\sqrt{N}})]| \leqslant \frac{C}{6}\frac{E[|Y_1|^3]+E[|W_1|^3]}{\sqrt{N}}$*

Proof. Scriviamo il primo termine come una somma telescopica, definendo $a_N = E[\phi(\frac{Y_1+\ldots+Y_N}{\sqrt{N}})]$, $a_0 = E[\phi(\frac{W_1+\ldots+W_N}{\sqrt{N}})]$ e $a_k = E[\phi(\frac{Y_1+\ldots+Y_k+W_{k+1}+\ldots+W_N}{\sqrt{N}})]$, allora $|E[\phi(\frac{Y_1+\ldots+Y_N}{\sqrt{N}})] - E[\phi(\frac{W_1+\ldots+W_N}{\sqrt{N}})]| \leqslant \sum_{k=1}^N |a_k - a_{k-1}|$. Ma, definendo $V_k = \frac{Y_1+\ldots+Y_k+W_{k+1}+\ldots+W_N}{\sqrt{N}}$, si ha $a_k - a_{k-1} = E[\phi(V_k + \frac{Y_k}{\sqrt{N}})] - E[\phi(V_k) + \frac{W_k}{\sqrt{N}}]$.
Usando il precedente lemma, si ha $|a_k - a_{k-1}| \leqslant \frac{C}{6}E[|\frac{Y_k}{\sqrt{N}}|^3] + E[|\frac{W_k}{\sqrt{N}}|^3] = \frac{C}{6}\frac{E[|Y_1|^3]+E[|W_1|^3]}{N^{\frac{3}{2}}}$, dunque $\sum_{k=1}^N |a_k - a_{k-1}| \leqslant N\frac{C}{6}\frac{E[|Y_1|^3]+E[|W_1|^3]}{N^{\frac{3}{2}}} = \frac{C}{6}\frac{E[|Y_1|^3]+E[|W_1|^3]}{\sqrt{N}}$ □

Teorema 3.6.3 (Principio di Lindeberg)**.** *Siano $\{X_i\}_{i\in\mathbb{N}_0}$ e $\{\tilde{X}_i\}_{i\in\mathbb{N}_0}$ variabili aleatorie reali IID in L^2 con varianza non nulla, Z_N e $\tilde{Z}_N$ le standardizzate*

delle rispettive medie campionarie. Allora, $\lim_{N\to\infty} E[\phi(Z_N)] - E[\phi(\tilde{Z}_N)] = 0$ *per ogni scelta di* $\phi \in \mathscr{C}_b^3$

Proof. Definiamo per gli X_i (e analogamente per i $\tilde{X}_i$) $Y_i = \frac{X_i - m}{\sigma}$, allora $Z_N = \frac{S_N - mN}{\sigma\sqrt{N}} = \frac{Y_1 + \ldots Y_N}{\sqrt{N}}$ e $\tilde{Z}_N = \frac{W_1 + \ldots + W_N}{\sqrt{N}}$, con $W_i = \frac{\tilde{X}_i - \tilde{m}}{\tilde{\sigma}}$. Notiamo che sia le Y_i che le W_i sono variabili aleatorie IID in L^2 con stessa media e varianza. Applicando la precedente proposizione, si ottiene la tesi. □

Teorema 3.6.4 (Teorema Limite Centrale)**.** *Siano* $\{X_i\}_{i\in\mathbb{N}_0}$ *variabili aleatorie IID in* L^2*, con* $m = E[X_i] \in \mathbb{R}$ *e* $\sigma^2 = Var[X_i] \neq 0$*,* $\overline{X}_N$ *la media campionaria e* Z_N *la sua standardizzata. Allora,* $Z_N \to Z \sim N(0,1)$ *debolmente.*
In altre parole, $F_{Z_N}(z) = p(Z_N \leqslant z) \to \Phi(z) = p(Z \leqslant z) = \int_{-\infty}^{z} \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}} dx$ *per ogni* $z \in \mathbb{R}$

Proof. Siano $\{\tilde{X}_i\}_{i\in\mathbb{N}_0}$ variabili aleatorie reali IID normali standard ($N(0,1)$), allora $\tilde{Z}_N = \frac{\tilde{X}_1 + \ldots \tilde{X}_N}{\sqrt{N}}$ è una variabile aleatoria normale perché combinazione lineare di variabili aleatorie normali indipendenti. Ma $E[\tilde{Z}_N] = 0$ e $Var[\tilde{Z}_N] = 1$ poiché è standardizzata, dunque $\tilde{Z}_N \sim N(0,1)$ e ha la stessa distribuzione di Z. Applicando il principio di Lindeberg, otteniamo la tesi $0 = \lim_{N\to\infty} E[\phi(Z_N)] - E[\phi(\tilde{Z}_N)] \iff \lim_{N\to\infty} E[\phi(Z_N)] = E[\phi(Z)]$ □

Il fatto che $Z_N \to Z$ variabile aleatoria reale, significa che $\overline{X}_N = m + \frac{\sigma}{\sqrt{N}} Z_n \to m + \frac{\sigma}{\sqrt{N}} Z \cong m \pm O(\frac{1}{\sqrt{N}})$ debolmente e similmente per $S_N \cong mN \pm O(\sqrt{N})$

Esempio 3.6.1. *Sia* X_i *l'esito di un dado regolare, allora* $E[X_i] = m = \frac{7}{2}$*, dunque* $E[S_N] \cong mN \cong 3.5N$*,* $Var[S_N] = \sigma^2 N$ *e* $SD(S_N) \cong \sigma\sqrt{N}$*, quindi gli 'scostamenti' dei valori assunti da* S_N *rispetto al valore medio crescono in modo proporzionale a* $\sqrt{N}$*.*

Esempio 3.6.2. *Siano* $\{X_i\}_{i\in\mathbb{N}_0}$ *variabili aleatorie IID di tipo* $Be(\frac{1}{2})$*, allora* $E[X_i] = m = \frac{1}{2}$*,* $Var[X_i] = \frac{1}{2}(1 - \frac{1}{2}) = \frac{1}{4}$ *e* $\sigma = SD[X_i] = \sqrt{\sigma^2} = \frac{1}{2}$*. Sia* S_N *il numero di teste in* N *lanci, allora* $p(S_N > \frac{1}{2}N + \frac{1}{2}\sqrt{N}t) = p(Z_n > t) \to p(Z > t)$*, con* $N \sim N(0,1)$*. Per* N *grande tale probabilità risulta quasi indipendente da* N*, scegliamo ad esempio* $t = 1.5$*, allora*
$p(S_{100} > 57) \cong 6.66\%$
$p(S_{1000} > 523) \cong 6.86\%$

$p(S_{10000} > 5075) \cong 6.55\%$
Invece,
$p(S_{100} > 53) \cong 24\%$
$p(S_{1000} > 530) \cong 2.7\%$
$p(S_{10000} > 5300) \cong 10^{-9}$

3.7 Indipendenza di σ-algebre

3.7.1 Legge 0-1 di Kolmogorov

Riprendiamo il concetto di σ-algebra generata da una variabile aleatoria $X : (\Omega, \mathscr{A}, p) \to (E, \mathscr{E})$, essa è la più piccola σ-algebra su Ω che rende X misurabile; in quanto, $\sigma(X) = \{X^{-1}(B) = \{X \in B \mid B \in \mathscr{E}\}$

Definizione 3.7.1. *Siano $\{X_i\}_{i\in I}$ variabili aleatorie definite sullo stesso spazio di probabilità, allora la σ-algebra generata dalla famiglia è la più piccola σ-algebra su Ω che rende misurabili tutte le $X_i : (\Omega, \mathscr{A}, p) \to (E_i, \mathscr{E}_i)$*

Una base è data da $\mathscr{C} = \{C^{(k)}_{i_1,...,i_k,B_1,...,B_k}\} = \{X_{i_1} \in B_1, ..., X_{i_k} \in B_k$, con $k \in \mathbb{N}_0$, $i_1, ..., i_k \in I$, $B_j \in \mathscr{E}_{ij}\}$
Nel caso in cui $I = \mathbb{N}_0$, allora $\mathscr{C} = \bigcup_{N\in\mathbb{N}_0} \mathscr{C}_N = \{C_{B_1,...,B_N} \mid N \in \mathbb{N}_0, B_1 \in \mathscr{E}_1, ..., B_N \in \mathscr{E}_N\}$
Osserviamo inoltre che la σ-algebra generata da un evento coincide con quella generata dalla sua funzione caratteristica $\sigma(A) = \{\varnothing, A, A^c, \Omega\}$

Definizione 3.7.2. *Sia $(\Omega, \mathscr{A}, p)$ uno spazio di probabilità, allora le σ-algebre $\mathscr{F}, \mathscr{G} \subseteq \mathscr{A}$ si dicono indipendenti se e solo se $p(A \cap B) = p(A)p(B)$ per ogni scelta di $A \in \mathscr{F}$ e di $B \in \mathscr{G}$*
Una famiglia finita di σ-algebre si dice indipendente se e solo se $p(\bigcap_{i=1}^n A_i) = \prod_{i=1}^n p(A_i)$ per ogni scelta di $A_i \in \mathscr{F}_i$
Una famiglia arbitraria di σ-algebre si dice indipendente se e solo se ogni sottofamiglia finita è indipendente.

Teorema 3.7.1. *Siano $\{A_i\}_{i\in I}$ eventi in $(\Omega, \mathscr{A}, p)$, allora essi sono indipendenti se e solo se lo sono le σ-algebre da essi generati.*
Analogamente, vale per variabili aleatorie.

Definizione 3.7.3. *Per $N \in \mathbb{N}_0$, definiamo le σ-algebre $\mathscr{F}_N = \sigma(X_1, ..., X_N)$, $\mathscr{G}_N = \sigma(\{X_i\}_{i>N})$, $\mathscr{F}_\infty = \sigma(\{X_i\}_{i\in\mathbb{N}_0})$ e $\mathscr{G}_\infty = \bigcap_{N\in\mathbb{N}_0} \mathscr{G}_N$*

Teorema 3.7.2. *Siano $\tilde{\mathscr{F}}$ base di $\mathscr{F}$ e $\tilde{\mathscr{G}}$ base di $\mathscr{G}$. Se $\tilde{\mathscr{F}}$ e $\tilde{\mathscr{G}}$ sono indipendenti, allora anche $\mathscr{F}$ e $\mathscr{G}$*

Proof. Siano $A \in \mathscr{E}$ e $B \in \mathscr{G}$, supponiamo inoltre $p(A), p(B) > 0$ perché in caso contrario $p(A \cap B) = 0 = p(A)p(B)$. Fissiamo $B \in \tilde{\mathscr{G}}$ e definiamo $Q(A) = p(A|B)$, allora l'ipotesi diventa $Q(A) = p(A)\ \forall A \in \tilde{\mathscr{F}}$. Le probabilità Q e P coincidono sulla base $\tilde{\mathscr{F}}$, dunque coincidono anche sulla σ-algebra, ovvero la tesi è verificata nel caso $B \in \tilde{\mathscr{G}}$. Facendo lo stesso con $\tilde{\mathscr{F}}$, si ottiene la tesi. □

Teorema 3.7.3 (Indipendenza a blocchi)**.** *Siano $\{X_i\}_{i\in I}$ variabili aleatorie indipendenti e siano $J, K \subseteq I$ disgiunti. Allora, $\{X_j\}_{j\in J}$ e $\{X_k\}_{k\in K}$ sono indipendenti, ovvero lo sono le σ-algebre $\mathscr{F}$ e $\mathscr{G}$ generate.*

Proof. Basta mostrare che una base di $\mathscr{F}$ è indipendente da una base di $\mathscr{G}$, consideriamo il caso $I = \mathbb{N}$ e $J = \{1, ..., N\}, K = \{N+1, ...\}$. Una base di $\mathscr{F}_N$ è data da $\mathscr{C}_N = \{C_{A_1,...,A_N} = \{X_1 \in A_1, ..., X_N \in A_n\}\}$, mentre una base di $\mathscr{G}_N$ è data da $\mathscr{C}'_N = \bigcup_{k=1}^{\infty} \mathscr{C}'_{[N+1,N+k]} = \{C'_{A_{N+1},...,A_{N+K}} = \{X_{N+1} \in A_{N+1}, ..., X_{N+k} \in A_{N+k}\}\}$. Allora,
$p(C_{A_1,...,A_N} \cap C'_{A_{N+1},...,A_{N+k}}) = p(\bigcap_{i=1}^{N+k}\{X_i \in A_i\}) = \prod_{i=1}^{N+k} p(X_i \in A_i) = (\prod_{i=1}^{N} p(X_i \in A_i))(\prod_{i=N+1}^{N+k} p(X_i \in A_i)) = p(C_{A_1,...,A_N})p(C'_{A_{N+1},...,A_{N+k}})$ □

Corollario 3.7.3.1. *Date $\{X_i\}_{i\in\mathbb{N}_0}$ variabili aleatorie indipendenti, le σ-algebre $\mathscr{F}_N$ e $\mathscr{G}_N$ sono indipendenti.*

Teorema 3.7.4 (Legge 0-1 di Kolmogorov)**.** *Se $\{X_i\}_{i\in\mathbb{N}_0}$ sono variabili aleatorie indipendenti, la σ-algebra $\mathscr{G}_\infty$ è banale, ovvero $p(A) \in \{0, 1\}$ per ogni evento $A \in \mathscr{G}_\infty$*

Proof. Dal precedente corollario sappiamo che $\mathscr{F}_N$ e $\mathscr{G}_N$ sono indipendenti e similmente $\mathscr{F}_N$ e $\mathscr{G}_\infty$ perché $\mathscr{G}_\infty \subseteq \mathscr{G}_N$.
Dobbiamo quindi mostrare che $\mathscr{F}_\infty$ è indipendente da $\mathscr{G}_\infty$, ma una base di $\mathscr{F}_\infty$ è data da $\bigcup_{N\in\mathbb{N}_0} \mathscr{C}_N \subseteq \bigcup_{N\in\mathbb{N}_0} \mathscr{F}_N$, quindi basta mostrare che la loro unione è indipendente da $\mathscr{G}_\infty$, ma lo abbiamo già verificato poc'anzi.
Dato che $\mathscr{G}_\infty = \bigcap_{N\in\mathbb{N}_0} \mathscr{G}_N \subseteq \mathscr{G}_1 = \sigma(X_2, ...) \subseteq \mathscr{F}_\infty$, concludiamo che $\mathscr{G}_\infty$ e $\mathscr{G}_\infty$ sono indipendenti.
Dunque, per ogni $A, B \in \mathscr{G}_\infty$ si ha $p(A \cap B) = p(A)p(B)$, scegliendo $B = A$ si ha $p(A) = p(A)^2$, da cui $p(A) \in \{0, 1\}$ □

Corollario 3.7.4.1. *Nelle stesse ipotesi, ogni variabile aleatorie reale estesa Z misurabile rispetto a $\mathscr{G}_\infty$ è quasi-ovunque costante.*

Proof. Si può mostrare che se X è una variabile aleatoria reale estesa tale che $p(X \in B) \in \{0,1\}$, allora X è quasi-ovunque costante. Segue la tesi. □

Corollario 3.7.4.2. *La convergenza del Teorema Limite Centrale non può essere quasi-certa.*

Proof. Assumiamo per semplicità che $\{X_i\}_{i\in\mathbb{N}_0}$ siano variabili aleatorie IID con $E[X_i] = m = 0$ e $Var[X_i] = \sigma^2 = 1$. Allora, $Z_N = \frac{X_1+\ldots+X_N}{\sqrt{N}}$. Sia per assurdo $Z_N \to Z$ quasi-certamente, allora $Z = \lim_{n\to\infty} \frac{X_1+\ldots+X_n}{\sqrt{n}} = \lim_{n\to\infty} \frac{X_{N+1}+\ldots+X_n}{\sqrt{n}}$, che è un insieme misurabile rispetto a $\mathscr{G}_N$, dunque Z è misurabile rispetto a $\mathscr{G}_\infty$ dunque Z deve essere costante quasi-ovunque, in contraddizione con $Z \sim N(0,1)$ □

Corollario 3.7.4.3. *La convergenza del Teorema Limite Centrale non può essere in probabilità.*

Definizione 3.7.4. *Una famiglia di probabilità $\{\mu_i\}_{i\in I}$ su $\mathbb{R}$ si dice tight se e solo se per ogni $\varepsilon > 0$ esiste $A < B \in \mathbb{R}$ tale che $\mu_i([A,B]) > 1-\varepsilon$ $\forall i \in I$*

Teorema 3.7.5. *Ogni famiglia finita di probabilità è tight.*

Proof. Ogni probabilità singola è tight. Infatti, posto $F(x) = \mu((-\infty, x])$,, sappiamo che per ogni $\varepsilon > 0$ esiste $A < B \in \mathbb{R}$ tale per cui $F(A) < \frac{\varepsilon}{2}$ e $F(B) > 1 - \frac{\varepsilon}{2}$. Allora, $\mu([A,B]) \geqslant \mu((A,B]) = \mu((-\infty,B]) - \mu((-\infty,A]) = F(B) - F(A) > 1 - \frac{\varepsilon}{2} - \frac{\varepsilon}{2}$
Fissata μ_i nella famiglia sappiamo che essa è tight, dunque ponendo $A = \min_{i\in I} A_i$ e $B = \max_{i\in I} B_i$, allora $\mu_i([A,B]) \geqslant \mu_i([A_i,B_i]) > 1-\varepsilon$ □

Esempio 3.7.1. *La famiglia $\{\delta_n\}_{n\in\mathbb{N}_0}$ non è tight, in quanto posto $\varepsilon = \frac{1}{2}$ si ha $\delta_n([A,B]) < \varepsilon$ prendendo $n > B$*

Teorema 3.7.6. *Siano $\{\mu_n\}_{n\in\mathbb{N}_0}$ probabilità su $\mathbb{R}$. Allora, se la successione converge debolmente, $\{\mu_n\}_{n\in\mathbb{N}_0}$ è tight.*

Esempio 3.7.2. *Siano $\mu \neq \mu'$ probabilità distinte su $\mathbb{R}$, definendo $\mu_n = \begin{cases} \mu, & n \text{ pari} \\ \mu', & n \text{ dispari} \end{cases}$ allora $\{\mu_n\}_{n\in\mathbb{N}_0}$ è tight perché $\{\mu,\mu'\}$ è tight, ma la successione non converge debolmente.*

Teorema 3.7.7. *Sia $\{\mu_n\}_{n\in\mathbb{N}_0}$ una famiglia tight di probabilità su $\mathbb{R}$. Allora, esiste una sottosuccessione $\{n_k\}_{k\in\mathbb{N}_0}$ di $\{n\}_{n\in\mathbb{N}_0}$ tale che $\{\mu_{n_k}\}_{k\in\mathbb{N}_0}$ converge debolmente.*

3.7.2 Funzione caratteristica

Definizione 3.7.5. *Sia μ una probabilità su $\mathbb{R}^d$, si definisce funzione caratteristica di μ la funzione $\hat{\mu} : \mathbb{R}^d \to \mathbb{C}$ definita da $\hat{\mu}(\theta) = \int_{\mathbb{R}^d} e^{i<\theta,x>}\mu(dx)$*
Sia X un vettore aleatorio in $\mathbb{R}^d$, si definisce funzione caratteristica di X la funzione caratteristica della sua legge $\phi_X = \hat{\mu}_X$

Teorema 3.7.8. *La funzione caratteristica identifica le probabilità.*

Teorema 3.7.9. *Siano $X_1, ..., X_d$ variabili aleatorie reali. Allora, esse sono indipendenti se e solo se $\phi_{(X_1,...,X_d)}(\theta_1, ..., \theta_d) = \phi_{X_1}(\theta_1)...\phi_{X_d}(\theta_d)$*

Teorema 3.7.10 (Teorema di Levy)**.** *Siano $\{\mu_n\}_{n\in\mathbb{N}_0}, \mu$ probabilità su $\mathbb{R}$. Allora, $\mu_n \to \mu$ debolmente se e solo se $\hat{\mu}_n(\theta) \to \mu(\theta)$*

Esempio 3.7.3. *Sia $\mu = N(0,1)$, allora $\hat{\mu}(\theta) = e^{-\frac{\theta^2}{2}}$, in quanto $\hat{\mu}(\theta) = \int_{\mathbb{R}} e^{i\theta x}\mu(dx) = \int_{\mathbb{R}} e^{i\theta x}\frac{e^{\frac{-x^2}{2}}}{\sqrt{2\pi}}dx = e^{-\frac{\theta^2}{2}}\int_{\mathbb{R}}\frac{e^{-\frac{(x-i\theta)^2}{2}}}{\sqrt{2\pi}}dx = e^{-\frac{\theta^2}{2}}$*

Teorema 3.7.11. *Siano X una variabile aleatoria reale e $\phi_X(\theta) = E[e^{i\theta X}]$. Allora,*
(i) $\phi_X : \mathbb{R} \to \mathbb{C}$ è una funzione uniformemente continua.
(ii) Se $X \in L^1$, allora $\phi_X \in \mathscr{C}^1$ e si ha $\phi'_X(\theta) = E[iXe^{i\theta X}]$, in particolare $\phi'_X(0) = iE[X]$
(iii) Se $X \in L^2$, allora $\phi_X \in \mathscr{C}^2$ e si ha $\phi''_X(\theta) = -E[X^2e^{i\theta X}]$, in particolare $\phi''_X(0) = -E[X^2]$

Per concludere, forniamo una dimostrazione alternativa del Teorema Limite Centrale.

Teorema 3.7.12 (Teorema Limite Centrale)**.** *Siano $\{X_i\}_{i\in\mathbb{N}_0}$ variabili aleatorie IID in L^2, con $m = E[X_i] \in \mathbb{R}$ e $\sigma^2 = Var[X_i] \neq 0$, $\overline{X}_N$ la media campionaria e Z_N la sua standardizzata. Allora, $Z_N \to Z \sim N(0,1)$ debolmente.*

Proof. Basta mostrare che $\phi_{Z_N}(\theta) \to \phi_Z(\theta) = e^{-\frac{\theta^2}{2}}$. Dunque, $\phi_{Z_N}(\theta) = E[e^{i\theta Z_N}] = E[e^{i\theta\frac{X_1}{\sqrt{N}}}...e^{i\theta\frac{X_N}{\sqrt{N}}}] = \prod_{i=1}^N E[e^{i\theta\frac{X_i}{\sqrt{N}}}] = \phi_{X_1}(\frac{\theta}{\sqrt{N}})^N$
Ma $X_1 \in L^2$, dunque $\phi_{X_1} \in \mathscr{C}^2$ e posso applicare lo sviluppo di Taylor $\phi_{X_1}(\frac{\theta}{\sqrt{N}}) = \phi_{X_1}(0) + \phi'_{X_1}(0)\frac{\theta}{\sqrt{N}} + \frac{1}{2}\phi''_{X_1}(0)(\frac{\theta}{\sqrt{N}})^2 + o((\frac{\theta}{\sqrt{N}})^2) = 1 - -\frac{1}{2}\frac{\theta^2}{N} + o(\frac{1}{N})$
Concludiamo che $\phi_{Z_N}(\theta) = \phi_{X_1}(\frac{\theta}{\sqrt{N}})^N = [1 - \frac{\theta^2}{2N} + o(\frac{1}{N})]^N \to e^{-\frac{\theta^2}{2}}$ □

4 Catene di Markov

4.1 Processi Stocastici

Definizione 4.1.1. *Si definisce processo stocastico una famiglia* $X = \{X_t\}_{t\in\Pi}$ *di variabili aleatorie definite sullo stesso spazio di probabilità e a valori nello stesso spazio misurabile.*
Lo spazio di arrivo si chiama spazio degli stati.
Tipicamente sono o a tempo discreto ($\Pi = \mathbb{N}_0$ *o* $\Pi = \mathbb{N}$*) o a tempo continuo (*$\Pi = [0, \infty)$*).*

Un processo stocastico è il modello matematico che descrive una successione casuale di elementi di E. Può essere pensato come un'unica variabile aleatoria a valori in $E^{\mathbb{N}} = \bigtimes_{n\in\mathbb{N}} E = \{x = (x_n)_{n\in\mathbb{N}} \mid x_n \in E\}$

Definizione 4.1.2. *Dato un processo stocastico, si chiama legge del processo la legge* μ_X *dell'intera successione, che è una probabilità sullo spazio delle traiettorie* $(E^{\mathbb{N}}, \mathscr{E}^{\otimes\mathbb{N}})$
Si chiamano leggi finito-dimensionali le leggi $\mu_{(X_0,...,X_k)}$ *dei vettori* $(X_0, ..., X_k)$ *per* $k \in \mathbb{N}$.

Teorema 4.1.1. *Le leggi finito-dimensionali determinano la legge di un processo stocastico.*

Proof. Sia $C_{A_0,...,A_k} \in \mathscr{C}$, si ha $\mu_X(C_{A_0,...,A_k}) = p(X \in C_{A_0,...,A_k}) = p(X_0 \in A_0, ..., X_k \in A_k) = p((X_0, ..., X_k) \in A_0 \times ... \times A_k) = \mu_{(X_0,...,X_k)}(A_0 \times ... \times A_k)$
Dato che $\mathscr{C}$ è una base delle σ-algebra, la legge μ_X è determinata dalle singole leggi finito-dimensionali. □

Se lo spazio degli stati è finito o numerabile, anche $E^{\otimes(k+1)}$ è finito o numerabile e le leggi finito-dimensionali sono determinate dalle rispettive densità discrete.

4.2 Catene di Markov

Definizione 4.2.1. *Si definisce catena di Markov un processo stocastico* $X = \{X_n\}_{n\in\mathbb{N}}$ *tale per cui:*
(i) E *è al più numerabile.*
(ii) Esiste una funzione $q : E \times E \to \mathbb{R}$ *tale che* $p(X_{n+1} = y|X_n = x, ..., X_0 = x_0) = p(X_{n+1} = y|X_n = x) = q(x, y)$ $\forall n \in \mathbb{N}, \forall x_0, ..., x_{n-1}, x, y \in E$

Intuitivamente, è un moto casuale in un insieme al più numerabile con la proprietà di assenza di memoria.

Esempio 4.2.1. *Sia* $P \in (0,1)$ *e consideriamo* $X = \{X_n\}_{n\in\mathbb{N}}$ *a valori in* $\mathbb{Z}$ *tale che* $X_{n+1} = \begin{cases} X_n + 1, \text{con probabilità } P \\ X_n - 1, \text{con probabilità } 1-P \end{cases}$ *e* $X_0 = 0$. *Per definirlo formalmente, siano* $\{Y_n\}_{n\in\mathbb{N}_0}$ *variabili aleatorie IID di tipo* $Be(P)$, *cioè* $p(Y_n = 1) = P$ *e* $p(Y_n = 0) = 1 - P$, *allora definiamo il processo come* $\begin{cases} X_0 = 0 \\ X_{n+1} = X_n + (2Y_{n+1} - 1) \end{cases}$, *allora* $X_n = \sum_{k=1}^{n} (2Y_k - 1)$

Esempio 4.2.2. *Consideriamo un re che vaga su una scacchiera* $E = \{a, ..., h\} \times \{1, ..., 8\}$. *Sia* $X = \{X_n\}_{n\in\mathbb{N}}$ *a valori in* E *e fissiamo una casella* $x_0 \in E$ *e poniamo* $X_0 = x_0$. *Se* $X_n = x$, *allora* $X_{n+1} = y$, *dove* y *è scelta uniformemente tra le caselle adiacenti a* x.

Definizione 4.2.2. *Sia* X *una catena di Markov.*
Diremo che $Q = (q(x,y))_{x,y\in E}$ *è la matrice di transizione della catena di Markov e scriveremo* $X = \{X_n\}_{n\in\mathbb{N}} \sim Markov(Q)$
Diremo che $\lambda = \{\lambda(x) = p(X_0 = x)\}_{x\in E}$ *è la distribuzione iniziale della catena di Markov e scriveremo* $X = \{X_n\}_{n\in\mathbb{N}} \sim Markov(Q, \lambda)$

Si può pensare a Q come una matrice indicizzata dagli elementi di E. Da ciò segue che $q(x,y) \geqslant 0 \ \forall x, y \in E$ e $\sum_{y\in E} q(x,y) = 1 \ \forall x \in E$

Definizione 4.2.3. *Sia* E *un insieme al più numerabile. Si definisce matrice stocastica su* E *ogni funzione* $q : E \times E \to \mathbb{R}$ *tale che:*
(i) $q(x,y) \geqslant 0 \ \forall x, y \in E$
(ii) $\sum_{y\in E} q(x,y) = 1 \ \forall x \in E$
Chiameremo, con abuso di notazione, probabilità o distribuzioni su E *le densità discrete con quelle proprietà.*

Nel senso precedente, la distribuzione iniziale di una catena di Markov è una distribuzione su E.

Teorema 4.2.1. *La distribuzione iniziale* $\lambda = \{\lambda(x)\}_{x\in E}$ *e la matrice di transizione* $Q = \{q(x,y)\}_{x,y\in E}$ *determinano le leggi finito-dimensionali di una catena di Markov.*
Infatti, $X \sim Markov(Q, \lambda) \iff p(X_0 = x_0, ..., X_n = x_n)\lambda(x_0)q(x_0, x_1)...q(x_{n-1}, x_n) \ \forall n \in \mathbb{N}, \forall x_0, ..., x_n \in E$

Proof. ($\Longrightarrow$) Si ha $p(X_0 = x_0, ..., X_n = x_n) = p(X_0 = x_0)p(X_1 = x_1|X_0 = x_0)...p(X_n = x_n|X_0, ..., X_{n-1} = x_{n-1})$
($\Longleftarrow$) Si ha $p(X_{n+1} = y|X_n = x, ..., X_0 = x_0) = \frac{p(X_0=x_0,...,X_n=x,X_{n+1}=y)}{p(X_0=x_=,...,X_{n-1}=x_{n-1},X_n=x)} = \frac{\lambda(x_0)q(x_0,x_1)....q(x_{n-1},x)q(x,y)}{\lambda(x_0)q(x_0,x_1)....q(x_{n-1},x)} = q(x,y)$ □

Esempio 4.2.3. *Riprendendo il re che vaga sulla scacchiera, definendo* $x \sim y$ *se e solo se* x *e* y *sono 'vicine' nelle* 8 *direzioni, si ha* $q(x,y) = \begin{cases} \frac{1}{3}, x \in giallo, y \sim x \\ \frac{1}{5}, x \in verde, y \sim x \\ \frac{1}{8}, x \in viola, y \sim x \\ 0, y \nsim x \end{cases}$

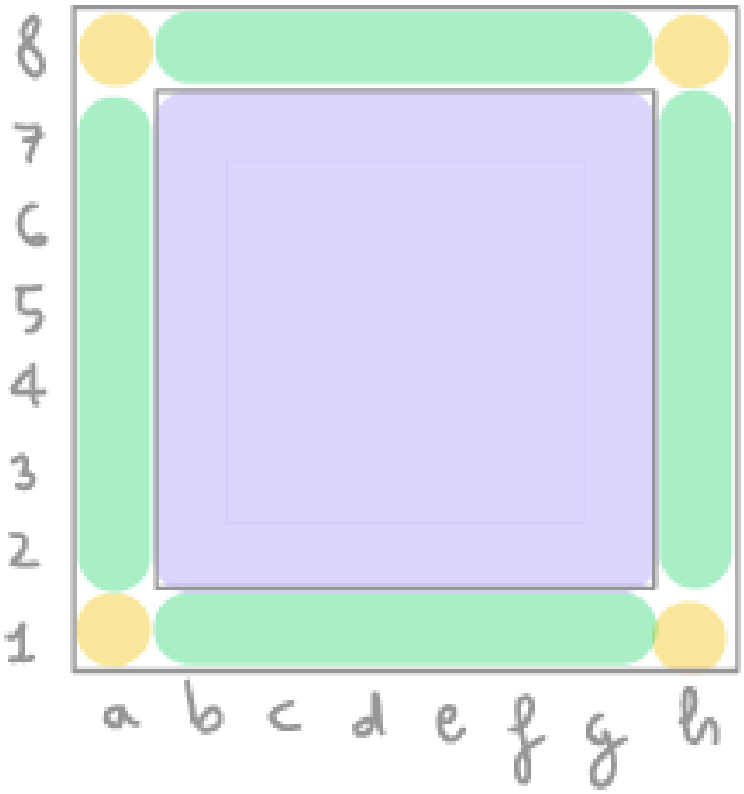


Figure 1: Esempio: Re sulla scacchiera

Esempio 4.2.4. *Riprendendo la passeggiata aleatoria su* $\mathbb{Z}$*, si ha* $q(x,y) =$

$\begin{cases} P,\ y = x+1 \\ 1-P,\ y = x-1 \\ 0,\ y \notin \{x \pm 1\} \end{cases}$. *Dunque,* $X \sim Markov(Q,\lambda) \iff \lambda(x) = p(X_0 = x), Q = (q(x,y))_{x,y\in E}$ $q(x,y) = p(X_{n+1} = y | X_n = x) \iff p(X_0 = x_0, ..., X_n = x_n) = \lambda(x_0)q(x_0,x_1)...q(x_{n-1},x_n)$

Definizione 4.2.4. *Scriveremo p_λ per riferirsi a una catena di Markov con distribuzione iniziale λ.*
Se $\lambda = \delta_{\bar{x}}$, con $\bar{x} \in E$, si ha $\lambda(x) = \delta_{x\bar{x}}$. In questo caso, scriveremo $p_{\bar{x}}$ invece di $p_{\delta_{\bar{x}}}$

Teorema 4.2.2. *Valgono le seguenti proprietà:*
(i) $p_{\bar{x}}(X_1 = x_1, ..., X_n = x_n) = q(\bar{x}, x_1)q(x_1,x_2)...q(x_{n-1},x_n)$
(ii) $p_{\bar{x}}(...) = p_\lambda(...|X_0 = \bar{x})$
(iii) $p_\lambda(...) = \sum_{x_0\in E} \lambda(x_0)p_{x_0}(...) = \sum_{x_0\in E} p_\lambda(...|X_0 = x_0)p(X_0 = x_0)$

Definizione 4.2.5. *Siano $Q = \{q(x,y)\}_{x,y\in E}, R = \{r(x,y)\}_{x,y\in E}$ "matrici" e $v = \{v(x)\}_{x\in E}$ "vettore". Allora, definiamo Qv ponendo $(Qv)(x) = \sum_{y\in E} q(x,y)v(y)$, v^tQ ponendo $(v^tQ)(z) = \sum_{x\in E} v(x)q(x,z)$ e QR ponendo $(QR)(x,z) = \sum_{y\in E} q(x,y)r(y,z)$.*
Definiamo inoltre $Q^0 = I$, ovvero $Q^0(x,y) = \delta_{xy}$, e $Q^n = Q^{n-1}Q$

Teorema 4.2.3. *Sia $X \sim Markov(Q)$, allora $p_x(X_n = y) = (Q^n)(x,y)$ $\forall x,y \in E$. Più in generale, per ogni distribuzione iniziale λ si ha $p_\lambda(X_n = y) = (\lambda^t Q^n)(y)$ $\forall y \in E$*

Proof. Notiamo che $\{X_n = y\} = \bigcup_{x_1,...,x_{n-1}\in E} \{X_1 = x_1, ..., X_n = y\}$, dunque
$p_x(X_n = y) = \sum_{x_1,...,x_{n-1}\in E} p_x(X_1 = x_1, ..., X_n = y) = \sum_{x_1,...,x_{n-1}\in E} q(x,x_1)...q(x_{n-1},y) = \sum_{x_0,...,x_n\in E \mid x_0=x_1, x_n=y} q(x_0,x_1)...q(x_{n-1},x_n) = (Q^n)(x,y)$
La seconda segue dalla prima, in quanto $p_\lambda(X_n = y) = \sum_{x\in E} \lambda(x)p_x(X_n = y) = (\lambda^t Q^n)(y)$ □

Esempio 4.2.5. *Alessia fa quotidianamente il tragitto casa ↔ lavoro. In ogni tragitto, Alessia prende l'ombrello solo se piove e se l'ombrello si trova nel posto in cui si trova Alessia. Inizialmente, Alessia ha l'ombrello ($n = 0$). Supponiamo che in ogni tragitto sia fissata la probabilità P che piova, indipendente dagli altri tragitti. Vogliamo sapere la probabilità che, dopo n*

tragitti, Alessia si trovi a dover fare il prossimo tragitto sotto la pioggia e senza ombrello. Definiamo $X_n = \begin{cases} 1, \text{ Alessia ha ombrello} \\ 0, \text{ Alessia non ha ombrello} \end{cases}$, *allora* $\{X_n\}_{n\in\mathbb{N}}$ *è una catena di Markov su* $E = \{0,1\}$ *e per costruzione* $X_0 = 1$ *con* $\lambda = \delta_1$. *Allora,* $Q = \begin{pmatrix} q(0,0) & q(0,1) \\ q(1,0) & q(1,1) \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 1-P & P \end{pmatrix}$, *dunque* $Q^n = \frac{1}{2-P}\begin{pmatrix} 1-P+(P-1)^n & 1-(P-1)^n \\ 1-P+(P-1)^{n+1} & 1-(P-1)^{n+1} \end{pmatrix}$. *Calcolando* $p_1(X_n = 1) = Q^n(1,1) = \frac{1-(P-1)^{n+1}}{2-P} \to \frac{1}{2-P} > \frac{1}{2}$, *concludiamo che* $p_1(X_n = 0) = 1 - p_1(X_n = 1) \to 1 - \frac{1}{2-P} = \frac{1-P}{2-P}$

Teorema 4.2.4 (Teorema di esistenza della catena di Markov)**.** *Siano* E *insieme al più numerabile,* Q *matrice stocastica su* E *e* $\lambda = \{\lambda(x)\}_{x\in E}$ *probabilità su* E. *Allora, esiste uno spazio di probabilità su cui è definito un processo stocastico* $X = \{X_n\}_{n\in\mathbb{N}} \sim Markov(Q,\lambda)$

Teorema 4.2.5. *Sia* $X \sim Markov(Q)$ *su* E *e definiamo le abbreviazioni* $X_0^n = (X_0,...,X_n)$ *e* $X_n^\infty = (X_n,...)$. *Allora, per ogni* $A \subseteq E^{n+1}, B \subseteq E^{\mathbb{N}}$ *misurabili, si ha:*
(i) $p(X_n^\infty \in B | X_n = x, X_0^n \in A) = p_x(X_0^\infty \in B)$
(ii) $p(X_0^n \in A, X_n^\infty \in B | X_n = x) = p(X_0^n \in A | X_n = x)p(X_n^\infty \in B | X_n = x)$.
(iii) $p(X_n^\infty \in B | X_n = x) = p_x(X_0^\infty \in B)$

Proof. Mostriamo che $p(X_0^n \in A, X_n = x, X_n^\infty \in B) = p(X_0^n \in A, X_n = x)p_x(X_0^\infty \in B)$, in quanto:
(i) Segue dividendo per $p(X_0^n \in A, X_n = x)$
(ii) Si ottiene dividendo per $p(X_n = x)$
(iii) Deriva scegliendo $A = E^{n+1}$ in (i)
Scegliamo dunque $A = \{(x_0,...,x_n)\}$, $B = \{(y_n,...,y_{n+k})\}$ e assumiamo $x_n = x = y_n$. Allora, $p(X_0^n \in A, X_n = x, X_n^\infty \in B) = p(X_0^n = x_0^n, X_n = x, X_n^k = y_n^{n+k}) = p(X_0 = x_=,...,X_{n-1} = x_{n-1}, X_n = x, X_{n+1} = y_{n+1},...,X_{n+k} = y_{n+k}) = [\lambda(x_0)q(x_0,x_1)...q(x_{n-1},x)][q(x,y_{n+1})...q(y_{n+k-1},y_{n+k})] = p(X_0 = x_0,...,X_{n-1} = x_{n-1}, X_n = x)p_x(X_1 = y_{n+1},...,X_k = y_{n+k}) = p(X_0^n \in A, X_n = x)p_x(X_0^\infty \in B)$ □

Definizione 4.2.6. *Dati* $x,y \in E$, *diciamo che "y è accessibile da x" (o "x conduce a y"), e scriveremo* $x \rightsquigarrow y$, *se e solo se* $Q^n(x,y) > 0$ *per qualche* $n \in \mathbb{N}$

Teorema 4.2.6 (Lemma)**.** *Si ha $x \rightsquigarrow y$ se e solo se esiste $n \in \mathbb{N}$ per cui esiste un cammino di n passi $x_0, ..., x_n \in E$ che conduce da $x_0 = x$ a $x_n = y$ tale che ogni passo ha probabilità non nulla.*

Teorema 4.2.7. *La relazione di accessibilità è transitiva ma non simmetrica.*

Definizione 4.2.7. *Dati $x, y \in E$, diciamo che "x e y comunicano" se e solo se $x \rightsquigarrow y$ e $y \rightsquigarrow x$, e scriveremo $x \leftrightsquigarrow y$. Se accade per ogni $x, y \in E$, diremo che la catena di Markov è irriducibile.*

Esempio 4.2.6. *La passeggiata aleatoria semplice su $\mathbb{Z}$, il re che vaga sulla scacchiera e l'ombrello sono tutte catene di Markov irriducibili.*

4.3 Misure Invarianti

Definizione 4.3.1. *Sia E al più numerabile, chiamiamo "misura" ogni vettore $\mu = \{\mu(x)\}_{x \in E}$ tale che $\mu(x) \geqslant 0$.*

Teorema 4.3.1. *Una misura μ è una probabilità se e solo se $\sum_{x \in E} \mu(x) = 1$*

Definizione 4.3.2. *Una misura μ si dice stazionaria o invariante se e solo se $\mu^t = \mu^t Q$, cioè $\mu(y) = \sum_{x \in E} \mu(x) q(x, y)\ \forall y \in E$*
Una misura μ si dice reversibile se e solo se $\mu(x)q(x, y) = \mu(y)q(y, x)\ \forall x, y \in E$

Teorema 4.3.2. *Ogni misura reversibile è invariante.*

Notiamo che $\mu^t Q = \mu^t$ se e solo se $Q^t \mu = \mu$ cioè se e solo se μ è autovettore di Q^t di autovalore 1, ovvero se e solo se μ^t è autovettore sinistro di Q di autovalore 1.
Notiamo inoltre che $\sum_{y \in E} q(x, y) = 1$ se e solo se $Q1 = 1$, dove 1 è il vettore unitario.

Teorema 4.3.3. *Sia E insieme finito e supponiamo che esistano i limiti $\lim_{n \to \infty} p(X_n = y) = \mu(y)\ \forall y \in E$. Allora, $\mu = \{\mu(y)\}_{y \in E}$ è una probabilità invariante.*

Proof. (Probabilità) μ è una probabilità perché $\mu(y) \geqslant 0\ \forall y \in E$ e $\sum_{y \in E} \mu(y) = \sum_{y \in E} \lim_{n \to \infty} p(X_n = y) = \lim_{n \to \infty} \sum_{y \in E} p(X_n = y) = 1$

(Invariante) Usiamo la formula delle probabilità totali e le proprietà delle catene di Markov $p(X_{n+1}=y)=\sum_{x\in E}p(X_n=x)p(X_{n+1}=y|X_n=x) \iff p(X_{n+1}=y)=\sum_{x\in E}p(X_n=x)q(x,y) \iff \lim_{n\to\infty}p(X_{n+1}=y)=\lim_{n\to\infty}\sum_{x\in E}p(X_n=x)q(x,y) \iff \mu(y)=\sum_{x\in E}\mu(x)q(x,y)$ □

Teorema 4.3.4. *Sia $\Pi=\{\Pi(x)\}_{x\in E}$ una probabilità invariante. Scegliendo $X\sim Markov(Q,\Pi)$, si ha $X_n=^d X_0=^d \Pi$ per ogni $n\in\mathbb{N}$, cioè $p_\Pi(X_n=y)=p_\Pi(X_0=y)=\Pi(y)\ \forall y\in E$*

Proof. $p_\Pi(X_n=y)=(\Pi^tQ^n)(y)=\Pi^t(y)=\Pi(y)$. Dato che Π è invariante, $\Pi^t=\Pi^tQ$, dunque $\Pi^t=\Pi^tQ^2$ e di conseguenza $\Pi^t=\Pi^tQ^n$ per ogni $n\in\mathbb{N}$ □

Teorema 4.3.5. *Sia $\Pi=\{\Pi(x)\}_{x\in E}$ una probabilità reversibile. Scegliendo $X\sim Markov(Q,\Pi)$, si ha $(X_0,...,X_n)=^d(X_n,X_{n-1},...,X_0)$ per ogni $n\in\mathbb{N}$, ovvero $p_\Pi(X_0=x_0,...,X_n=x_n)=p_\Pi(X_0=x_n,...,X_n=x_0)\ \forall x_0,...,x_n\in E$*

Proof. $p_\Pi(X_0=x_=,...,X_n=x_n)=\Pi(x_0)q(x_0,x_1)...q(x_{n-1},x_n)=$
$=q(x_1,x_0)\Pi(x_1)q(x_1,x_2)...q(x_{n-1},x_n)=q(x_1,x_0)q(x_2,x_1)....q(x_n,x_{n-1})\Pi(x_n)=$
$\Pi(x_n)q(x_n,x_{n-1})...q(x_1,x_0)=p(X_0=x_n,...,X_n=x_0)$ □

Esempio 4.3.1. *Troviamo una probabilità invariante nel caso dell'ombrello* $Q=\begin{pmatrix}0 & 1\\ 1-P & P\end{pmatrix}$ *e sia* $\Pi=\begin{pmatrix}\Pi(0)\\ \Pi(1)\end{pmatrix}$, *allora* $\Pi^t=\Pi^tQ \iff \begin{cases}\Pi(0)=0\Pi(0)+(1-P)\Pi(1)\\ \Pi(1)=\Pi(0)+P\Pi(1)\end{cases} \iff$
$\Pi=\begin{pmatrix}\frac{1-P}{2-P}\\ \frac{1}{2-P}\end{pmatrix}$, *che notiamo coincidere con la probabilità calcolata.*

Esempio 4.3.2. *Riprendendo il passeggio aleatorio semplice su $\mathbb{Z}$. Per $P=\frac{1}{2}$, $\mu=1$ è una misura invariante (l'unica!), mentre per $P\neq\frac{1}{2}$ esiste una misura invariante distinta, data da $\lambda=(\lambda(x)=\{\frac{P}{1-P})^x\}_{x\in E=\mathbb{Z}}$. Infatti,* $\sum_{x\in E}\lambda(x)q(x,y)=\lambda(y-1)q(y-1,y)+\lambda(y+1)q(y+1,y)=(\frac{P}{1-P})^{y-1}P+$
$(\frac{P}{1-P})^{y+1}(1-P)=\frac{P^y}{(1-P)^{y-1}}+\frac{P^{y+1}}{(1-P)^y}=\frac{P^y}{(1-P)^y}[(1-P)+P]=\frac{P^y}{(1-P)^y}=\lambda(y)$

Definizione 4.3.3. *Un grafo (non orientato) è una coppia $G=(E,A)$, dove E è un insieme non vuoto e A è una relazione simmetrica su E.*
Gli elementi di A sono detti archi.

Definizione 4.3.4. *Il grado di un vertice di un grafo (E,A) è $deg(x)=\#\{y\in E\mid y\sim x\}\in(0,\infty)$*

Possiamo definire una matrice stocastica per un grafo come $q(x,y) = \begin{cases} \frac{1}{deg(x)}, & y \sim x \\ 0, & altrimenti \end{cases}$ e notiamo che $\sum_{y \in E} q(x,y) = \frac{1}{deg(x)} \sum_{y \in E} \chi_{\{y \sim x\}} = \frac{deg(x)}{deg(x)} = 1$

Definizione 4.3.5. *La catena di Markov su E è detta passeggiata aleatoria su $G = (E, A)$*

Esempio 4.3.3. *Il re sulla scacchiera è la passeggiata aleatoria sul grafo $G = (E, A)$, dove E è la scacchiera e $A = \{\{x, y\} \mid x \rightsquigarrow y$ è una mossa ammissibile per il re, cioè x e y sono adiacenti$\}$*

Definizione 4.3.6. *Siano $G = (E, A)$ un grafo e $X = \{X_n\}_{n \in \mathbb{N}}$ una passeggiata aleatoria con matrice di transizione $q(x,y) = \begin{cases} \frac{1}{deg(x)}, & y \sim x \\ 0, & y \not\sim x \end{cases}$. Allora, G è connesso se e solo se per ogni $x, y \in E$ esiste $n \in \mathbb{N}$ con $x_0 = x, x_n = y$ tale che $x_{i-1} \sim x_i$. Equivalentemente, X è connesso se e solo se X è irriducibile.*

Teorema 4.3.6 (Lemma)**.** *$\mu = \{\mu(x) = deg(x)\}_{x \in E}$ è una misura reversibile (e dunque invariante) per la passeggiata aleatoria sul grafo.*

Proof. Siano $x, y \in E$, dobbiamo verificare che $\mu(x)q(x,y) = \mu(y)q(y,x)$. Se $x \not\sim y$, allora $q(x,y) = q(y,x) = 0$, dunque è verificata. Altrimenti, $q(x,y) = \frac{1}{deg(x)}$ e $q(y,x) = \frac{1}{deg(y)}$, dunque $\mu(x)q(x,y) = 1 = \mu(y)q(y,x)$ □

Corollario 4.3.6.1. *Se $|E| < \infty$, allora una probabilità invariante è $\Pi = \{\Pi(x) = \frac{deg(x)}{D}\}_{x \in E}$, dove $D = \sum_{x \in E} deg(x) = (2\|A\|)$*

Teorema 4.3.7. *Se $\lambda = \{\lambda(x)\}_{x \in E}$ è una misura invariante, allora anche $c\lambda = \{c\lambda(x)\}_{x \in E}$ è invariante. In particolare, se λ ha massa finita ($\Lambda = \sum_{x \in E} \lambda(x) < \infty$), allora scegliendo $c = \frac{1}{\Lambda}$ otteniamo una probabilità invariante.*

Definizione 4.3.7. *Dato $x \in E$, si dice periodo di x la quantità $t_x = gcd\{n \in \mathbb{N}_0 \mid Q^n(x,x) > 0\}$*

Teorema 4.3.8 (Lemma)**.** *Se $x \leftrightsquigarrow y$, allora $t_x = t_y$. In particolare, in una catena di Markov irriducibile, tutti gli stati hanno lo stesso periodo $t = t_x$, detto periodo della catena. Nel caso $t = 1$, la catena si dice aperiodica.*

Teorema 4.3.9 (Teorema di convergenza all'equilibrio). *Sia $X = \{X_n\}_{n\in\mathbb{N}}$ irriducibile su E e assumiamo che esista una probabilità invariante $\Pi = \{\Pi(x)\}_{x\in E}$. Allora, essa è unica e vale:*
(i) Se la catena è aperiodica, per ogni distribuzione iniziale λ si ha $p_\lambda(X_n = y) \to \Pi(y)\ \forall y \in E$
(ii) Se la catena ha periodo $t \in \mathbb{N}$ (con $t \geqslant 2$), allora per ogni $x, y \in E$ esiste $a_{xy} \in \{0, ..., t-1\}$ (con $a_{xx} = 0$) tale che $p_x(X_n = y) = Q^n(x, y) \to t\Pi(y)$ per ogni $x, y \in E$, con $n = a_{xy} + tk$ e $k \to \infty$

Esempio 4.3.4. *Riprendendo l'esempio del re sulla scacchiera, si ha $deg(x) = \begin{cases} 3, & x \in giallo \\ 5, & x \in verde \\ 8, & x \in viola \end{cases}$, dunque $D = \sum_{x\in E} deg(x) = 3\cdot 4 + 5\cdot 24 + 8\cdot 36 = 420$, dunque la probabilità invariante è $\Pi(x) = \frac{deg(x)}{\Lambda} = \begin{cases} \frac{3}{420} = \frac{1}{140}, & x \in giallo \\ \frac{5}{420} = \frac{1}{84}, & x \in verde \\ \frac{8}{420} = \frac{1}{52.5}, & x \in viola \end{cases}$*
La catena è aperiodica, infatti se $x \in viola$, allora $\{n \in \mathbb{N} \mid Q^n(x, x) = p(X_n = x | X_0 = 0) > 0\} \supseteq \{2, 3\}$, dunque $t_x = 1$. Per il teorema di convergenza, si ha che $p(X_n = y) \to \Pi(y)\ \forall y \in E$

4.4 Tempi di Ritorno

Definizione 4.4.1. *Dato uno stato $x \in E$, definiamo il tempo di ritorno come $T_x(\omega) = \min\{n \in \mathbb{N} \mid X_n(\omega) = x\} \in \overline{\mathbb{N}}$*

Dato che X è un processo stocastico, segue che T_x è una variabile aleatoria definita sul medesimo spazio.

Definizione 4.4.2. *Dato uno stato $x \in E$, esso si dice:*
- Transitorio, se $p_x(T_x < \infty) < 1$
- Ricorrente, se $p_x(T_x < \infty) = 1$
Uno stato x ricorrente si dice:
- Nullo, se $E_x[T_x] = \infty$
- Positivo, se $E_x[T_x] < \infty$

Teorema 4.4.1 (Lemma). *Se $x \leftrightsquigarrow y$, allora x e y sono dello stesso tipo.*

Definiamo per $x \in E$ la variabile aleatoria $N_x = \#\{n \in \mathbb{N} \mid X_n = x\} = \sum_{n\in\mathbb{N}} \chi_{\{X_n = x\}}$

Teorema 4.4.2. *Per ogni $x \in E$, si ha $p_x(N_x > k) = p_x(T_x < \infty)^k \ \forall k \in \mathbb{N}$. Di conseguenza, se $X_0 = x$ allora:*
(i) x è ricorrente se e solo se $N_x = \infty$ quasi-ovunque per p_x se e solo se $E_x[N_x] = \infty$
(ii) x è transitorio se e solo se $N_x < \infty$ quasi-ovunque per p_x se e solo se $E_x[N_x] < \infty$

Proof. Sappiamo che $\{N_k > k\} = \{\exists n_1, ..., n_k \in \mathbb{N}_0 \mid X_{n_1} = x, ..., X_{n_k} = x, X_m \neq x \ \forall m \in \{1, ..., n_1 - 1\} \cup \{n_1 + 1, ..., n_2 - 1\} \cup ... \cup \{n_{k-1} + 1, ..., n_k - 1\}\} = \{1, ..., n_k\} \backslash \{n_1, ..., n_k\}$ Da ciò segue che $p_x(N_x > k) = \sum_{n_1 < ... < n_k} p_x(T_1 = n_1) p_x(T_1 = n_2 - n_1) ... p_x(T_1 = n_k - n_{k-1})$, facciamo un cambio di variabili $m_i = n_i - n_{i-1}$ con $n_0 = 0$ e si ha $p_x(N_x > k) = \sum_{m_1, ..., m_k \in \mathbb{N}_0} p_x(T_1 = m_1) ... p_x(T_1 = m_k) = (\sum_{m_1 \in \mathbb{N}_0} p_x(T_1 = m_1))(\sum_{m_2 \in \mathbb{N}_0} p_x(T_1 = m_2)) ... (\sum_{m_k \in \mathbb{N}_0} p_x(T_1 = m_k)) = (\sum_{m \in \mathbb{N}_0} p_x(T_1 = m))^k = p_x(T_1 \in \mathbb{N}_0)^k = p_x(T_1 < \infty)^k$
Giustifichiamo il primo uguale nel caso $k = 2$, $p_x(X_{n_1} = x, X_{n_2} = x, X_m \neq x \ \forall m \in \{1, ..., n_1 - 1\} \cup \{n_1 + 1, ..., n_2 - 1\}) = p_x(A \cap B) = p_x(A) p_x(B|A)$, con $A = \{X_1 \neq x, ..., X_{n_1 - 1} \neq x, X_{n_1} = x\}$ e $B = \{X_{n_1 + 1} \neq x, ..., X_{n_2 - 1} \neq x, X_{n_2} = x\}$. Ma $p_x(A) = p_x(T_x = n_1)$ e $p_x(B|A) = p_x(T_x = n_2 - n_1)$
(i) Sia x ricorrente, allora $p_x(N_x > k) = 1^k = 1$, dunque $p(N_x = \infty) = \lim_{k \to \infty} p(N_k > k) = 1$, ma $\{N_x = \infty\} = \bigcap_{k \in \mathbb{N}_0} \{N_x > k\}$ e per continuità dall'alto si ha $E_x[N_x] = \infty$
(ii) Sia x transitorio, allora $p_x(N_x > k) = (1 - p_x)^k$, ovvero la variabile N_x è di tipo $Geo(p_x)$ rispetto a p_x, infatti $p_x(N_x = k) = p_x(N_x > k - 1) - p_x(N_x > k) = (1 - p_x)^{k-1} - (1 - p_x)^k = [1 - (1 - p_x)](1 - p_x)^{k-1} = p_x(1 - p_x)^{k-1}$. Da ciò, segue che $p_x(N_x < \infty) = 1$ e $E_x[N_x] = \frac{1}{p_x} < \infty$ □

Con poche modifiche si mostra che $p_z(N_x > k) = p_z(T_x < \infty) p_x(T_x < \infty)^k \ \forall z \neq x, \forall k \in \mathbb{N}$, ovvero x transitorio implica $N_x < \infty$ quasi-ovunque per p_z per ogni $z \in E$ e dunque $E_z[N_x] < \infty$ per ogni $z \in E$.

Corollario 4.4.2.1. *Sia x uno stato transitorio, allora per ogni distribuzione iniziale λ si ha $p_\lambda(X_n = x) \to 0$*

Proof. $p_\lambda(X_n = x) = (\lambda^t Q^n)(x) = \sum_{z \in E} \lambda(z) Q^n(z, x)$. Dando per assunto $Q^n(z, x) \to 0$, si ha per convergenza dominata che $\lim_{n \to \infty} p_\lambda(X_n = x) = \sum_{z \in E} \lim_{n \to \infty} \lambda(z) Q^n(z, x) = 0$. Mostriamo infine che $Q^n(z, x) \to 0$ osservando che $Q^n(z, x) = p_z(X_n = x)$, dunque $\sum_{n=0}^{\infty} Q^n(z, x) = \sum_{n=0}^{\infty} p_z(X_n = x) = E_z[\sum_{n=0}^{\infty} \chi_{\{X_n = x\}}] < \infty$, dunque $Q^n(z, x) \to 0$ □

Corollario 4.4.2.2. *Sia $\Pi = \{\Pi(x)\}_{x\in E}$ una probabilità invariante. Allora, $\Pi(x) = 0$ per ogni stato transitorio x.*

Proof. Per il corollario precedente, se x è transitorio, allora $p_\Pi(X_n = x) \to 0$, am $p_\Pi(X_n = x) = \Pi(x)\ \forall n \in \mathbb{N}$ perché Π è invariante, dunque $\Pi(x) = 0$ □

Esempio 4.4.1. *Riprendiamo la passeggiata aleatoria semplice su $\mathbb{Z}$, mostriamo che X è ricorrente se $p = \frac{1}{2}$ e transitoria altrimenti. Si ha che $E_x[N_x] = \sum_{n=0}^{\infty} E_x[\chi_{\{X_n=x\}}] = \sum_{n=0}^{\infty} p_x(X_n = x)$, dunque calcoliamo $p_x(X_n = x)$. Per simmetria, sia $x = 0$ e osserviamo che $p_0(X_n = 0) = 0\ \forall n$ dispari. Sia dunque $n = 2k$, possiamo scrivere $X_n = (2Y_1 - 1) + (2Y_2 - 1) + ... + (2Y_n) - 1$, dove $\{Y_i\}_{i\in\mathbb{N}_0}$ sono variabili aleatorie IID di tipo $Be(P)$, allora $X_n = 2(Y_1 + ... + Y_n) - n$. Dunque, $p(X_{2k} = 0) = p(2S_{2k} - 2k = 0) = p(S_{2k} = k)$, ma $p(S_n = k) = \binom{n}{k} P^k(1-P)^{n-k}$, quindi $p(X_{2k} = 0) = \binom{2k}{k} P^k(1-P)^{2k-k} = \binom{2k}{k}[P(1-P)]^k \approx \frac{2^{2k}}{\sqrt{\pi k}}[P(1-P)]^k = \frac{[4P(1-P)]^k}{\sqrt{\pi}\sqrt{k}}$*

Dunque, se $p \neq \frac{1}{2}$, $4P(1-P) < 1$ e $\sum_{k=1}^{\infty} \frac{[4P(1-P)]^k}{\sqrt{\pi k}} \leqslant \sum_{k=1}^{\infty}[4p(1-p)]^k < \infty$; altrimenti, $4P(1-P) = 1$, dunque $\sum_{k=1}^{\infty} \frac{[4P(1-P)]^k}{\sqrt{\pi}\sqrt{k}} = \sum_{k=1}^{\infty} \frac{1}{\sqrt{\pi}\sqrt{k}} = \infty$

Quindi, $\sum_{k=1}^{\infty} p(X_{2k} = 0) \begin{cases} < \infty,\ p \neq \frac{1}{2} \\ = \infty,\ p = \frac{1}{2} \end{cases}$

Teorema 4.4.3. *Sia $X = \{X_n\}_{n\in\mathbb{N}}$ irriducibile e ricorrente (tutti gli stati lo sono). Allora, la misura $\lambda_x = \{\lambda_x(y)\}_{y\in E}$, definita come $\lambda_x(y) = E_x[\sum_{n=1}^{T_x} \chi_{\{X_n=y\}}]$ per ogni $x \in E$, è invariante e soddisfa $\lambda_x(x) = 1$ e $\sum_{y\in E} \lambda_x(y) = E_x[T_x]$*
Inoltre, se $\rho = \{\rho(y)\}_{y\in E}$ è una misura invariante tale che $\rho(x) = 1$ per qualche $x \in E$, allora $\rho = \lambda_x$

Teorema 4.4.4 (Lemma)**.** *Sia $\mu = \{\mu(y)\}_{y\in E}$ con $0 \leqslant \mu(y) \leqslant \infty$ per ogni $y \in E$ tale che $\mu^t = \mu^t Q$, con Q matrice di transizione di una catena di Markov irriducibile. Allora deve essere o $\mu = 0$ o $\mu = \infty$ o $0 < \mu(y) < \infty\ \forall y \in E$*

Proof. Per irriducibilità, sappiamo che per ogni $x, y \in E$ si ha $x \rightsquigarrow y$ ed esiste $\bar{m} \in \mathbb{N}_0$ per cui $Q^{\bar{m}}(x, y) > 0$. Per ipotesi sappiamo che $\mu^t = \mu^t Q$ cioè $\mu(y) = \sum_{x\in E} \mu(x)q(x, y)$, dunque $\mu^t = \mu^t Q^m$ cioè $\mu(y) = \sum_{z\in E} \mu(z)Q^m(z, y)$ per ogni $m \in \mathbb{N}_0$. Allora, per ogni $x, y \in E$, si ha $\mu(y) \geqslant \mu(x)Q^{\bar{m}}(x, y)$, dunque se esiste $y \in E$ per cui $\mu(y) = 0$, allora deve essere per ogni $x \in E$ $\mu(x) \leqslant \frac{\mu(y)}{Q^{\bar{m}}(x,y)} = 0$. Infine, se esiste $x \in E$ tale che $\mu(x) = \infty$, allora per ogni $y \in E$ deve essere $\mu(y) \geqslant \mu(x)Q^{\bar{m}}(x, y) = \infty$ □

Teorema 4.4.5. *Sia $X = \{X_n\}_{n\in\mathbb{N}}$ irriducibile e ricorrente. Allora, esiste ed è unica (a meno di multipli) una misura invariante $\mu = \{\mu(y)\}_{y\in E}$*

Proof. (Esistenza) Per il teorema precedente, la misura λ_x è invariante per $x \in E$ fissato.
(Unicità) Sia μ misura invariante e definiamo $\rho = \frac{\mu}{\mu(x)}$ (qui stiamo usando che $0 < \mu(x) < \infty$), allora ρ è invariante e soddisfa $\rho(x) = 1$, dunque $\rho = \lambda_x$, dunque $\mu = \mu(x)\rho = \mu(x)\lambda_x$, cioè μ è multiplo di λ_x □

Teorema 4.4.6. *Sia $X = \{X_n\}_{n\in\mathbb{N}}$ irriducibile, allora X è ricorrente positiva se e solo se esiste una misura invariante $\mu = \{\mu(y)\}_{y\in E}$ di massa finita se e solo se esiste una probabilità invariante, unica e vale $\Pi = \{\Pi(x) = \frac{1}{E_x[T_x]}\}_{x\in E}$*

Proof. ($\Longrightarrow$) Fissiamo $x \in E$, sappiamo che λ_x è una misura invariante e $\sum_{y\in E} \lambda_x(y) = E_x[T_x] < \infty$. Normalizzandola, si ottiene una probabilità invariante $\Pi_x = \frac{\lambda_x}{E_x[T_x]}$. Siano ora Π e Π' probabilità invarianti, allora per il teorema precedente sono multiple l'una dell'altra. Ma sono entrambe probabilità, dunque $\Pi = \Pi'$. ($\Longleftarrow$) Dato che Π è una probabilità invariante, allora X è ricorrente perché una probabilità invariante si annulla solo negli stati transitori. Ma λ_x è una misura invariante e tutte le misure invarianti sono multiple l'una dell'altra, dunque $\lambda_x = c\Pi$ e $\sum_{y\in E} \lambda_x(y) = c \sum_{y\in E} \Pi(y) = c < \infty \ \forall x \in E$, cioè X è ricorrente e positiva. □

Dunque, data una catena di Markov irriducibile, possiamo affermare che:
(i) Se esiste una misura invariante di massa finita, allora la catena è ricorrente positiva.
(ii) Se non esistono misure invarianti oppure se esistono almeno due misure invarianti che non sono multiple tra di loro, allora la catena è transitoria.
(iii) Se esiste un'unica (a meno di multipli) misura invariante di massa infinita, la catena può essere transitoria oppure ricorrente nulla.

Teorema 4.4.7. *Se X è una catena di Markov irriducibile su uno spazio E finito, allora X è ricorrente positiva.*

Proof. Se X fosse transitoria, allora $p(X_n = y) \to 0$ per ogni $y \in E$, ma ciò non è possibile perché seguirebbe $1 = \sum_{y\in E} p(X_n) = y \to 0$, il che è assurdo ($E$ è finito!). Dunque, X è ricorrente perciò esiste $\lambda = \{\lambda(y)\}_{y\in E}$ misura invariante. Ma E è finito, dunque $\sum_{y\in E} \lambda(y) < \infty$, ovvero ha massa finita. Concludiamo che X è ricorrente positiva. □

Teorema 4.4.8 (Teorema di convergenza all'equilibrio)**.** *Sia $X = \{X_n\}_{n\in\mathbb{N}}$ una catena di Markov irriducibile su uno spazio degli stati E al più numerabile.*
(i) Se X è transitoria o ricorrente nulla, allora $p_\lambda(X_n = y) \to 0$ per ogni $y \in E$ e per ogni λ distribuzione iniziale.
(ii) Se X è ricorrente positiva, allora esiste ed è unica la probabilità invariante $\Pi = \{\Pi(x) = \frac{1}{E_x[T_x]}\}_{x\in E}$.
Se la catena è aperiodica, allora $p_\lambda(X_n = y) \to \Pi(y)$ per ogni $y \in E$ e per ogni λ distribuzione iniziale. In particolare, $p_x(X_n = y) \to \Pi(y)$ per ogni $x, y \in E$
Se la catena ha periodo $t \in \mathbb{N}_0$, con $t \geqslant 2$, allora per ogni $x, y \in E$ esiste $a_{x,y} \in \{0, ..., t-1\}$ (con $a_{xx} = 0$) tale che $p_x(X_n = y) \to t\Pi(y)$, con $n = a_{xy} + kt$ e $k \to \infty$

4.5 Catene di Markov riducibili

Definizione 4.5.1. *Le classi di comunicazione C_i sono le classi di equivalenza rispetto alla relazione di equivalenza $\leftrightsquigarrow$ su E.*

Esempio 4.5.1. *Sia $\{X_n\}_{n\in\mathbb{N}}$ catena di Markov su $E = \{1, 2, 3, 4\}$ descritta dal grafo in figura. Allora, $Q = \begin{pmatrix} \frac{1}{2} & 0 & 0 & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{4} & \frac{1}{4} & 0 \\ 0 & 0 & 1 & 0 \\ \frac{1}{4} & 0 & 0 & \frac{3}{4} \end{pmatrix}$ e le classi di comunicazione sono $C_1 = \{1, 4\}$, $C_2 = \{2\}$ e $C_3 = \{3\}$*

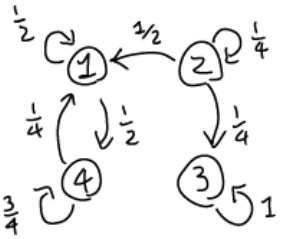


Figure 2: Esempio: Grafo su $\{1, 2, 3, 4\}$

Definizione 4.5.2. *Una classe di comunicazione $C \subseteq E$ si dice chiusa se $\forall x \in C$ e $\forall y \notin C$ si ha $x \not\rightsquigarrow y$. Equivalentemente, $\forall x \in C, \forall y \in E \mid x \rightsquigarrow y$ allora $y \in C$*

Teorema 4.5.1 (Lemma)**.** *Sia $C \subseteq E$ una classe di comunicazione, allora C è chiusa se e solo se $\forall x \in C, \forall y \notin C$ si ha $q(x,y) = 0$*

Corollario 4.5.1.1. *La restrizione di una catena di Markov a una classe di comunicazione $C \subseteq E$ chiusa è una catena irriducibile, con spazio degli stati C e matrice di transizione $Q_{|C} = \{q(x,y)\}_{x,y \in C}$. In particolare, tutte le nozioni studiate per catene di Markov irriducibili si applicano a queste catene ristrette.*

Teorema 4.5.2 (Lemma)**.** *Una classe di comunicazione ricorrente è chiusa, dunque ogni classe di comunicazione non chiusa è transitoria.*

Teorema 4.5.3 (Lemma)**.** *Una classe di comunicazione chiusa e finita è ricorrente positiva.*

Nel caso in cui lo spazio degli stati sia finito, si possono semplicemente classificare gli stati determinando le classi di comunicazione e distinguendole in chiuse e non.

Esempio 4.5.2. *Riprendendo l'esempio precedente, C_1 e C_3 sono chiusa, dunque le restrizioni sono ricorrenti positive e ammettono ciascuna un'unica probabilità invariante, mentre C_2 è non chiusa e dunque la restrizione è transitoria e non ammette probabilità invarianti.*
La classe $C_3 = \{3\}$ supporta la probabilità $\Pi^{(3)}(x) = 1 \cdot \delta_{3x}$, dunque $\Pi^{(3)} = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \end{pmatrix}$

La classe $C_1 = \{1,4\}$ supporta la probabilità $\Pi^{(1)} = \begin{pmatrix} a \\ 0 \\ 0 \\ b \end{pmatrix}$ Dato che ${\Pi^{(1)}}^t Q_{|C_1} = \Pi^{(1)}$, dunque $(a,b)\begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{4} & \frac{3}{4} \end{pmatrix} = (a,b)$, da cui $(a,b) = (\frac{1}{3}, \frac{2}{3})$ perché $a + b = 1$.
Concludiamo che la probabilità invariante generale per la catena è $\Pi = \alpha_1 \Pi^{(1)} + \alpha_3 \Pi^{(3)}$, con $\alpha_1, \alpha_3 \geqslant 0$ e $\alpha_1 + \alpha_3 = 1$

A partire da uno stato $x \in E$ transitorio (con E finito), la catena di Markov finirà per essere assorbita in una classe chiusa C_i. Definiamo $h^{(i)}(x) = p_x(\text{la catena entra nella classe } C_i) = p_x(\exists n \in \mathbb{N} \mid X_n \in C_i)$, allora possiamo

scrivere un sistema di equazioni soddisfatto dalle $\{h^{(i)}(x)\}_{x\in E}$ come segue

$$h^{(i)}(x) = \begin{cases} 1, \ x \in C_i \\ 0, \ x \in C_j, j \neq i \\ \sum_{y\in E} q(x,y)h^{(i)}(y) \end{cases}$$

Teorema 4.5.4. *Se $|E| < \infty$, il sistema ammette sempre un'unica soluzione.*

Consideriamo ora una catena di Markov $X = \{X_n\}_{n\in\mathbb{N}}$ irriducibile e ricorrente su E, allora sappiamo esiste un'unica (a meno di multipli) misura invariante $\mu = \{\mu(x)\}_{x\in E}$, fissando $x \in E$ e imponendo $\mu(x) = 1$, allora $\mu = \lambda_x$ deve definire per ogni $y \in E$ $\lambda_x(y) = E_x[\sum_{n=1}^{T_x} \chi_{\{X_n=y\}}] = E_x[\sum_{n=1}^{\infty} \chi_{\{X_n=y\}}\chi_{\{n\leqslant T_x\}}] = \sum_{n=1}^{\infty} p_x(n \leqslant T_x, X_n = y) = \sum_{n=1}^{\infty} p_x(X_1 \neq x, ..., X_{n-1} \neq x, X_n = y) = \sum_{n=1}^{\infty}[\sum_{x_1\neq x} \cdots \sum_{x_{n-1}\neq x} q(x,x_1)q(x_1,x_2)...q(x_{n-1},y)]$

Teorema 4.5.5. *Se $\mu = \{\mu(y)\}_{y\in E}$ è invariante con $\mu(x) = 1$, allora $\mu(y) \geqslant \lambda_x(y) \ \forall y \in E$*

Proof. Dato che μ è invariante, allora $\mu(y) = \mu_{z\in E}\mu(z)q(z,y)$ Sia $x \in E$ tale che $\mu(x) = 1$, allora si ha $\mu(y) \geqslant \sum_{z=x} \mu(z)q(z,y) = \mu(x)q(x,y) = q(x,y)$ in quanto $\mu, q \geqslant 0$. Iterando l'argomento e avendo mostrato che $\mu(y) \geqslant q(x,y)$ per ogni $y \in E$, si ha $\mu(y) = \sum_{z\in E} \mu(z)q(z,y) = \mu(x)q(x,y) + \sum_{z\neq x} \mu(z)q(z,y) \geqslant q(x,y)+\sum_{z\neq x} q(x,z)q(z,y) = q(x,y)+\sum_{x_1\neq x} q(x,x_1)q(x_1,y)$.
Ricordiamo che $\lambda_x(y) = q(x,y)+\sum_{x_1\neq x} q(x,x_1)q(x_1,y)+\sum_{x_1\neq x, x_2\neq x} q(x,x_1)q(x_1,x_2)q(x_2,y)+$
...
Per induzione, supponendo sia vero $\mu(y) \geqslant \sum_{n=1}^{N}[\sum_{x_1\neq x} \cdots \sum_{x_{n-1}\neq x} q(x,x_1)q(x_1,x_2)...q(x_{n-1},y)]$ si ottiene la tesi scrivendo $\mu(y) = q(x,y) + \sum_{z\neq x} \mu(z)q(z,y)$ perché $\mu(z) \geqslant \sum_{n=1}^{N}[\sum_{x_1\neq x} \cdots \sum_{x_{n-1}\neq x} q(x,x_1)q(x_1,x_2)...q(x_{n-1},z)]$ □

Se si mostra che λ_x è una misura invariante segue che lo è anche $\mu - \lambda_x$ ed essendo per costruzione $\mu(x) - \lambda_x(x) = 1 - 1 = 0$, dunque $\mu = \lambda_x$

4.5.1 "Rovina del giocatore"

Usiamo qui equivalentemente h_x e $h(x)$
Stiamo considerando un gioco ripetuto in cui ad ogni turno punto 1 euro, se vinco ne ricevo 2 e se perdo non ricevo niente. Siano $P \in (0,1)$ la probabilità di vittoria in un turno, $A \in \mathbb{N}_0$ il capitale iniziale e $B \in \mathbb{N}_0$ l'obiettivo di vincita. Considero $X = \{X_n\}_{n\in\mathbb{N}}$ la passeggiata aleatoria semplice sull'insieme $E = \{-A, -A+1, ..., 0, ..., B-1, B\}$ (dove X_n è il guadagno

dopo n turni) con condizioni al bordo assorbenti (mi ritiro sia se perdo tutto sia se arrivo all'obiettivo), iniziando con $X_0 = 0$. Dunque, $q(x,y) = \begin{cases} P,\ x \leqslant B-1, y = x+1 \\ 1-P,\ x \geqslant -A+1, y = x-1 \\ 1,\ x = y = -A \vee x = y = B \\ 0,\ \textit{altrimenti} \end{cases}$

Si hanno le classi di comunicazione $C_1 = \{B\}$ (chiusa e finita), $C_2 = \{-A\}$ (chiusa e finita) e $C_3 = \{-A+1, ..., B-1\}$ (non chiusa).

La probabilità di vincita è una probabilità di assorbimento $h(x) = h^{\{B\}}(x) = p_x(\text{la catena raggiunge prima o poi } \{B\})$ con $x = 0$.

Allora, $h(x) = \begin{cases} 1,\ x = B \\ 0,\ x = -A \\ \sum_{y \in E} q(x,y)h(y),\ x \in \{-A+1, ..., B-1\} \end{cases} =$

$$= \begin{cases} 1,\ x = B \\ 0,\ x = -A \\ Ph_{x+1} + (1-P)h_{x-1},\ x \in \{-A+1, ..., B-1\} \end{cases}$$

Se guardiamo il caso non al bordo, l'equazione da risolvere è un equazione differenziale discreta lineare. Consideriamo il caso $P = \frac{1}{2}$, allora $h_x = \frac{h_{x+1}+h_{x-1}}{2}$ e ci sono due soluzioni banali $h(x) = 1$ e $h(x) = x$. Dunque, $h(x) = \alpha + \beta x$ è soluzione e, imponendo $h(-A) = 0$ e $h(B) = 1$, si ottiene $h(x) = \frac{A+x}{A+B}$, quindi $h(0) = \frac{1}{1+\frac{B}{A}}$. Quello che otteniamo è che la probabilità di vincere, ad esempio nel caso in cui B è un centesimo di A, la probabilità di vincere è del 99%.

Se $P \neq \frac{1}{2}$, allora si hanno per soluzioni $h(x) = 1$ e $h(x) = (\frac{1-P}{P})^x$ e imponendo le condizioni al bordo come prima si può ricavare una conclusione in modo analogo.

E' interessante notare che è sufficiente conoscere la funzione in due punti adiacenti per avere un'unica soluzione.

4.5.2 Algoritmo "PageRank" di Google

Il problema è di attribuire una nozione di importanza per ordinare le pagine, che sia robusta e non facilmente aggirabile.

Associamo a ogni pagine x un numero $h_x \in (0, \infty)$ che rappresenta l'importanza. Questo non è sufficiente, ma vogliamo tradurre la funzione in modo che associ l'importanza a quante pagine la linkano. Dunque, $h_y = \sum_{x \in E | x \to y} \frac{h_x}{deg^+(x)}\ \forall y \in$

E, dove la freccia sta a dire che esiste un link e $deg^+(x) = \#\{y \in E \mid x \to y\}$ Vogliamo quindi cercare la misura invariante h rispetto alla matrice di transizione, definita ponendo $q(x,y) = \begin{cases} \frac{1}{deg^+(x)}, \ x \rightsquigarrow y \\ 0, \ \textit{altrimenti} \end{cases}$ allora, questa matrice descrive un passaggio su Internet. Questa catena non è irriducibile perché non tutte le pagine sono linkate tra di loro, ma si risolve passando a una pagina casuale con una probabilità P.